

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
PROGRAMA DE PÓS-GRADUAÇÃO EM ECONOMIA
Microeconometria – 2015/3

Microeconometrics: Lecture Notes

Autor: Paulo Ferreira Naibert
Professor: Hudson Torrent

Porto Alegre
30/06/2020
Revisão: July 13, 2020

1 Regressão MQO Clássico

Wooldridge (2010, C.4 – The Single-Equation Linear Model and OLS Estimation, p.49–76)

1.1 Modelo de equações lineares

O modelo populacional que estudamos é linear em seus parâmetros,

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_K x_K + u \quad (1.1)$$

onde:

y, x_1, \dots, x_K são escalares aleatórios e observáveis (i.e., conseguimos observá-los em uma amostra aleatória da população);

u é o *random disturbance* não observável, ou erro;

$\beta_0, \beta_1, \dots, \beta_K$ são parâmetros (constantes) que gostaríamos de estimar.

Notação Vetorial

Wooldridge (2010, Sec. 4.2 – Asymptotic Properties of OLS; p.51)

Por conveniência, escrevemos a equação populacional em forma de vetor:

$$y = \mathbf{x}\boldsymbol{\beta} + u \quad (1.2)$$

onde,

$\mathbf{x} \equiv (x_1, \dots, x_K)$ é um vetor $1 \times K$ de regressores;

$\boldsymbol{\beta} \equiv (\beta_1, \dots, \beta_K)'$ é um vetor $K \times 1$.

Uma vez que a maioria das equações contém um intercepto, assumiremos que $x_1 \equiv 1$, visto que essa hipótese deixa a interpretação mais fácil.

Amostra Aleatória

Assumimos que conseguimos obter uma amostra aleatória de tamanho N da população para estimarmos $\boldsymbol{\beta}$. Dessa forma, $\{(\mathbf{x}_i, y_i); i = 1, 2, \dots, N\}$ são tratados como variáveis aleatória independentes, identicamente distribuídas, onde \mathbf{x}_i é $1 \times K$ e y_i é escalar. Para cada observação i , temos:

$$y_i = \mathbf{x}_i \boldsymbol{\beta} + u_i. \quad (1.3)$$

onde \mathbf{x}_i é um vetor $1 \times K$ de regressores.

1.2 Hipóteses

OLS.1 $y_i = \mathbf{x}_i \boldsymbol{\beta} + u_i, \quad i = 1, \dots, N;$

OLS.2 \mathbf{X} é não estocástica;

OLS.3 $\{u_i\}_{i=1}^N$ é *iid* com e para cada $i = 1, \dots, N$:

$$E(u_i) = 0$$

$$\text{Var}(u_i) = E(u_i^2) = \sigma^2$$

OLS.2' \mathbf{X} é estocástica;

OLS.3'

$$E(u_i|\mathbf{X}) = 0,$$

$$\text{Var}(u_i|\mathbf{X}) = E\left\{[u_i - E(u_i|\mathbf{X})]^2|\mathbf{X}\right\} = E(u_i^2|\mathbf{X}) = \sigma^2.$$

Remark. $E(u_i|\mathbf{X}) = 0$ implica que u_i é **não correlacionado** com todos os regressores x_k para $k = 1, \dots, K$. **Exogeneidade estrita.**

1.3 Estimação

Usando **OLS.1:**

$$y_i = \mathbf{x}_i\boldsymbol{\beta} + u_i$$

$$\mathbf{x}_i'y_i = \mathbf{x}_i'\mathbf{x}_i\boldsymbol{\beta} + \mathbf{x}_i'u_i$$

$$E(\mathbf{x}_i'y_i) = E(\mathbf{x}_i'\mathbf{x}_i)\boldsymbol{\beta} + E(\mathbf{x}_i'u_i)$$

Usando $E(\mathbf{x}_i'u_i) = 0$ [Qual seria essa hipótese?]

$$E(\mathbf{x}_i'y_i) = E(\mathbf{x}_i'\mathbf{x}_i)\boldsymbol{\beta}$$

$$\boxed{\boldsymbol{\beta} = [E(\mathbf{x}_i'\mathbf{x}_i)]^{-1}E(\mathbf{x}_i'y_i)} \quad (1.4)$$

Agora, usando o **princípio da analogia** e utilizando **estimadores amostrais**:

$$\boxed{\hat{\boldsymbol{\beta}} = \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'\mathbf{x}_i\right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'y_i\right)} \quad (1.5)$$

Podemos desenvolver essa equação para:

$$\begin{aligned} \hat{\boldsymbol{\beta}} &= \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'\mathbf{x}_i\right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'(\mathbf{x}_i\boldsymbol{\beta} + \mathbf{u}_i)\right) \\ &= \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'\mathbf{x}_i\right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'\mathbf{x}_i\boldsymbol{\beta}\right) + \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'\mathbf{u}_i\right) \\ \boxed{\hat{\boldsymbol{\beta}} &= \boldsymbol{\beta} + \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'\mathbf{x}_i\right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'\mathbf{u}_i\right)} \end{aligned} \quad (1.6)$$

1.3.1 Notação Matricial

Empilhando as N observações, obtemos a **Notação Matricial**:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u} \quad (1.7)$$

\mathbf{y} é um vetor $N \times 1$;

\mathbf{X} é uma matriz $N \times K$ de regressores, com N vetores, \mathbf{x}_i , de dimensão $1 \times K$ empilhados;

$\boldsymbol{\beta}$ é um vetor $K \times 1$;

\mathbf{u} é um vetor $N \times 1$;

$$\mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix}; \quad \mathbf{X} = \begin{bmatrix} \mathbf{x}_1 \\ \vdots \\ \mathbf{x}_N \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1K} \\ \vdots & \vdots & \ddots & \vdots \\ x_{N1} & x_{N2} & \dots & x_{NK} \end{bmatrix}; \quad \mathbf{u} = \begin{bmatrix} u_1 \\ \vdots \\ u_N \end{bmatrix}.$$

As somas de vetores viram simples multiplicações de matrizes e a equação (1.5), vira:

$$\hat{\beta} = (N^{-1}\mathbf{X}'\mathbf{X})^{-1}(N^{-1}\mathbf{X}'\mathbf{y}) \implies \boxed{\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{y})} \quad (1.8)$$

1.4 Valor Esperado

$$\begin{aligned} E(\hat{\beta}) &= E[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}] = E[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \mathbf{u})] = E[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}] \\ &= E(\beta) + E[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}] \implies \boxed{E(\hat{\beta}) = \beta + E[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}]} \end{aligned}$$

1.4.1 Viés

$$B(\hat{\beta}) = E(\hat{\beta}) - \beta \implies \boxed{B(\hat{\beta}) = E[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}]}$$

Remark. Sob **OLS.2'** e **OLS.3'**:

$$E[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}] = E\{E[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}|\mathbf{X}]\} = E\left\{(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\underbrace{E(\mathbf{u}|\mathbf{X})}_{=0}\right\} = 0$$

ou seja, $B(\hat{\beta}) = 0$, logo $\hat{\beta}$ é **não-viciado**. O que também é equivalente a $E(\hat{\beta}) = \beta$.

1.5 Variância

Supondo **OLS.2'** e **OLS.3'**:

$$\begin{aligned} \text{Var}(\hat{\beta}|\mathbf{X}) &= E\left\{\left[\hat{\beta} - E(\hat{\beta}|\mathbf{X})\right]^2|\mathbf{X}\right\} \\ &= E\left\{\left[\hat{\beta} - E(\hat{\beta}|\mathbf{X})\right]\left[\hat{\beta} - E(\hat{\beta}|\mathbf{X})\right]'|\mathbf{X}\right\} \\ &= E\left\{[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}][(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}]'|\mathbf{X}\right\} \\ &= E[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}\mathbf{u}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}|\mathbf{X}] \end{aligned}$$

$$\boxed{\text{Var}(\hat{\beta}|\mathbf{X}) = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'E[\mathbf{u}\mathbf{u}'|\mathbf{X}]\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}}$$

1.5.1 Homocedasticidade

Supondo **homocedasticidade** e ausência de correlação serial: $E[\mathbf{u}\mathbf{u}'|\mathbf{X}] = \sigma^2\mathbf{I}_N$. Assim,

$$\text{Var}(\hat{\beta}|\mathbf{X}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{I}_N\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \implies \boxed{\text{Var}(\hat{\beta}|\mathbf{X}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}}.$$

2 Ausência de Exogeneidade Estrita

Nem sempre poderemos supor **exogeneidade estrita**. Por exemplo, no modelo com variável defasada mostrado abaixo:

$$\begin{aligned}y_t &= \beta_0 + \beta_1 y_{t-1} + \beta_2 x_{1t} + u_t \\y_{t-1} &= \beta_0 + \beta_1 y_{t-2} + \beta_2 x_{1t-1} + u_{t-1} \\y_t &= \beta_0(1 + \beta_1) + \beta_1^2 y_{t-2} + \beta_1 \beta_2 x_{1t-1} + \beta_2 x_{1t} + u_t + \beta_1 u_{t-1},\end{aligned}$$

o erro é correlacionado com o regressor y_{t-1} . Nesse caso, tentaremos obter apenas **consistência** e **variância assintótica** do estimador. Para tanto, utilizaremos a equação (1.6):

$$\hat{\beta} = \beta + \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i u_i \right).$$

Aqui começaria a seção 17.

2.1 Consistência

Vamos definir a matriz $K \times K$, $\mathbf{A} \equiv E(\mathbf{x}'_i \mathbf{x}_i)$. Supondo \mathbf{A} , finita e positiva definida, posto(\mathbf{A}) = K . Usando **LGN matricial** (Definição 17.2 na página 43), temos:

[lembrar que as dimensões dos vetores estão invertidas: $1 \times K$ e **não** $K \times 1$]

$$N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \xrightarrow{p} \mathbf{A} \implies \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \xrightarrow{p} \mathbf{A}^{-1}. \quad (2.1)$$

Além disso, vamos supor $E(\mathbf{x}'_i u_i) = 0$, o que corresponde a $\text{Cov}(\mathbf{x}_i, u_i) = 0$, ou seja, o erro u_i **não** é correlacionado com os regressores da própria equação. Isso é bem menos que exogeneidade estrita. Então,

$$N^{-1} \sum_{i=1}^N \mathbf{x}'_i u_i \xrightarrow{p} E(\mathbf{x}'_i u_i) = \mathbf{0}_K.$$

Logo,

$$\boxed{\hat{\beta} = \beta + \underbrace{\left(\sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \left(\sum_{i=1}^N \mathbf{x}'_i u_i \right)}_{\xrightarrow{p} 0}}$$

Então, $(\hat{\beta} - \beta) \xrightarrow{p} 0$ que é equivalente a $\hat{\beta} \xrightarrow{p} \beta$ e $\text{plim } \hat{\beta} = \beta$, ou seja, $\hat{\beta}$ é **consistente** para β .

2.2 Normalidade Assintótica

$$\begin{aligned}\hat{\beta} &= \beta + \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i u_i \right) \\ (\hat{\beta} - \beta) &= \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i u_i \right) \\ \sqrt{N}(\hat{\beta} - \beta) &= \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i \right)\end{aligned}$$

Supondo $E(x_{ik}^2 u_i^2) < +\infty$, $k = 1, \dots, K$, e definindo $\mathbf{B} = E[\mathbf{x}'_i u_i u_i \mathbf{x}_i] = E[u_i^2 \mathbf{x}'_i \mathbf{x}_i]$. Temos, pela Definição 17.7 (TCL), que

$$N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i \xrightarrow{d} N(\mathbf{0}, \mathbf{B}) \implies N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i = O_p(1) \quad (2.2)$$

Além disso, vamos utilizar a matriz **simétrica** e **não singular** \mathbf{A} da equação (2.1). Assim, temos

$$\begin{aligned}\sqrt{N}(\hat{\beta} - \beta) &= \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i \right) \\ &= \left[\left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} + \mathbf{A}^{-1} - \mathbf{A}^{-1} \right] \left(N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i \right) \\ &= \left[\left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} - \mathbf{A}^{-1} \right] \left(N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i \right) + \mathbf{A}^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i \right),\end{aligned}$$

Podemos inverter \mathbf{A} porque ela tem posto completo (não singular). Pelas propriedades de \mathbf{A} , temos:

$$N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \xrightarrow{p} \mathbf{A} \implies \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} - \mathbf{A}^{-1} = o_p(1).$$

Então,

$$\sqrt{N}(\hat{\beta} - \beta) = o_p(1)O_p(1) + \mathbf{A}^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i \right),$$

Usando (2.2) e o Lema 17.2.

$$\mathbf{A}^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i \right) \xrightarrow{d} N(\mathbf{0}, \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1}).$$

Lembrando que $o_p(1)O_p(1) = o_p(1)$, temos:

$$\sqrt{N}(\hat{\beta} - \beta) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1}) \implies \sqrt{N}(\hat{\beta} - \beta) \stackrel{a}{\sim} \mathcal{N}(\mathbf{0}, \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1})$$

2.3 Variância

$$\mathbf{V} = \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1}$$

$$\mathbf{V} = \mathbb{E}[(\mathbf{x}'_i \mathbf{x}_i)]^{-1} \mathbb{E}[(\mathbf{x}'_i u'_i u_i \mathbf{x}_i)] \mathbb{E}[(\mathbf{x}'_i \mathbf{x}_i)]^{-1}$$

$$\mathbf{V} = \mathbb{E}[(\mathbf{x}'_i \mathbf{x}_i)]^{-1} \mathbb{E}[u_i^2 \mathbf{x}'_i \mathbf{x}_i] \mathbb{E}[(\mathbf{x}'_i \mathbf{x}_i)]^{-1}.$$

2.3.1 Homocedasticidade

Sob **Homocedasticidade**, temos $\mathbf{B} = \mathbb{E}(u_i^2 \mathbf{x}'_i \mathbf{x}_i) = \sigma^2 \mathbb{E}(\mathbf{x}'_i \mathbf{x}_i)$, logo

$$\boxed{\mathbf{V} = \sigma^2 \mathbb{E}[(\mathbf{x}'_i \mathbf{x}_i)]^{-1}}.$$

2.3.2 Estimador Amostral

$$\begin{aligned} \hat{\mathbf{V}} &= \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N u_i^2 \mathbf{x}'_i \mathbf{x}_i \right) \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \\ &= N \left(\sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \left(\sum_{i=1}^N u_i^2 \mathbf{x}'_i \mathbf{x}_i \right) \left(\sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \end{aligned}$$

$$\boxed{\hat{\mathbf{V}} = N (\mathbf{X}' \mathbf{X})^{-1} \left(\sum_{i=1}^N u_i^2 \mathbf{x}'_i \mathbf{x}_i \right) (\mathbf{X}' \mathbf{X})^{-1}}.$$

2.3.3 Variância do estimador de OLS

$$\text{Var}(\sqrt{N} \hat{\boldsymbol{\beta}}) = \mathbf{V}$$

$$\text{Var}(\hat{\boldsymbol{\beta}}) = N^{-1} \mathbf{V}$$

$$\boxed{\text{Var}(\hat{\boldsymbol{\beta}}) = (\mathbf{X}' \mathbf{X})^{-1} \left(\sum_{i=1}^N u_i^2 \mathbf{x}'_i \mathbf{x}_i \right) (\mathbf{X}' \mathbf{X})^{-1}}.$$

A variância **Robusta** é:

$$\boxed{\widehat{\text{Var}}(\hat{\boldsymbol{\beta}}) = (\mathbf{X}' \mathbf{X})^{-1} \left(\sum_{i=1}^N \hat{u}_i^2 \mathbf{x}'_i \mathbf{x}_i \right) (\mathbf{X}' \mathbf{X})^{-1}}.$$

A variância sob **Homocedasticidade** é:

$$\boxed{\widehat{\text{Var}}(\hat{\boldsymbol{\beta}}) = \hat{\sigma}^2 (\mathbf{X}' \mathbf{X})^{-1}}.$$

3 System OLS (SOLS)

Wooldridge (2010, C.7 – Estimating Systems of Equations by OLS and GLS, p.143–179)

Wooldridge (2010, Sec.7.3 – System OLS Estimation of a Multivariate Linear System, p.147)

3.1 Modelo Linear

Assumimos que temos as seguintes observações *cross section iid*: $\{(\mathbf{X}_i, \mathbf{y}_i) : i = 1, \dots, N\}$, onde:

\mathbf{X}_i é uma matriz $G \times K$ e contém as variáveis explicativas que aparecem em qualquer lugar do sistema.

\mathbf{y}_i é um vetor $G \times 1$, que contém as variáveis dependentes para todas as equações G (ou períodos de tempo, no caso de dados de painel).

O modelo linear multivariado para uma observação (draw) aleatória da população pode ser expresso como:

$$\mathbf{y}_i = \mathbf{X}_i \boldsymbol{\beta} + \mathbf{u}_i, \quad i = 1, \dots, N, \quad (3.1)$$

onde:

$\boldsymbol{\beta}$ é um vetor $K \times 1$ de parâmetros de interesse; e

\mathbf{u}_i é um vetor $G \times 1$ de não observáveis.

A equação (3.1) explica as G variáveis y_{i1}, \dots, y_{iG} em termos de \mathbf{X}_i e das não observáveis \mathbf{u}_i . Por causa da hipótese de amostra aleatória podemos escrever tudo em termos de uma observação genérica.

3.2 Hipóteses

Wooldridge (2010, Sec.7.3.1)

SOLS.1 $E(\mathbf{X}_i' \mathbf{u}_i) = \mathbf{0}_{K \times 1}$.

SOLS.2 $\mathbf{A} \equiv E(\mathbf{X}_i' \mathbf{X}_i)$ é não singular (tem posto pleno, posto igual a K).

3.3 Estimação

Note que, sob **SOLS.1**, temos:

$$E[\mathbf{X}_i' (\mathbf{y}_i - \mathbf{X}_i \boldsymbol{\beta})] = \mathbf{0}$$

$$E(\mathbf{X}_i' \mathbf{X}_i) \boldsymbol{\beta} = E(\mathbf{X}_i' \mathbf{y}_i)$$

$$\boldsymbol{\beta} = [E(\mathbf{X}_i' \mathbf{X}_i)]^{-1} E(\mathbf{X}_i' \mathbf{y}_i) \quad (3.2)$$

Usando estimadores amostrais:

$$\hat{\boldsymbol{\beta}}^{SOLS} = \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{y}_i \right). \quad (3.3)$$

Para computar $\hat{\boldsymbol{\beta}}$ usando linguagem de computação é mais fácil utilizar a notação matricial. Para tanto, cortamos os N^{-1} e substituímos os somatórios por multiplicações de matrizes.

$$\hat{\boldsymbol{\beta}}^{SOLS} = (\mathbf{X}' \mathbf{X})^{-1} (\mathbf{X}' \mathbf{y}) \quad (3.4)$$

onde

$\mathbf{X} \equiv (\mathbf{X}_1', \dots, \mathbf{X}_N')$ é uma matriz $NG \times K$ dos \mathbf{X}_i empilhados.

$\mathbf{y} \equiv (\mathbf{y}_1', \dots, \mathbf{y}_N')$ é um vetor $NG \times 1$ das observações \mathbf{y}_i empilhadas.

3.4 Consistência

Para provarmos a **consistência** do estimador, usamos as equações (3.3) e (3.1):

$$\begin{aligned}\hat{\beta}^{SOLS} &= \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{y}_i \right) \\ &= \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left[N^{-1} \sum_{i=1}^N \mathbf{X}_i' (\mathbf{X}_i \beta + \mathbf{u}_i) \right] \\ &= \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \beta \right) + \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right).\end{aligned}$$

E chegamos em:

$$\boxed{\hat{\beta}^{SOLS} = \beta + \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right).} \quad (3.5)$$

Por **SOLS.1**:

$$N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \xrightarrow{p} \mathbf{0};$$

e por **SOLS.2**

$$\left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \xrightarrow{p} \mathbf{A}^{-1}.$$

Resumimos esse resultado pelo seguinte Teorema:

Theorem 3.1 (Consistência do SOLS). Sob Hipóteses **SOLS.1** e **SOLS.2**, temos

$$\boxed{\hat{\beta}^{SOLS} \xrightarrow{p} \beta}.$$

3.5 Normalidade Assintótica

De (3.5):

$$\begin{aligned}\hat{\beta} &= \beta + \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right) \\ (\hat{\beta} - \beta) &= \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right).\end{aligned}$$

E chegamos em:

$$\boxed{\sqrt{N}(\hat{\beta} - \beta) = \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right).} \quad (3.6)$$

Uma vez que $E(\mathbf{X}_i' \mathbf{u}_i) = 0$, sob a hipótese **SOLS.1**, a definição 17.7 (**TCL**) implica que:

$$N^{-1/2} \sum_{i=1}^N \mathbf{X}_i \mathbf{u}_i \xrightarrow{d} N(\mathbf{0}, \mathbf{B}),$$

onde

$$\mathbf{B} \equiv E(\mathbf{X}_i' \mathbf{u}_i \mathbf{u}_i' \mathbf{X}_i) \equiv \text{Var}(\mathbf{X}_i \mathbf{u}_i).$$

Em particular,

$$N^{-1/2} \sum_{i=1}^N \mathbf{X}_i \mathbf{u}_i = O_p(1).$$

Porém,

$$\left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} = (\mathbf{X}' \mathbf{X} / N)^{-1} = \mathbf{A}^{-1} + o_p(1).$$

Sendo assim,

$$\begin{aligned} \sqrt{N}(\hat{\beta} - \beta) &= \left[\mathbf{A}^{-1} + \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} - \mathbf{A}^{-1} \right] \left(N^{-1/2} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right) \\ &= \mathbf{A}^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right) + [(\mathbf{X}' \mathbf{X} / N)^{-1} - \mathbf{A}^{-1}] \left(N^{-1/2} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right) \\ &= \mathbf{A}^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right) + o_p(1) O_p(1) \\ &= \mathbf{A}^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right) + o_p(1) \end{aligned}$$

$\sqrt{N}(\hat{\beta} - \beta) \xrightarrow{d} N(\mathbf{0}, \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1})$

(3.7)

3.6 Variância Assintótica

SOLS.3: Homocedasticidade $E(\mathbf{X}_i' \mathbf{u}_i \mathbf{u}_i' \mathbf{X}_i) = \sigma^2 E(\mathbf{X}_i' \mathbf{X}_i)$.

De (3.7), vamos definir $\mathbf{V} = \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1}$. Sob **SOLS.3**, $\mathbf{V} = \sigma^2 [E(\mathbf{X}_i' \mathbf{X}_i)]^{-1}$. Estimando:

$$\hat{\sigma}^2 = \frac{1}{NG - K} \sum_{i=1}^N \sum_{g=1}^G \hat{u}_{ig}^2$$

onde $\hat{u}_{ig} = y_{ig} - \mathbf{x}_{ig} \hat{\beta}^{SOLS}$

3.6.1 A Matriz Robusta

$$\hat{\mathbf{V}} = (\mathbf{X}' \mathbf{X})^{-1} \left(\sum_{i=1}^N \mathbf{X}_i' \hat{\mathbf{u}}_i \hat{\mathbf{u}}_i' \mathbf{X}_i \right) (\mathbf{X}' \mathbf{X})^{-1}$$

$$\sum_{i=1}^N \mathbf{X}_i' \hat{\Omega} \mathbf{X}_i \xrightarrow{p} E(\mathbf{X}_i \Omega \mathbf{X}_i)$$

Mas **não** é verdade que $\hat{\Omega} \xrightarrow{p} \Omega$.

- Havendo constante, **SOLS.1** $\implies E(\mathbf{u}_i) = 0$
- Ausência de correlação entre os regressores de uma equação e o erro da própria equação \implies **SOLS.1**.

3.6.2 Variância Assintótica

REVER

$$\text{Avar}(\hat{\beta}^{SOLS}) = \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1} / N. \quad (3.8)$$

Assim, $\text{Avar}(\hat{\beta}^{SOLS})$ tende a zero a uma taxa $1/N$, como esperado. Estimação consistente de \mathbf{A} é:

$$\hat{\mathbf{A}} \equiv \mathbf{X}'\mathbf{X}/N = N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i$$

Um estimador consistente para \mathbf{B} pode ser achado usando o princípio da analogia.

$$\mathbf{B} = E(\mathbf{X}_i' \mathbf{u}_i \mathbf{u}_i' \mathbf{X}_i), \quad N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \mathbf{u}_i' \mathbf{X}_i \xrightarrow{p} \mathbf{B}.$$

Uma vez que não podemos observar \mathbf{u}_i , usamos os resíduos da estimação de SOLS:

$$\hat{\mathbf{u}}_i \equiv \mathbf{y}_i - \mathbf{X}_i \hat{\beta} = \mathbf{u}_i - \mathbf{X}_i (\hat{\beta} - \beta).$$

Assim, definimos $\hat{\mathbf{B}}$ e usando LGN, podemos mostrar que:

$$\hat{\mathbf{B}} \equiv N^{-1} \sum_{i=1}^N \mathbf{X}_i' \hat{\mathbf{u}}_i \hat{\mathbf{u}}_i' \mathbf{X}_i \xrightarrow{p} \mathbf{B}.$$

onde supomos que certos momentos envolvendo \mathbf{X}_i e \mathbf{u}_i são finitos.

Portanto, $\text{Avar}[\sqrt{N}(\hat{\beta} - \beta)]$ é **consistentemente** estimado por $\hat{\mathbf{A}}^{-1} \hat{\mathbf{B}} \hat{\mathbf{A}}^{-1}$, e $\text{Avar}(\hat{\beta})$ é estimado como:

$$\hat{\mathbf{V}} \equiv \left(\sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(\sum_{i=1}^N \mathbf{X}_i' \hat{\mathbf{u}}_i \hat{\mathbf{u}}_i' \mathbf{X}_i \right) \left(\sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1}.$$

Sob as hipóteses **SOLS.1** e **SOLS.2**, nós fazemos inferência em β como $\hat{\beta}$ fosse normalmente distribuído com média β e variância $\hat{\mathbf{V}}$.

4 Dados de Painel (POLS)

Wooldridge (2010, C.7 – Estimating Systems of Equations by OLS and GLS. p.143-179)

Wooldridge (2010, Sec.7.8 – The Linear Panel Data Model, Revisited. p.169)

4.1 Modelo Linear para Dados de Painel

No caso de dados de painel, temos a seguinte amostra aleatória:

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + u_{it}, \quad i = 1, \dots, N, \quad t = 1, \dots, T. \quad (4.1)$$

onde

y_{it} é um escalar.

$\boldsymbol{\beta}$ é um vetor $K \times 1$.

\mathbf{x}_{it} é um vetor $K \times 1$.

u_{it} é um escalar.

Em notação vetorial:

$$\mathbf{y}_i = \mathbf{X}_i\boldsymbol{\beta} + \mathbf{u}_i, \quad i = 1, \dots, N,$$

onde

\mathbf{y}_i é um vetor $T \times 1$.

$\boldsymbol{\beta}$ é um vetor $K \times 1$.

\mathbf{X}_i é uma matriz $K \times T$.

\mathbf{u}_i é um vetor $T \times 1$.

Em notação matricial:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$$

onde

\mathbf{y} é um vetor $NT \times 1$.

$\boldsymbol{\beta}$ é um vetor $K \times 1$.

\mathbf{X} é uma matriz $NT \times K$.

\mathbf{u} é um vetor $NT \times 1$.

4.2 Estimação

$$\sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i = \sum_{i=1}^N \sum_{t=1}^T \mathbf{x}_{it}' \mathbf{x}_{it}; \quad \sum_{i=1}^N \mathbf{X}_i' \mathbf{y}_i = \sum_{i=1}^N \sum_{t=1}^T \mathbf{x}_{it}' y_{it}.$$

Portanto, podemos escrever $\hat{\boldsymbol{\beta}}$ como:

$$\hat{\boldsymbol{\beta}}^{POLS} = \left(\sum_{i=1}^N \sum_{t=1}^T \mathbf{x}_{it}' \mathbf{x}_{it} \right)^{-1} \left(\sum_{i=1}^N \sum_{t=1}^T \mathbf{x}_{it}' y_{it} \right). \quad (4.2)$$

Este estimador é chamado **estimador de Mínimos Quadrados Agrupados (POLS)** porque ele corresponde a rodar uma regressão OLS nas observações agrupadas através de i e t . O estimador da equação (4.2) é o mesmo para unidades de *cross section* amostradas em diferentes pontos do tempo.

4.3 Hipóteses

POLS.1 $E(\mathbf{X}'_i \mathbf{u}_i) = E(\mathbf{x}'_{it} u_{it}) = \mathbf{0}_{K \times 1}$, para cada $i = 1, \dots, N$ e $t = 1, \dots, T$.

De fato, **POLS.1** \implies **SOLS.1**.

Obs: O modelo (4.1) permite $y_{i,t-1}$ como regressor, se satisfeita **POLS.1**.

5 Alguns Testes

Lembrando a equação do modelo (4.1):

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + u_{it}$$

5.1 Autocorrelação dos Resíduos

Nos dois testes apresentado, primeiro precisamos guardar os resíduos estimado. Para tanto, rodamos a regressão do modelo (4.1) e guardamos os resíduos:

$$\hat{u}_{it} = y_{it} - \mathbf{x}_{it}\hat{\boldsymbol{\beta}}^{POLS}. \quad (5.1)$$

Com Exogeneidade Estrita Sob exogeneidade estrita, rodamos a seguinte regressão dos resíduos:

$$\hat{u}_{it} = \delta_0 + \delta\hat{u}_{it-1} + \varepsilon_{it}, \quad i = 1, \dots, N; \quad t = 1, \dots, T.$$

Então, testamos

$$H_0 : \delta_1 = 0$$

$$H_1 : \delta_1 \neq 0$$

via teste t (pode ser robusto).

Sem Exogeneidade Estrita (Apenas exogeneidade contemporânea) Sem exogeneidade estrita, rodamos a seguinte regressão dos resíduos:

$$\hat{u}_{it} = \mathbf{x}_{it}\boldsymbol{\alpha} + \delta\hat{u}_{it-1} + \varepsilon_{it}, \quad i = 1, \dots, N; \quad t = 1, \dots, T.$$

Então, testamos

$$H_0 : \delta_1 = 0$$

$$H_1 : \delta_1 \neq 0$$

via teste t .

5.2 Heterocedasticidade

Com os resíduos da equação (5.1), rodamos a seguinte regressão:

$$\hat{u}_{it}^2 = \gamma_0 + \gamma_1\hat{y}'_{it} + \gamma_2\hat{y}_{it}^2 + \varepsilon_{it}$$

onde $\hat{y}_{it} = \mathbf{x}_{it}\hat{\boldsymbol{\beta}}^{POLS}$. Definindo $\mathbf{h}_{it} = (\hat{y}'_{it}, \hat{y}_{it}^2)$, podemos reescrever a equação acima como

$$\hat{u}_{it}^2 = \gamma_0 + \mathbf{h}_{it}\boldsymbol{\gamma} + \varepsilon_{it}$$

Então, testamos

$$H_0 : \boldsymbol{\gamma} = \mathbf{0} \quad (\gamma_1 = 0 \text{ e } \gamma_2 = 0)$$

$$H_1 : \boldsymbol{\gamma} \neq \mathbf{0}$$

via teste de Wald.

5.3 Teste de Wald

Se é verdade que

$$\sqrt{N}(\hat{\beta} - \beta) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \hat{\mathbf{V}}).$$

Seja \mathbf{R} uma matriz $Q \times K$ com $Q \leq K$ e $\text{posto}(\mathbf{R}) = Q$ (posto pleno), então

$$\sqrt{N}\mathbf{R}(\hat{\beta} - \beta) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{R}\hat{\mathbf{V}}\mathbf{R}').$$

e

$$\left[\sqrt{N}\mathbf{R}(\hat{\beta} - \beta) \right]' (\mathbf{R}\hat{\mathbf{V}}\mathbf{R}')^{-1} \left[\sqrt{N}\mathbf{R}(\hat{\beta} - \beta) \right] \stackrel{a}{\sim} \chi_Q^2$$

O resultado acima vale para $\hat{\mathbf{V}}$ no lugar de \mathbf{V} , desde que $\hat{\mathbf{V}} \xrightarrow{p} \mathbf{V}$. Ou seja, vale para estimadores **consistentes** de \mathbf{V} .

Teste de Wald

$$H_0 : \mathbf{R}\beta = \mathbf{r}$$

$$H_1 : \mathbf{R}\beta \neq \mathbf{r}$$

A estatística do teste acima é:

$$N \left[\mathbf{R}\hat{\beta} - \mathbf{r} \right]' \left(\mathbf{R}\hat{\mathbf{V}}\mathbf{R}' \right)^{-1} \left[\mathbf{R}\hat{\beta} - \mathbf{r} \right] \stackrel{a}{\sim} \chi_Q^2$$

Remarks

1. $\hat{\mathbf{V}}$ pode ser a matriz robusta.
2. Uma aproximação, via distribuição F é dado por:

$$\frac{\text{Est. Teste}}{Q} \stackrel{a}{\sim} F_{Q, N-K}$$

$$\text{com } \text{Avar}(\hat{\beta}) = \frac{N}{N-K} \hat{\mathbf{V}}.$$

6 Modelo de Efeitos Não Observados (UEM)

Wooldridge (2010, C.10 – Basic Linear Unobserved Effects Panel Data Models, p.247–291)

Wooldridge (2010, Sec.10.1 – Motivation: The Omitted Variables Problem, p.247)

Wooldridge (2010, Sec.10.2 – Assumptions about the Unobserved Effects and Explanatory Variables, p.251)

Wooldridge (2010, Sec.10.3 – Estimating UEM by POLS, p.256)

6.1 Modelo UEM

O modelo básico de efeitos não observados (UEM) pode ser escrito para uma amostra *cross-section* aleatória i como:

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + c_i + u_{it}, \quad t = 1, \dots, T. \quad (6.1)$$

onde c_i é o efeito não observado (componente não observado, variável latente, heterogeneidade não observada, efeito individual, heterogeneidade individual). Estamos supondo c_i **não** observável.

Definindo os erros compostos $v_{it} = c_i + u_{it}$, temos:

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + v_{it} \quad (6.2)$$

Ou, em forma de vetor:

$$\mathbf{y}_i = \mathbf{X}_i\boldsymbol{\beta} + \mathbf{v}_i \quad (6.3)$$

6.2 Estimação e Consistência

Wooldridge (2010, Sec.10.3 – Estimating UEM by POLS, p.256).

Se usarmos o estimador POLS na equação (6.1), o estimador será consistente se:

$$E(\mathbf{x}'_{it}v_{it}) = \mathbf{0}, \quad t = 1, \dots, T.$$

Ou seja, precisamos que:

$$E(\mathbf{x}'_{it}u_{it}) = \mathbf{0}, \quad t = 1, \dots, T.$$

$$E(\mathbf{x}'_{it}c_i) = \mathbf{0}, \quad t = 1, \dots, T.$$

Caso 1: $E(\mathbf{x}'_{it}c_i) = \mathbf{0}$.

POLS é consistente, mas não é eficiente.

Efeitos Aleatórios é consistente e eficiente.

EA é o **FGLS** do modelo.

Caso 2: $E(\mathbf{x}'_{it}c_i) \neq \mathbf{0}$.

Se POLS é **inconsistente**.

Nesse caso, usaremos o Modelo de **Efeitos Fixos** ou **Primeira Diferença**.

EF e PD é o POLS nos modelos transformados.

Obs: Modelos com variáveis dependentes defasadas em \mathbf{x}_{it} *devem* violar a hipótese $E(\mathbf{x}'_{it}u_{it}) = \mathbf{0}$ uma vez que $y_{i,t-1}$ e c_i devem ser correlacionados. Considerando $y_{i,t-1}$ como regressor:

$$\left. \begin{aligned} y_{it} &= \alpha y_{i,t-1} + \mathbf{x}_{it}\boldsymbol{\beta} + v_{it} \\ y_{i,t-1} &= \alpha y_{i,t-2} + \mathbf{x}_{i,t-1}\boldsymbol{\beta} + v_{i,t-1} \end{aligned} \right\} \text{Cov}(y_{i,t-1}, v_{it}) \neq 0.$$

Mesmo se $E(\mathbf{x}'_{it}u_{it}) = \mathbf{0}$ é verdadeiro, os erros compostos serão serialmente correlacionados devido a presença de c_i em cada período de tempo. Portanto, a inferência do POLS requer um estimador robusto de matriz de covariância e estatísticas robustas de teste.

7 Modelo de Efeitos Fixos (EF), (Fixed Effects FE)

Wooldridge (2010, Sec.10.5 – Fixed Effects Methods, p.265)

7.1 Modelo

O modelo linear de **efeitos individuais não observados (UEM)**:

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + c_i + u_{it}, \quad i = 1, \dots, N; \quad t = 1, \dots, T. \quad (7.1)$$

Estamos supondo c_i **não** observável. Definindo $v_{it} = c_i + u_{it}$.

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + v_{it}, \quad i = 1, \dots, N; \quad t = 1, \dots, T. \quad (7.2)$$

No modelo FE permitimos $\text{Cov}(\mathbf{x}_{it}, c_i) \neq 0$.

7.2 Transformação *Within*

Tirando a média do modelo ao longo de $t = 1, \dots, T$:

$$\bar{y}_i = \bar{\mathbf{x}}_i\boldsymbol{\beta} + \bar{c}_i + \bar{u}_i, \quad i = 1, \dots, N. \quad (7.3)$$

onde:

$$\bar{y}_i = T^{-1} \sum_{t=1}^T y_{it}; \quad \bar{\mathbf{x}}_i = T^{-1} \sum_{t=1}^T \mathbf{x}_{it}; \quad \bar{c}_i = T^{-1} \sum_{t=1}^T c_i = c_i; \quad \bar{u}_i = T^{-1} \sum_{t=1}^T u_{it}.$$

Então, subtraindo (7.3) de (7.1):

$$y_{it} - \bar{y}_i = (\mathbf{x}_{it} - \bar{\mathbf{x}}_i)\boldsymbol{\beta} + \underbrace{c_i - \bar{c}_i}_{=0} + u_{it} - \bar{u}_i, \quad i = 1, \dots, N; \quad t = 1, \dots, T.$$

Finalmente, obtemos:

$$\ddot{y}_{it} = \ddot{\mathbf{x}}_{it}\boldsymbol{\beta} + \ddot{u}_{it}, \quad i = 1, \dots, N; \quad t = 1, \dots, T. \quad (7.4)$$

Onde $\ddot{y}_{it} \equiv y_{it} - \bar{y}_i$, $\ddot{\mathbf{x}}_{it} \equiv \mathbf{x}_{it} - \bar{\mathbf{x}}_i$ e $\ddot{u}_{it} \equiv u_{it} - \bar{u}_i$. E eliminamos variáveis que não variam ao longo do tempo.

7.3 Notação Vetorial e Matriz Centralizadora (*Centering Matrix*) \mathbf{M}^0

Utilizando notação vetorial para o modelo linear de **efeitos individuais não observados (UEM)**:

$$\mathbf{y}_i = \mathbf{X}_i\boldsymbol{\beta} + c_i\mathbf{1} + \mathbf{u}_i, \quad i = 1, \dots, N. \quad (7.5)$$

$$\mathbf{y}_i = \mathbf{X}_i\boldsymbol{\beta} + \mathbf{v}_{it}, \quad i = 1, \dots, N. \quad (7.6)$$

Agora, definimos a matriz \mathbf{M}^0 (Wooldridge (2010, p. 268) usa a notação \mathbf{Q}_T para essa matriz) como:

$$\mathbf{M}^0 = \mathbf{I}_T - \mathbf{1}_T(\mathbf{1}'_T\mathbf{1}_T)^{-1}\mathbf{1}'_T = \mathbf{I}_T - T^{-1}\mathbf{1}_T\mathbf{1}'_T$$

A matriz \mathbf{M}^0 é idempotente ($\mathbf{M}^0\mathbf{M}^0 = \mathbf{M}^0$) e simétrica ($\mathbf{M}^{0'} = \mathbf{M}^0$).

Podemos transformar o modelo (7.5) ao premultiplicarmos todo o modelo por \mathbf{M}^0 :

$$\begin{aligned}\mathbf{M}^0 \mathbf{y}_i &= (\mathbf{I}_T - T^{-1} \mathbf{1}_T \mathbf{1}_T') \mathbf{y}_i = \mathbf{y}_i - \mathbf{1}_T \bar{y}_i = \ddot{\mathbf{y}}_i \\ \mathbf{M}^0 \mathbf{X}_i &= \mathbf{X}_i - T^{-1} \mathbf{1}_T \mathbf{1}_T' \bar{\mathbf{X}}_i = \mathbf{X}_i - \mathbf{1}_T \bar{\mathbf{x}}_i = \ddot{\mathbf{X}}_i \\ \mathbf{M}^0 \mathbf{u}_i &= (\mathbf{I}_T - T^{-1} \mathbf{1}_T \mathbf{1}_T') \mathbf{u}_i = \mathbf{u}_i - \mathbf{1}_T \bar{u}_i = \ddot{\mathbf{u}}_i \\ \mathbf{M}^0 (c_i \mathbf{1}_T) &= (\mathbf{I}_T - T^{-1} \mathbf{1}_T \mathbf{1}_T') c_i \mathbf{1}_T = c_i (\mathbf{I}_T - T^{-1} \mathbf{1}_T \mathbf{1}_T') \mathbf{1}_T = c_i (\mathbf{1}_T - \mathbf{1}_T) = \mathbf{0}_T\end{aligned}$$

onde $\bar{\mathbf{x}}_i$ é o vetor $1 \times K$ com a média dos K regressores.

$$\begin{aligned}\mathbf{M}^0 \mathbf{y}_i &= \mathbf{M}^0 \mathbf{X}_i \boldsymbol{\beta} + \mathbf{M}^0 (c_i \mathbf{1}_T) + \mathbf{M}^0 \mathbf{u}_i, \quad i = 1, \dots, N. \\ \ddot{\mathbf{y}}_i &= \ddot{\mathbf{X}}_i \boldsymbol{\beta} + \ddot{\mathbf{u}}_i, \quad i = 1, \dots, N.\end{aligned}\tag{7.7}$$

Exemplo: (Wooldridge, 2010, p.266) Considere o modelo:

$$y_{it} = \beta_0 + \beta_2 d2_t + \dots + \beta_T dT_t + \mathbf{z}_i \boldsymbol{\delta} + d2_t \mathbf{z}_i \boldsymbol{\delta}_2 + \dots + dT_t \mathbf{z}_i \boldsymbol{\delta}_T + \mathbf{x}_{it} \boldsymbol{\alpha} + v_{it}$$

Após a transformação:

$$\ddot{y}_{it} = \beta_2 \ddot{d}2_t + \dots + \beta_T \ddot{d}T_t + \ddot{d}2_t \mathbf{z}_i \boldsymbol{\delta}_2 + \dots + dT_t \mathbf{z}_i \boldsymbol{\delta}_T + \ddot{\mathbf{x}}_{it} \boldsymbol{\alpha} + \ddot{u}_{it}$$

Então, não podemos estimar o coeficiente da variável sexo do indivíduo, por exemplo. Mas podemos estimar se houve mudança desse efeito ao longo do tempo, em relação a categoria de referência.

7.4 Hipóteses

FE.1: Exogeneidade Estrita: $E(u_{it} | \mathbf{x}_{i1}, \dots, \mathbf{x}_{iT}, c_i) = 0$, para $t = 1, \dots, T$ e $i = 1, \dots, N$.

FE.2: Posto pleno de $E(\ddot{\mathbf{X}}_i' \ddot{\mathbf{X}}_i)$ (para inverter a matriz). $\text{posto}[E(\ddot{\mathbf{X}}_i' \ddot{\mathbf{X}}_i)] = K$.

FE.3: Homoscedasticidade: $E(\mathbf{u}_i \mathbf{u}_i' | \mathbf{X}_i, c_i) = \sigma_u^2 \mathbf{I}_T$.

7.5 Estimação POLS

Usando a equação (7.7), temos:

$$\begin{aligned}\ddot{\mathbf{X}}_i' \ddot{\mathbf{y}}_i &= \ddot{\mathbf{X}}_i' \ddot{\mathbf{X}}_i \boldsymbol{\beta} + \ddot{\mathbf{X}}_i' \ddot{\mathbf{u}}_i, \quad i = 1, \dots, N. \\ E(\ddot{\mathbf{X}}_i' \ddot{\mathbf{X}}_i) \boldsymbol{\beta} &= E(\ddot{\mathbf{X}}_i' \ddot{\mathbf{y}}_i) - E(\ddot{\mathbf{X}}_i' \ddot{\mathbf{u}}_i)\end{aligned}$$

Note que para $E(\ddot{\mathbf{X}}_i' \ddot{\mathbf{u}}_i) = \mathbf{0}$, é necessário não haver correlação entre todos os erros u_{it} para cada $t = 1, \dots, T$ e todos os regressores \mathbf{x}_{it} para cada $t = 1, \dots, T$. A hipótese **FE.1** implica a condição acima. Assim,

$$E(\ddot{\mathbf{X}}_i' \ddot{\mathbf{X}}_i) \boldsymbol{\beta} = E(\ddot{\mathbf{X}}_i' \ddot{\mathbf{y}}_i)$$

E utilizando **FE.2**:

$$\boxed{\boldsymbol{\beta} = \left[E(\ddot{\mathbf{X}}_i' \ddot{\mathbf{X}}_i) \right]^{-1} E(\ddot{\mathbf{X}}_i' \ddot{\mathbf{y}}_i)}\tag{7.8}$$

Utilizando o princípio da analogia e utilizando estimadores amostrais:

$$\boxed{\hat{\boldsymbol{\beta}}^{FE} = \left[N^{-1} \sum_{i=1}^N \ddot{\mathbf{X}}_i' \ddot{\mathbf{X}}_i \right]^{-1} \left[N^{-1} \sum_{i=1}^N \ddot{\mathbf{X}}_i' \ddot{\mathbf{y}}_i \right]}\tag{7.9}$$

7.6 Consistência

Usando a equação (7.7) em (7.9), temos:

$$\hat{\beta}^{FE} = \beta + \left[N^{-1} \sum_{i=1}^N \ddot{\mathbf{X}}_i' \ddot{\mathbf{X}}_i \right]^{-1} \left[N^{-1} \sum_{i=1}^N \ddot{\mathbf{X}}_i' \ddot{\mathbf{u}}_i \right]$$

Então, como

$$\left[N^{-1} \sum_{i=1}^N \ddot{\mathbf{X}}_i' \ddot{\mathbf{X}}_i \right]^{-1} \xrightarrow{p} \mathbf{A}^{-1} \quad \text{e} \quad \left[N^{-1} \sum_{i=1}^N \ddot{\mathbf{X}}_i' \ddot{\mathbf{u}}_i \right] \xrightarrow{p} \mathbf{0}$$

Então, $\hat{\beta}^{FE} \xrightarrow{p} \beta$, e temos um estimador consistente para β^{FE} .

7.7 Formato Totalmente Matricial

Sabendo que $\ddot{\mathbf{X}} = (\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X}$ e $\ddot{\mathbf{u}} = (\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{u}$, definimos:

$$\begin{aligned} E(\beta^{FE}) &= \beta + E \left\{ [\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X}]^{-1} [\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{u}] \right\} \\ E(\beta^{FE}) &= \beta + E \left\{ [\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X}]^{-1} [\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{u}] \right\} \end{aligned}$$

7.8 Variância

Usamos a variância do estimador para inferência. Usando **FE.1** e **FE.2**, apenas:

$$\text{Var}(\beta^{FE}) = E \left[(\ddot{\mathbf{X}}' \ddot{\mathbf{X}})^{-1} (\ddot{\mathbf{X}}' \ddot{\mathbf{u}}) (\ddot{\mathbf{u}}' \ddot{\mathbf{X}}) (\ddot{\mathbf{X}}' \ddot{\mathbf{X}})^{-1} \right]$$

Pão:

$$\begin{aligned} E \left[(\ddot{\mathbf{X}}' \ddot{\mathbf{X}})^{-1} \right] &= E \left\{ [\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X}]^{-1} \right\} \\ &= E \left\{ [\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X}]^{-1} \right\} \end{aligned}$$

Recheio:

$$\begin{aligned} E \left[(\ddot{\mathbf{X}}' \ddot{\mathbf{u}}) (\ddot{\mathbf{u}}' \ddot{\mathbf{X}}) \right] &= E \left[\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{u} \mathbf{u}'(\mathbf{I}_N \otimes \mathbf{M}^0)(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X} \right] \\ &= E \left[\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{u} \mathbf{u}'(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X} \right] \end{aligned}$$

$$\text{Var}(\beta^{FE}) = \text{Pão Recheio Pão}$$

$$\text{Var}(\beta^{FE}) = E \left\{ [\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X}]^{-1} \right\} E \left[\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{u} \mathbf{u}'(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X} \right] E \left\{ [\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X}]^{-1} \right\}$$

7.9 Variância sob Homocedasticidade

Usando **FE.3**, temos

Recheio':

$$E \left[\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0) \right] \sigma_u^2 \mathbf{I}_{NT} E \left[(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X} \right] = \sigma_u^2 E \left[\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X} \right]$$

$(\mathbf{I}_N \otimes \mathbf{M}^0)$ é uma matrix de dimensão $NT \times NT$, visto que \mathbf{I}_N é $N \times N$ e \mathbf{M}^0 é $T \times T$.

$\text{Var}(\boldsymbol{\beta}^{FE}) = \text{Pão Recheio' Pão}$

$$\begin{aligned} &= \text{E} \left\{ [\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X}]^{-1} \right\} \sigma_u^2 \text{E} [\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X}] \text{E} \left\{ [\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X}]^{-1} \right\} \\ &= \text{E} \left\{ [\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X}]^{-1} \right\} \sigma_u^2 \mathbf{I}_{NT} \end{aligned}$$

$$\boxed{\text{Var}(\boldsymbol{\beta}^{FE}) = \sigma_u^2 \cdot \text{E} [\mathbf{X}'(\mathbf{I}_N \otimes \mathbf{M}^0)\mathbf{X}]}$$

O modelo contém explicitamente um componente não observado que não varia no tempo c_i . Abordamos esse componente como parte do erro, não como parâmetro a não observado. No caso da análise de **Efeitos Fixos (EF, FE)**, permitimos que esse componente c_i seja correlacionado com \mathbf{x}_{it} . Assim, se decidíssemos estimar o modelo (7.1) por POLS, ignorando c_i , teríamos problemas de inconsistência devido a **endogeneidade**.

As T equações do modelo (7.1) podem ser reescritas como:

$$\mathbf{y}_i = \mathbf{X}_i \boldsymbol{\beta} + c_i \mathbf{1}_T + \mathbf{u}_i,$$

com $\mathbf{v}_i = c_i \mathbf{1}_T + \mathbf{u}_i$ sendo os erros compostos.

8 First Difference (FD, PD)

Wooldridge (2010, Sec.10.6 – First Difference Methods, p.279)

8.1 Modelo

O modelo linear de **efeitos não observados**:

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + c_i + u_{it}, \quad (8.1)$$

para $t = 1, \dots, T$ e $i = 1, \dots, N$.

O modelo contém explicitamente um componente não observado, c_i , que não varia no tempo. Tratamos o componente não observado como parte do erro, não como parâmetro a ser estimado. Aqui permitimos que c_i seja correlacionado com \mathbf{x}_{it} . Deste modo, **não** podemos ignorar a sua presença e estimar (8.1) por POLS, visto que isso resultaria num estimador inconsistente devido a **endogeneidade**.

Assim, transformamos o modelo para eliminar c_i e conseguirmos fazer uma estimação consistente de $\boldsymbol{\beta}$. A transformação a ser feita é a primeira diferença. Para tanto, seguimos os seguintes passos:

- Reescrevemos (8.1) defasado:

$$y_{it-1} = \mathbf{x}_{it-1}\boldsymbol{\beta} + c_i + u_{it-1} \quad (8.2)$$

- Tiramos a diferença entre (8.2) e (8.1):

$$\begin{aligned} y_{it} - y_{it-1} &= (\mathbf{x}_{it} - \mathbf{x}_{it-1})\boldsymbol{\beta} + c_i - c_i + u_{it} - u_{it-1} \\ \Delta y_{it} &= \Delta \mathbf{x}_{it}\boldsymbol{\beta} + \Delta u_{it}. \end{aligned} \quad (8.3)$$

para $t = 2, \dots, T$ e $i = 1, \dots, N$.

Reescrevendo (8.3) no formato matricial empilhando T :

$$\Delta \mathbf{y}_i = \Delta \mathbf{X}_i \boldsymbol{\beta} + \mathbf{e}_i \quad (8.4)$$

com $\boxed{e_{it} = \Delta u_{it}}$.

- $\Delta \mathbf{y}_i$ vetor $(T-1) \times 1$
- $\Delta \mathbf{X}_i$ matriz $(T-1) \times K$
- $\boldsymbol{\beta}$ vetor $K \times 1$
- \mathbf{e}_i vetor $(T-1) \times 1$

8.2 Estimação POLS

O estimador $\hat{\boldsymbol{\beta}}^{FD}$ é o POLS da regressão no modelo (8.4), assim:

$$\boxed{\boldsymbol{\beta}^{FD} = \left[\sum_{i=1}^N \Delta \mathbf{X}_i' \Delta \mathbf{X}_i \right]^{-1} \left[\sum_{i=1}^N \Delta \mathbf{X}_i' \Delta \mathbf{y}_i \right]} \quad (8.5)$$

8.3 Hipóteses

As Hipóteses que usamos para $\hat{\beta}^{FD}$ são:

FD.1: Exogeneidade Estrita: $E(u_{it} | \mathbf{x}_{i1}, \dots, \mathbf{x}_{iT}, c_i) = 0$, para $t = 1, \dots, T$ e $i = 1, \dots, N$.

FD.2: Posto completo de $E(\Delta \mathbf{X}'_i \Delta \mathbf{X}_i)$ (para inverter a matriz). $\text{posto}[E(\Delta \mathbf{X}'_i \Delta \mathbf{X}_i)] = K$.

FD.3: Homoscedasticidade: $E(\mathbf{e}_i \mathbf{e}'_i | \mathbf{X}_i, c_i) = \sigma_e^2 \mathbf{I}_{T-1}$.

8.4 Valor Esperado

Usando apenas **FD.1** e **FD.2**:

$$E(\beta^{FD}) = \beta + E \left[\left(\sum_{i=1}^N \Delta \mathbf{X}'_i \Delta \mathbf{X}_i \right)^{-1} \left(\sum_{i=1}^N \Delta \mathbf{X}'_i \mathbf{e}_i \right) \right]$$

$$E(\beta^{FD}) = \beta + E \left[(\Delta \mathbf{X}' \Delta \mathbf{X})^{-1} (\Delta \mathbf{X}' \mathbf{e}) \right]$$

8.5 Variância

Usando apenas **FD.1** e **FD.2**:

$$\text{Var}(\beta^{FD}) = E \left[(\Delta \mathbf{X}' \Delta \mathbf{X})^{-1} (\Delta \mathbf{X}' \mathbf{e} \mathbf{e}' \Delta \mathbf{X}) (\Delta \mathbf{X}' \Delta \mathbf{X})^{-1} \right]$$

8.6 Variância sob Homocedasticidade

Usando **FD.3**, temos

$$\text{Var}(\beta^{FD}) = \sigma_e^2 E \left[(\Delta \mathbf{X}' \Delta \mathbf{X})^{-1} (\Delta \mathbf{X}' \Delta \mathbf{X}) (\Delta \mathbf{X}' \Delta \mathbf{X})^{-1} \right]$$

$$\text{Var}(\beta^{FD}) = \sigma_e^2 E \left[(\Delta \mathbf{X}' \Delta \mathbf{X})^{-1} \right]$$

com

$$\sigma_e^2 = [N(T-1) - K]^{-1} \left[\sum_{i=1}^N \sum_{t=1}^T \hat{e}_{it}^2 \right],$$

que é a média de todos \hat{e}_{it}^2 contando K regressores.

9 System GLS (SGLS)

Wooldridge (2010, Sec.7.4 – Consistency and Asymptotic Normality of Generalized Least Squares, p.153)

9.1 Modelo Linear

9.2 Hipóteses

Para implementarmos o estimador de **GLS** precisamos das seguintes hipótese:

1. $E(\mathbf{X}_i \otimes \mathbf{u}_i) = 0$.

Para SGLS ser consistente, precisamos que \mathbf{u}_i não seja correlacionada com nenhum elemento de \mathbf{X}_i .

2. Ω é positiva definida (para ter inversa). $E(\mathbf{X}_i' \Omega^{-1} \mathbf{X}_i)$ é **não** singular (para ter inversa).

Onde, Ω é a seguinte matriz **simétrica**, positiva-definida:

$$\Omega = E(\mathbf{u}_i \mathbf{u}_i').$$

9.3 Estimação

Agora, transformamos o sistema de equações ao realizarmos a pré-multiplicação do sistema por $\Omega^{-1/2}$:

$$\Omega^{-1/2} \mathbf{y}_i = \Omega^{-1/2} \mathbf{X}_i \boldsymbol{\beta} + \Omega^{-1/2} \mathbf{u}_i$$

$$\mathbf{y}_i^* = \mathbf{X}_i^* \boldsymbol{\beta} + \mathbf{u}_i^*$$

Estimando a equação acima por **SOLS**:

$$\begin{aligned} \beta^{SOLS} &= \left(\sum_{i=1} \mathbf{X}_i^{*'} \mathbf{X}_i^* \right)^{-1} \left(\sum_{i=1} \mathbf{X}_i^{*'} \mathbf{y}_i^* \right) \\ &= \left(\sum_{i=1} \mathbf{X}_i' \Omega^{-1/2} \Omega^{-1/2} \mathbf{X}_i \right)^{-1} \left(\sum_{i=1} \mathbf{X}_i' \Omega^{-1/2} \Omega^{-1/2} \mathbf{y}_i \right) \\ &= \left(\sum_{i=1} \mathbf{X}_i' \Omega^{-1} \mathbf{X}_i \right)^{-1} \left(\sum_{i=1} \mathbf{X}_i' \Omega^{-1} \mathbf{y}_i \right) \end{aligned}$$

10 GLS Factível

Wooldridge (2010, Sec.7.5 – Feasible GLS, p.153)

10.1 FSGLS: SGLS Factível

Para obtermos β^{SGLS} precisamos conhecer Ω , o que não ocorre na prática. Então, precisamos estimar Ω com um estimador consistente. Para tanto usamos um procedimento de dois passos:

1. Estimar $\mathbf{y}_i = \mathbf{X}_i\beta + \mathbf{u}_i$ via **SOLS** e guardar o resíduo estimado $\hat{\mathbf{u}}_i$.
2. Estimar Ω com o seguinte estimador $\hat{\Omega}$:

$$\hat{\Omega} = N^{-1} \sum_{i=1}^N \mathbf{u}_i \mathbf{u}_i'$$

Com a estimativa $\hat{\Omega}$ feita, podemos obter β^{FSGLS} pela fórmula do β^{SGLS} :

$$\beta^{FGLS} = \left[\sum_i \mathbf{X}_i' \hat{\Omega}^{-1} \mathbf{X}_i \right]^{-1} \left[\sum_i \mathbf{X}_i' \hat{\Omega}^{-1} \mathbf{y}_i \right]$$

Empilhando as N observações:

$$\beta^{FGLS} = \left[\mathbf{X} (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{X}' \right]^{-1} \left[\mathbf{X}' (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{y} \right]$$

Reescrevendo a equação acima:

$$\begin{aligned} \beta^{FGLS} &= \left[\mathbf{X} (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{X}' \right]^{-1} \left[\mathbf{X}' (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) (\mathbf{X}\beta + \mathbf{u}) \right] \\ &= \left[\mathbf{X} (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{X}' \right]^{-1} \left\{ \left[\mathbf{X}' (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{X} \right] \beta + \left[\mathbf{X}' (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{u} \right] \right\} \\ &= \beta + \left[\mathbf{X} (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{X}' \right]^{-1} \left[\mathbf{X}' (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{u} \right] \end{aligned}$$

10.2 Valor Esperado

$$E(\beta^{FGLS}) = \beta + \left[\mathbf{X} (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{X}' \right]^{-1} \left[\mathbf{X}' (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{u} \right]$$

Concluimos que, se $\hat{\Omega} \xrightarrow{p} \Omega$, então, $\beta^{FSGLS} \xrightarrow{p} \beta$,

10.3 Variância

$$\begin{aligned} \text{Var}(\beta^{FGLS}) &= \left[\mathbf{X} (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{X}' \right]^{-1} \left[\mathbf{X}' (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{u} \right] \left\{ \left[\mathbf{X} (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{X}' \right]^{-1} \left[\mathbf{X}' (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{u} \right] \right\}' \\ &= \left[\mathbf{X} (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{X}' \right]^{-1} \left[\mathbf{X}' (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{u} \mathbf{u}' (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{X} \right] \left[\mathbf{X} (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{X}' \right]^{-1} \end{aligned}$$

Tirando o valor Esperado e supondo que:

$$E(\mathbf{X}_i \Omega^{-1} \mathbf{u}_i \mathbf{u}_i' \mathbf{X}_i) = E(\mathbf{X}_i \Omega^{-1})$$

temos:

$$E \left[\mathbf{X}' (\mathbf{I}_N \otimes \hat{\Omega}^{-1}) \mathbf{u} \mathbf{u}' (\mathbf{I}_N \otimes \hat{\Omega}^{-1})' \mathbf{X} \right] = E(\mathbf{X}' \Omega^{-1} \mathbf{X})$$

e temos:

$$\text{Var}(\beta^{FSGLS}) = [E(\mathbf{X}' \Omega^{-1} \mathbf{X})]^{-1}.$$

11 Random Effects (RE, EA)

Wooldridge (2010, Sec.10.4 – Random Effects Methods, p.257)

11.1 Modelo

O modelo linear de **efeitos não observados**:

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + c_i + u_{it}, \quad (11.1)$$

onde $t = 1, \dots, T$ e $i = 1, \dots, N$.

O modelo contém explicitamente um componente não observado que não varia no tempo c_i . Abordamos esse componente como parte do erro, não como parâmetro a ser estimado. Para a análise de **Efeitos Aleatórios, (EA) ou (RE)**, supomos que os regressões \mathbf{x}_{it} são **não correlacionados** com c_i , mas fazemos hipóteses mais restritas que o **POLS**; pois assim exploramos a presença de **correlação serial** do erro composto por GLS e garantimos a consistência do estimador de FGLS.

Podemos reescrever (11.1) como:

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + v_{it}, \quad (11.2)$$

onde $t = 1, \dots, T$, $i = 1, \dots, N$ e $\boxed{v_{it} = c_i + u_{it}}$ é o erro composto.

Agora, vamos empilhar os t 's e reescrever (11.2) como:

$$\mathbf{y}_i = \mathbf{X}_i\boldsymbol{\beta} + \mathbf{v}_i, \quad (11.3)$$

onde $i = 1, \dots, N$ e $\boxed{\mathbf{v}_i = c_i\mathbf{1}_T + \mathbf{u}_i}$.

11.2 Hipóteses

As Hipóteses que usamos para $\hat{\boldsymbol{\beta}}^{RE}$ são:

1. Usamos o modelo correto e c_i não é endógeno.

- a) $E(u_{it} | x_{i1}, \dots, x_{iT}, c_i) = 0$, $i = 1, \dots, N$.
- b) $E(c_{it} | x_{i1}, \dots, x_{iT}) = E(c_i) = 0$, $i = 1, \dots, N$.

2. Posto completo de $E(\mathbf{X}_i'\Omega^{-1}\mathbf{X}_i)$.

Definindo a matriz $T \times T$, $\boxed{\Omega \equiv E(\mathbf{v}_i\mathbf{v}_i')}$, queremos que $E(\mathbf{X}_i\Omega^{-1}\mathbf{X}_i)$ tenha posto completo (posto = K).

A matriz Ω é simétrica $\Omega' = \Omega$ e positiva definida $\det(\Omega) > 0$. Assim podemos achar $\Omega^{1/2}$ e $\Omega^{-1/2}$ com $\Omega = \Omega^{1/2}\Omega^{1/2}$ e $\Omega^{-1} = \Omega^{-1/2}\Omega^{-1/2}$.

11.3 Estimação

Premultiplicando (11.3) por $\Omega^{-1/2}$ do dois lados, temos:

$$\begin{aligned} \Omega^{-1/2}\mathbf{y}_i &= \Omega^{-1/2}\mathbf{X}_i\boldsymbol{\beta} + \Omega^{-1/2}\mathbf{v}_i \\ \mathbf{y}_i^* &= \mathbf{X}_i^*\boldsymbol{\beta} + \mathbf{v}_i^*, \end{aligned} \quad (11.4)$$

Estimando o modelo acima por POLS:

$$\begin{aligned}
\beta^{POLS} &= \left(\sum_{i=1}^N \mathbf{X}_i^{*'} \mathbf{X}_i^* \right)^{-1} \left(\sum_{i=1}^N \mathbf{X}_i^{*'} \mathbf{y}_i^* \right) \\
&= \left(\sum_{i=1}^N \mathbf{X}_i' \Omega^{-1} \mathbf{X}_i \right)^{-1} \left(\sum_{i=1}^N \mathbf{X}_i' \Omega^{-1} \mathbf{y}_i \right) \\
&= (\mathbf{X}'(\mathbf{I}_N \otimes \Omega^{-1})\mathbf{X})^{-1} (\mathbf{X}'(\mathbf{I}_N \otimes \Omega^{-1})\mathbf{y}).
\end{aligned} \tag{11.5}$$

O problema, agora, é estimar Ω . Supondo:

- $E(u_{it}u_{it}) = \sigma_u^2$;
- $E(u_{it}u_{is}) = 0$.

Como $\Omega = E(\mathbf{v}_i \mathbf{v}_i') = E[(c_i \mathbf{1}_T + \mathbf{u}_i)(c_i \mathbf{1}_T + \mathbf{u}_i)']$, temos que:

$$E(v_{it}v_{it}) = E(c_i^2 + 2c_i u_{it} + u_{it}^2) = \sigma_c^2 + \sigma_u^2$$

$$E(v_{it}v_{is}) = E[(c_i + u_{it})(c_i + u_{is})] = E(c_i^2 + c_i u_{is} + u_{it}c_i + u_{it}u_{is}) = \sigma_c^2.$$

Assim,

$$\Omega = E(\mathbf{v}_i \mathbf{v}_i') = \sigma_u^2 \mathbf{I}_T + \sigma_c^2 \mathbf{1}_T \mathbf{1}_T'$$

onde $\sigma_u^2 \mathbf{I}_T$ é uma matriz diagonal, e $\sigma_c^2 \mathbf{1}_T \mathbf{1}_T'$ é uma matriz com todos os elementos iguais a σ_c^2 .

Agora, rodando POLS em (11.3) e guardando os resíduos, temos:

$$\hat{v}_{it}^{POLS} = \hat{y}_{it}^{POLS} - \mathbf{x}_{it} \hat{\boldsymbol{\beta}}^{POLS}$$

e conseguimos estimar σ_v^2 e σ_c^2 por estimadores amostrais:

- como $\sigma_v^2 = E(v_{it}^2)$:

$$\hat{\sigma}_v^2 = (NT - K)^{-1} \sum_{i=1}^N \sum_{t=1}^T \hat{v}_{it}^2$$

- como $\sigma_c^2 = E(v_{it}v_{is})$:

$$\hat{\sigma}_c^2 = \left[N \frac{T(T-1)}{2} - K \right]^{-1} \sum_{i=1}^N \sum_{t=1}^{T-1} \sum_{s=t+1}^T \hat{v}_{it} \hat{v}_{is}$$

- N indivíduos;
- T elementos da diagonal principal de Ω
- $\frac{T(T-1)}{2}$ elementos da matriz triangular superior dos elementos fora da diagonal.
- K regressores.

Agora que temos $\hat{\sigma}_v^2$ e $\hat{\sigma}_c^2$ podemos achar $\hat{\sigma}_u^2$ pela equação $\boxed{\hat{\sigma}_u^2 = \hat{\sigma}_v^2 - \hat{\sigma}_c^2}$. Dessa forma, achamos os T^2 elementos de $\hat{\Omega}$, e podemos escrever:

$$\hat{\Omega} = \hat{\sigma}_u^2 \mathbf{I}_T + \hat{\sigma}_c^2 \mathbf{1}_T \mathbf{1}_T'$$

Com $\hat{\Omega}$ estimado, reescrevemos (11.5) como:

$$\beta^{RE} = [\mathbf{X}'(\mathbf{I}_N \otimes \hat{\Omega}^{-1})\mathbf{X}]^{-1} [\mathbf{X}'(\mathbf{I}_N \otimes \hat{\Omega}^{-1})\mathbf{y}]. \tag{11.6}$$

11.4 Valor Esperado

$$\boxed{E(\boldsymbol{\beta}^{RE}) = \boldsymbol{\beta} + \left[\mathbf{X}'(\mathbf{I}_N \otimes \hat{\Omega}^{-1})\mathbf{X} \right]^{-1} \left[\mathbf{X}'(\mathbf{I}_N \otimes \hat{\Omega}^{-1})\mathbf{v} \right]}.$$

11.5 Variância

$$\text{Var}(\boldsymbol{\beta}^{RE}) = E \left\{ \left[\mathbf{X}'(\mathbf{I}_N \otimes \hat{\Omega}^{-1})\mathbf{X} \right]^{-1} \left[\mathbf{X}'(\mathbf{I}_N \otimes \hat{\Omega}^{-1})\mathbf{v}\mathbf{v}'(\mathbf{I}_N \otimes \hat{\Omega}^{-1})'\mathbf{X} \right] \left[\mathbf{X}'(\mathbf{I}_N \otimes \hat{\Omega}^{-1})\mathbf{X} \right] \right\},$$

como $E(\mathbf{v}_i\mathbf{v}_i') = \Omega$,

$$\boxed{\text{Var}(\boldsymbol{\beta}^{RE}) = E \left[\mathbf{X}'(\mathbf{I}_N \otimes \hat{\Omega}^{-1})\mathbf{X} \right]}.$$

12 Endogeneity and GMM

12.1 Modelo

No seguinte modelo *cross-section*:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \varepsilon_i ; \quad i = 1, \dots, N. \quad (12.1)$$

A variável explicativa x_k é dita **endógena** se ela for correlacionada com erro. Se x_k for não correlacionada com o erro, então x_k é dita **exógena**.

Endogeneidade surge, normalmente, de três maneiras diferentes:

1. Variável Omitida;
2. Simultaneidade;
3. Erro de Medida.

No modelo (12.1) vamos supor:

- x_1 é exógena.
- x_2 é endógena.

12.2 Hipóteses

Assim, precisamos encontrar um instrumento z_i para x_2 , uma vez que queremos estimar β_0 , β_1 e β_2 de maneira consistente. Para z_i ser um bom instrumento precisamos que z tenha:

1. $Cov(z, \varepsilon) = 0 \implies z$ é exógena em (12.1).
2. $Cov(z, x_2) \neq 0 \implies$ correlação com x_2 após controlar para outras variáveis.

12.3 Estimação

Indo para o problema de dados de painel, temos:

$$\mathbf{y}_i = \mathbf{X}_i \boldsymbol{\beta} + \mathbf{u}_i ; \quad i = 1, \dots, N. \quad (12.2)$$

onde \mathbf{y}_i é um vetor $T \times 1$, \mathbf{X}_i é uma matriz $T \times K$, $\boldsymbol{\beta}$ é o vetor de coeficientes $K \times 1$, \mathbf{u}_i é o vetor de erros $T \times 1$.

Se é verdade que há endogeneidade em (12.2), então:

$$E(\mathbf{X}_i' \mathbf{u}_i) \neq 0$$

Definimos Z_i como uma matriz $T \times L$ com $L \geq K$ de variáveis exógenas (incluindo o instrumento). Queremos acabar com a endogeneidade, ou seja:

$$E(Z_i' \mathbf{u}_i) = 0$$

Supondo $L = K$ (apenas substituímos a variável endógena por um instrumento).

$$\begin{aligned} E[Z_i'(\mathbf{y}_i - \mathbf{X}_i \boldsymbol{\beta})] &= 0 \\ E(Z_i' \mathbf{y}_i) - E(Z_i' \mathbf{X}_i) \boldsymbol{\beta} &= 0 \\ E(Z_i' \mathbf{y}_i) &= E(Z_i' \mathbf{X}_i) \boldsymbol{\beta} \end{aligned}$$

$$\boxed{\boldsymbol{\beta} = [E(Z_i' \mathbf{X}_i)]^{-1} [E(Z_i' \mathbf{y}_i)]}$$

Se Usarmos estimadores amostrais:

$$\hat{\beta} = \left[N^{-1} \sum_{i=1}^N Z_i' \mathbf{X}_i \right]^{-1} \left[N^{-1} \sum_{i=1}^N Z_i' \mathbf{y}_i \right]$$

$$\boxed{\hat{\beta} = (Z' \mathbf{X})^{-1} (Z' \mathbf{y})}$$

Se $L > K$, vamos considerar:

$$\text{Min}_{\beta} E(Z_i \mathbf{u}_i)^2$$

onde:

$$\begin{aligned} E(Z_i \mathbf{u}_i)^2 &= E[(Z_i \mathbf{u}_i)'(Z_i \mathbf{u}_i)] = (Z' \mathbf{y} - Z' \mathbf{X} \beta)'(Z' \mathbf{y} - Z' \mathbf{X} \beta) \\ &= \mathbf{y}' Z Z' \mathbf{y} - \mathbf{y}' Z Z' \mathbf{X} \beta - \beta' \mathbf{X}' Z Z' \mathbf{y} + \beta' \mathbf{X}' Z Z' \mathbf{X} \beta \end{aligned}$$

Derivando em relação em β e igualando a zero:

$$\begin{aligned} -2\mathbf{y}' Z Z' \mathbf{X} + 2\beta' \mathbf{X}' Z Z' \mathbf{X} &= 0 \\ \beta' \mathbf{X}' Z Z' \mathbf{X} &= \mathbf{y}' Z Z' \mathbf{X} \\ \beta' &= (\mathbf{y}' Z Z' \mathbf{X})(\mathbf{X}' Z Z' \mathbf{X})^{-1} \\ \boxed{\beta &= (\mathbf{X}' Z Z' \mathbf{X})^{-1}(\mathbf{X}' Z Z' \mathbf{y})} \end{aligned}$$

Um estimador mais eficiente pode ser encontrado fazendo:

$$\text{Min}_{\beta} E[(Z_i' \mathbf{y} - Z_i' \mathbf{X} \beta)' W (Z_i' \mathbf{y} - Z_i' \mathbf{X} \beta)].$$

Escolhendo \widehat{W} , a priori, temos:

$$\text{Min}_{\beta} \left\{ \mathbf{y}' Z \widehat{W} Z' \mathbf{y} - \mathbf{y}' Z \widehat{W} Z' \mathbf{X} \beta - \beta' \mathbf{X}' Z \widehat{W} Z' \mathbf{y} + \beta' \mathbf{X}' Z \widehat{W} Z' \mathbf{X} \beta \right\}$$

Derivando em relação em β e igualando a zero:

$$\begin{aligned} -2\mathbf{y}' Z \widehat{W} Z' \mathbf{X} + 2\beta' \mathbf{X}' Z \widehat{W} Z' \mathbf{X} &= 0 \\ \beta' \mathbf{X}' Z \widehat{W} Z' \mathbf{X} &= \mathbf{y}' Z \widehat{W} Z' \mathbf{X} \\ \beta' &= (\mathbf{y}' Z \widehat{W} Z' \mathbf{X})(\mathbf{X}' Z \widehat{W} Z' \mathbf{X})^{-1} \\ \boxed{\beta^{GMM} &= (\mathbf{X}' Z \widehat{W}' Z' \mathbf{X})^{-1}(\mathbf{X}' Z \widehat{W}' Z' \mathbf{y})} \end{aligned}$$

12.4 Valor Esperado

$$\boxed{E(\beta^{GMM}) = \beta + E[(\mathbf{X}' Z \widehat{W}' Z' \mathbf{X})^{-1}(\mathbf{X}' Z \widehat{W}' Z' \mathbf{u})]}.$$

12.5 Variância

$$\begin{aligned}\text{Var}(\beta^{GMM}) &= E \left\{ \left[(X'Z\widehat{W}'Z'X)^{-1}(X'Z\widehat{W}'Z'\mathbf{u}) \right] \left[(X'Z\widehat{W}'Z'X)^{-1}(X'Z\widehat{W}'Z'\mathbf{u}) \right]' \right\} \\ &= E \left\{ (X'Z\widehat{W}'Z'X)^{-1}X'Z\widehat{W}'Z'\mathbf{u}\mathbf{u}'Z\widehat{W}Z'X(X'Z\widehat{W}'Z'X)^{-1} \right\}.\end{aligned}$$

Definindo $\Delta = E(Z'\mathbf{u}\mathbf{u}'Z)$ com $\Delta = W^{-1}$:

$$\begin{aligned}\text{Var}(\beta^{GMM}) &= E \left\{ (X'Z\widehat{W}'Z'X)^{-1}X'Z\widehat{W}'W^{-1}\widehat{W}Z'X(X'Z\widehat{W}'Z'X)^{-1} \right\} \\ &= E \left\{ (X'Z\widehat{W}'Z'X)^{-1}(X'Z\widehat{W}'Z'X)(X'Z\widehat{W}'Z'X)^{-1} \right\}.\end{aligned}$$

$$\boxed{\text{Var}(\beta^{GMM}) = E \left[(X'Z\widehat{W}'Z'X)^{-1} \right]}.$$

Se tivéssemos definido $W = (Z'Z)^{-1}$, teríamos β^{2SLS} .

13 Exogeneidade Estrita e FDIIV

13.1 Modelo

No seguinte modelo

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + u_{it},$$

para $t = 1, \dots, T$ e $i = 1, \dots, N$.

- y_{it} escalar;
- \mathbf{x}_{it} vetor $1 \times K$;
- $\boldsymbol{\beta}$ vetor $K \times 1$;
- u_{it} escalar.

$\{x_{it}\}$ é estritamente **exógeno** se valer:

$$E(u_{it} | \mathbf{x}_{i1}, \dots, \mathbf{x}_{iT}) = 0, \quad t = 1, \dots, T$$

ou seja:

$$E(y_{it} | \mathbf{x}_{i1}, \dots, \mathbf{x}_{iT}) = \mathbf{x}_{it}\boldsymbol{\beta}, \quad t = 1, \dots, T$$

o que é equivalente a hipótese de que utilizamos o modelo linear correto.

Para o seguinte modelo:

$$y_{it} = \mathbf{z}_{it}\boldsymbol{\gamma} + \rho y_{it-1} + c_i + u_{it}, \quad t = 2, \dots, T$$

é **impossível** termos exogeneidade estrita. Isso porque, nesse modelo, de efeitos não observados temos:

$$E(y_{it} | \mathbf{z}_{i1}, \dots, \mathbf{z}_{iT}, y_{it-1}, c_i) \neq 0.$$

Isso ocorre porque, y_{it} é afetado por y_{it-1} que contribui para y_{it} com, pelo menos, ρc_i .

$$\left. \begin{aligned} y_{it} &= \mathbf{z}_{it}\boldsymbol{\gamma} + \rho y_{it-1} + c_i + u_{it} \\ y_{it-1} &= \mathbf{z}_{it-1}\boldsymbol{\gamma} + \rho y_{it-2} + c_i + u_{it-1} \end{aligned} \right\} \implies y_{it} = \mathbf{z}_{it}\boldsymbol{\gamma} + \rho(\mathbf{z}_{it-1}\boldsymbol{\gamma} + \rho y_{it-2} + c_i + u_{it-1}) + c_i + u_{it}.$$

Para eliminarmos este efeito, podemos tirar a primeira diferença do modelo:

$$y_{it} - y_{it-1} = (\mathbf{z}_{it} - \mathbf{z}_{it-1})\boldsymbol{\gamma} + \rho(y_{it-1} - y_{it-2}) + (c_i - c_i) + (u_{it} - u_{it-1})$$

$\Delta y_{it} = \Delta \mathbf{z}_{it}\boldsymbol{\gamma} + \rho \Delta y_{it-1} + \Delta u_{it}, \quad t = 3, \dots, T$

(13.1)

13.2 Estimação

Não podemos estimar o modelo (13.1) por POLS, uma vez que $Cov(\Delta y_{it-1}, \Delta u_{it}) \neq 0$. Como saída, podemos estimar por P2SLS, usando instrumentos para Δy_{it-1} (alguns instrumentos para Δy_{it-1} são $y_{it-2}, y_{it-3}, \dots, y_{i1}$).

13.2.1 P2SLS

$$y_{it} = \mathbf{x}'_{it}\boldsymbol{\beta} + u_{it}$$

- $i = 1, \dots, N$
- $t = 1, \dots, T$
- y_{it} escalar;
- \mathbf{x}_{it} vetor $K \times 1$;
- $\boldsymbol{\beta}$ vetor $K \times 1$;
- u_{it} escalar.

$$\boxed{\boldsymbol{\beta}^{P2SLS} = (X'P_ZX)^{-1}(X'P_Z\mathbf{y})}$$

com

$$\boxed{P_Z = Z'(Z'Z)^{-1}Z}$$

onde P_Z é a matriz de projeção em Z .

13.2.2 FDIIV

$$y_{it} = \mathbf{x}'_{it}\boldsymbol{\beta} + c_i + u_{it}, \quad i = 1, \dots, N, \quad t = 1, \dots, T$$

$$\Delta y_{it} = \Delta \mathbf{x}'_{it}\boldsymbol{\beta} + \Delta u_{it}, \quad i = 1, \dots, N, \quad t = 2, \dots, T$$

Vamos supor $\Delta \mathbf{x}'_{it}$ tem variável endógena (y_{it} , no caso). \mathbf{w}_{it} é um vetor $1 \times L_t$ de instrumentos, onde $L_t \geq K$. Se os instrumentos forem diferentes:

$$W_i = \text{diag}(\mathbf{w}'_{i2}, \mathbf{w}'_{i3}, \dots, \mathbf{w}'_{iT})$$

onde W_i é uma matriz $(T-1) \times L$

$$L = L_2 + L_3 + \dots + L_T$$

13.3 Hipóteses

FDIV.1: $E(\mathbf{w}_{it}\Delta u_{it})$ para $i = 1, \dots, N, t = 2, \dots, T$.

FDIV.2: $Posto[E(W'_iW_i)] = L$

FDIV.3: $Posto[E(W'_i\Delta X_i)] = K$

13.4 Estimação FDIIV

$$\boxed{\boldsymbol{\beta}^{FDIV} = (\Delta X'P_W\Delta X)^{-1}(\Delta X'P_W\Delta \mathbf{y})}$$

$$\boxed{P_W = W(W'W)^{-1}W'}$$

13.5 Valor Esperado

$$E(\boldsymbol{\beta}^{FDIV}) = \boldsymbol{\beta} + (\Delta X'P_W\Delta X)^{-1}(\Delta X'P_W\mathbf{e})$$

13.6 Variância

$$\begin{aligned}
 \text{Var}(\boldsymbol{\beta}^{FDIV}) &= \text{E} \left\{ [\text{E}(\boldsymbol{\beta}^{FDIV}) - \boldsymbol{\beta}] [\text{E}(\boldsymbol{\beta}^{FDIV}) - \boldsymbol{\beta}]' \right\} \\
 &= \text{E} \left\{ [\Delta X' P_W \Delta X]^{-1} [\Delta X' P_W \mathbf{e}] [\Delta X' P_W \mathbf{e}]' [\Delta X' P_W \Delta X]^{-1} \right\} \\
 &= \text{E} \left[(\Delta X' P_W \Delta X)^{-1} (\Delta X' P_W \mathbf{e} \mathbf{e}' P_W \Delta X) (\Delta X' P_W \Delta X)^{-1} \right]
 \end{aligned}$$

$$e_i = \Delta u_{it}.$$

14 Latent Variables, Probit and Logit

14.1 Modelo

Suponha y^* não observável (**latente**) seguindo o seguinte modelo:

$$y_i^* = \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i. \quad (14.1)$$

Defina y como:

$$y_i = \begin{cases} 1, & y_i^* \geq 0 \\ 0, & y_i^* < 0 \end{cases}$$

temos que:

$$P(y_i = 1 | \mathbf{x}) = p(\mathbf{x})$$

$$P(y_i = 0 | \mathbf{x}) = 1 - p(\mathbf{x}).$$

Além disso, pela definição de y_i , equação (14.1), temos:

$$\begin{aligned} P(y_i = 1 | \mathbf{x}) &= P(y_i^* \geq 0 | \mathbf{x}) \\ &= P(\mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i \geq 0 | \mathbf{x}) \\ &= P(\varepsilon_i \geq -\mathbf{x}_i' \boldsymbol{\beta} | \mathbf{x}). \end{aligned}$$

Agora, supondo que ε_i tem FDA, G , tal que $G' = g$ é simétrica ao redor de zero:

$$\begin{aligned} P(y_i = 1 | \mathbf{x}) &= 1 - P(\varepsilon_i < -\mathbf{x}_i' \boldsymbol{\beta} | \mathbf{x}) \\ &= 1 - G(-\mathbf{x}_i' \boldsymbol{\beta} | \mathbf{x}) \\ &= G(\mathbf{x}_i' \boldsymbol{\beta}). \end{aligned}$$

Se $G(\cdot)$ for uma distribuição:

Normal Padrão: $\hat{\boldsymbol{\beta}}$ é o estimador **probit**.

Logística: $\hat{\boldsymbol{\beta}}$ é o estimador **logit**.

Supondo $\mathbf{y}_i | \mathbf{x} \sim \text{Bernoulli}(p(\mathbf{x}))$, sua fmp é dada por:

$$f(y_i | \mathbf{x}_i; \boldsymbol{\beta}) = [G(\mathbf{x}_i' \boldsymbol{\beta})]^{y_i} [1 - G(\mathbf{x}_i' \boldsymbol{\beta})]^{1-y_i}, \quad y = 0, 1.$$

Para estimarmos $\hat{\boldsymbol{\beta}}$ por máxima verossimilhança, temos de encontrar $\boldsymbol{\beta} \in B$, onde B é o espaço paramétrico, tal que $\boldsymbol{\beta}$ maximize o valor da distribuição conjunta de \mathbf{y} , ou seja:

$$\text{Max}_{\boldsymbol{\beta} \in B} \prod_{i=1}^N f(y_i | \mathbf{x}_i; \boldsymbol{\beta}).$$

Tirando o logaritmo e dividindo tudo por N (podemos fazer isso pois são transformações monotônicas e não alteram o lugar onde $\boldsymbol{\beta}$ ótimo irá parar):

$$\text{Max}_{\boldsymbol{\beta} \in B} \left\{ N^{-1} \sum_{i=1}^N \ln [f(y_i | \mathbf{x}_i; \boldsymbol{\beta})] \right\}.$$

Podemos definir $\ell_i(\boldsymbol{\beta}) = \ln[f(y_i | \mathbf{x}_i; \boldsymbol{\beta})]$ como sendo a verossimilhança condicional da observação i :

$$\max_{\beta \in B} \left\{ N^{-1} \sum_{i=1}^N \ell_i(\beta) \right\}.$$

Dessa forma, podemos ver que o problema acima é a analogia amostral de:

$$\max_{\beta \in B} E[\ell_i(\beta)].$$

Definindo o *vector score* da observação i :

$$s_i(\beta) = [\nabla_{\beta} \ell_i(\beta)]' = \left[\frac{\partial \ell_i(\beta)}{\partial \beta_1}, \dots, \frac{\partial \ell_i(\beta)}{\partial \beta_K} \right]$$

Definindo a **Matriz Hessiana** da observação i :

$$H_i(\beta) = \nabla_{\beta} s_i(\beta) = \nabla_{\beta}^2 \ell_i(\beta)$$

Tendo essas definições, o **Teorema do Valor Médio** (TVM) nos diz que no intervalo $[a, b]$, existe um número, c , tal que:

$$f'(c) = \frac{f(b) - f(a)}{b - a}.$$

FAZER DESENHO

Trocando $f(\cdot)$ por $s_i(\cdot)$, a por β_0 , b por $\hat{\beta}$ e c por $\bar{\beta}$, temos:

$$H_i(\bar{\beta}) = \frac{s_i(\hat{\beta}) - s_i(\beta_0)}{\hat{\beta} - \beta_0},$$

tirando médias dos dois lados:

$$N^{-1} \sum_{i=1}^N H_i(\bar{\beta}) = \frac{1}{\hat{\beta} - \beta_0} N^{-1} \sum_{i=1}^N [s_i(\hat{\beta}) - s_i(\beta_0)]$$

Supondo que $\hat{\beta}$ maximiza $\ell(\beta | \mathbf{y}, \mathbf{x})$, temos que: $N^{-1} \sum_{i=1}^N s_i(\hat{\beta}) = 0$. E podemos reescrever a equação anterior como:

$$\begin{aligned} \hat{\beta} - \beta_0 &= (-1) \left[N^{-1} \sum_{i=1}^N H_i(\bar{\beta}) \right]^{-1} N^{-1} \sum_{i=1}^N s_i(\beta_0) \\ \sqrt{N}(\hat{\beta} - \beta_0) &= \left[-N^{-1} \sum_{i=1}^N H_i(\bar{\beta}) \right]^{-1} \sqrt{N} \cdot N^{-1} \sum_{i=1}^N s_i(\beta_0) \\ \boxed{\sqrt{N}(\hat{\beta} - \beta_0) &= \left[-N^{-1} \sum_{i=1}^N H_i(\bar{\beta}) \right]^{-1} N^{-1/2} \sum_{i=1}^N s_i(\beta_0).} \end{aligned}$$

Onde

$$\left[-N^{-1} \sum_{i=1}^N H_i(\hat{\beta}) \right]^{-1} \xrightarrow{p} A_0^{-1}, \quad N^{-1/2} \sum_{i=1}^N s_i(\beta_0) \xrightarrow{d} N(0, B_0).$$

Assim, temos que:

$$\boxed{\sqrt{N}(\hat{\beta} - \beta_0) \rightarrow N(0, A_0^{-1} B_0 A_0^{-1})}.$$

A forma mais simples de achar $\text{Var}(\hat{\beta})$ é:

$$\boxed{\text{Var}(\hat{\beta}) = -E[H_i(\hat{\beta})]^{-1}}.$$

15 ATT, ATE, Propensity Score

15.1 Modelo

- $y_1 \rightarrow$ variável de interesse com tratamento
- $y_0 \rightarrow$ variável de interesse sem tratamento

$$w = \begin{cases} 1 & \text{se tratam} \\ 0 & \text{se não tratam} \end{cases}$$

Idealmente, para isolarmos completamente o efeito de $w = 1$, gostaríamos de poder calcular:

$$N^{-1} \sum_{i=1}^N (y_{i1} - y_{i0}).$$

Ou seja, o efeito que o tratamento causa sobre um indivíduo com todo o resto permanecendo constante. Em outras palavras, queríamos que houvesse dois mundos paralelos observáveis onde seria possível observar o que acontece com y_i com e sem tratamento. Infelizmente, para cada indivíduo i , observamos apenas y_{i1} ou y_{i0} , nunca ambos.

Antes de continuarmos, faremos as seguintes definições:

ATE: $E(y_1 - y_0)$

ATT: $E(y_1 - y_0 | w = 1)$ (ATE no tratado).

15.2 ATE e ATT condicional a variáveis dependentes

$$ATE(\mathbf{x}) = E(y_1 - y_0 | \mathbf{x})$$

$$ATT(\mathbf{x}) = E(y_1 - y_0 | \mathbf{x}, w = 1)$$

OBS:

$$E(y_1 - y_0) = E[E(y_1 - y_0 | w)]$$

$$E(y_1 - y_0 | w) = E(y_1 - y_0 | w = 0) \cdot P(w = 0) + E(y_1 - y_0 | w = 1) \cdot P(w = 1).$$

15.3 Métodos Assumindo Ignorabilidade do Tratamento

ATE.1: Ignorabilidade.

w e (y_1, y_0) são independentes condicionais a \mathbf{x} .

ATE.1': Ignorabilidade da Média.

$$\text{a) } E(y_0 | w, \mathbf{x}) = E(y_0 | \mathbf{x})$$

$$\text{b) } E(y_1 | w, \mathbf{x}) = E(y_1 | \mathbf{x})$$

Vamos definir

$$E(y_0 | \mathbf{x}) = \mu_0(\mathbf{x})$$

$$E(y_1 | \mathbf{x}) = \mu_1(\mathbf{x}).$$

Sob **ATE.1** e **ATE.1'**:

$$ATE(\mathbf{x}) = E(y_1 - y_0 | \mathbf{x}) = \mu_1(\mathbf{x}) - \mu_0(\mathbf{x})$$

$$ATT(\mathbf{x}) = E(y_1 - y_0 | \mathbf{x}, w = 1) = \mu_1(\mathbf{x}) - \mu_0(\mathbf{x})$$

ATE.2: Overlap

Para todo \mathbf{x} , $P(w = 1 | \mathbf{x}) \in (0, 1)$, $p(\mathbf{x}) = p(w = 1 | \mathbf{x})$.

$p(\mathbf{x})$ é o *Propensity Score*, ele representa a probabilidade de y_i ser tratado dado o valor das covariáveis \mathbf{x} . Essa hipótese é importante visto que podemos expressar o *ATE* em função de $p(\mathbf{x})$.

Para o *ATT* vamos supor:

ATT.1': $E(y_0 | \mathbf{x}, w) = E(y_0 | \mathbf{x})$

ATT.2: Overlap: Para todo \mathbf{x} , $P(w = 1 | \mathbf{x}) < 1$.

15.4 Propensity Score

Como foi dito anteriormente, apenas observamos ou y_1 ou y_0 para a mesma pessoa, mas não ambos. Mais precisamente, junto com w , o resultado observado é:

$$y = wy_1 + (1 - w)y_0$$

como w é binário, $w^2 = w$, assim, temos:

$$\begin{aligned} wy &= w^2y_1 + (w - w^2)y_0 \implies \boxed{wy = wy_1} \\ (1 - w)y &= (w - w^2)y_1 + (w^2 - 2w + 1)y_0 \implies \boxed{(1 - w)y = (1 - w)y_0}. \end{aligned}$$

Fazemos isso para tentar isolar $\mu_0(\mathbf{x})$ e $\mu_1(\mathbf{x})$:

$$\mu_1(\mathbf{x})$$

$$\begin{aligned} E(wy | \mathbf{x}) &= E[E(wy_1 | \mathbf{x}, w) | \mathbf{x}] \\ &= E[w\mu_1(\mathbf{x}) | \mathbf{x}] \\ &= \mu_1(\mathbf{x})E(w | \mathbf{x}). \end{aligned}$$

Como w é binária: $E(w | \mathbf{x}) = P(w = 1 | \mathbf{x}) = p(\mathbf{x})$. Assim:

$$E(wy | \mathbf{x}) = \mu_1(\mathbf{x})p(\mathbf{x})$$

$$\boxed{\mu_1(\mathbf{x}) = \frac{E(wy | \mathbf{x})}{p(\mathbf{x})}}$$

$$\mu_0(\mathbf{x})$$

$$\begin{aligned} E[(1 - w)y | \mathbf{x}] &= E[E((1 - w)y_0 | \mathbf{x}, w) | \mathbf{x}] \\ &= E[(1 - w)\mu_0(\mathbf{x}) | \mathbf{x}] \\ &= \mu_0(\mathbf{x})E(w | \mathbf{x}) \end{aligned}$$

$$E[(1 - w)y | \mathbf{x}] = \mu_0(\mathbf{x})[1 - p(\mathbf{x})] \implies$$

$$\boxed{\mu_0(\mathbf{x}) = \frac{E[(1 - w)y | \mathbf{x}]}{1 - p(\mathbf{x})}}$$

ATE:

$$\mu_1(\mathbf{x}) - \mu_0(\mathbf{x}) = E\left[\frac{[w - p(\mathbf{x})]y}{p(\mathbf{x})[1 - p(\mathbf{x})]} | \mathbf{x}\right]$$

$$\boxed{\widehat{ATE} = N^{-1} \sum_{i=1}^N \frac{[w_i - p(\mathbf{x}_i)]y_i}{p(\mathbf{x}_i)[1 - p(\mathbf{x}_i)]}}$$

ATT:

$$E(y_1|\mathbf{x}, w = 1) - E(y_0|\mathbf{x}) = \frac{1}{\hat{P}(w = 1)} E \left[\frac{[w - \hat{p}(\mathbf{x})]y}{[1 - \hat{p}(\mathbf{x})]} | \mathbf{x} \right]$$

$$\hat{P}(w = 1) = N^{-1} \sum_{i=1}^N w_i$$

$$\widehat{ATT} = \frac{N}{\sum_{i=1}^N w_i} N^{-1} \sum_{i=1}^N \frac{[w_i - \hat{p}(\mathbf{x}_i)]y_i}{[1 - \hat{p}(\mathbf{x}_i)]}$$

$$\boxed{\widehat{ATT} = \frac{1}{\sum_{i=1}^N w_i} \sum_{i=1}^N \frac{[w_i - \hat{p}(\mathbf{x}_i)]y_i}{[1 - \hat{p}(\mathbf{x}_i)]}}$$

16 Álgebra Linear

16.1 Vetores

16.2 Operações com Vetores

Vamos definir os vetores \mathbf{x} e \mathbf{y} com dimensão $1 \times N$:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_N \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix}$$

Multiplicação por escalar

Soma

Subtração

Multiplicação de vetores

Produto Interno (Produto Escalar, Dot Product, Inner Product)

$$\mathbf{x}'\mathbf{y} = \mathbf{x} \cdot \mathbf{y} = \langle \mathbf{x}, \mathbf{y} \rangle = \sum_{i=1}^N x_i y_i = x_1 y_1 + \cdots + x_N y_N. \quad (16.1)$$

Podemos utilizar a equação (16.1) para denotarmos a soma dos elementos de um vetor. Para tanto, definimos o vetor $\mathbf{1}_N$ como sendo o vetor cujos elementos são 1 e tem dimensão $N \times 1$. (Greene, 2012, p. 977, A.2.7)

$$x_1 + \cdots + x_N = \sum_{i=1}^N x_i = \mathbf{x}'\mathbf{1}_N = \mathbf{1}_N' \mathbf{x} = (\mathbf{x}'\mathbf{1}_N)'$$

Com a definição do vetor $\mathbf{1}_N$, também podemos escrever: $\mathbf{1}_N' \mathbf{1}_N = N$.

Usando a definição de **média aritmética**, também podemos representá-la da seguinte forma:

$$\frac{x_1 + \cdots + x_N}{N} = \bar{x} = N^{-1} \sum_{i=1}^N x_i = N^{-1} \mathbf{x}'\mathbf{1}_N$$

Usando a definição de **média ponderada**, também podemos representá-la da seguinte forma:

$$w_1 x_1 + \cdots + w_N x_N = \sum_{i=1}^N w_i x_i = \mathbf{w}' \mathbf{x}$$

onde $\mathbf{w}'\mathbf{1} = 1$

Produto Externo (Outer Product)

$$\begin{aligned}
\mathbf{1}_N \mathbf{1}'_N &= \begin{bmatrix} 1 & \dots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \dots & 1 \end{bmatrix}_{N \times N} & \mathbf{1}_N \mathbf{x}' &= \begin{bmatrix} x_1 & \dots & x_N \\ \vdots & \ddots & \vdots \\ x_1 & \dots & x_N \end{bmatrix}_{N \times N} & \mathbf{x} \mathbf{1}'_N &= \begin{bmatrix} x_1 & \dots & x_1 \\ \vdots & \ddots & \vdots \\ x_N & \dots & x_N \end{bmatrix}_{N \times N} \\
\mathbf{x} \mathbf{x}' &= \begin{bmatrix} x_1 \\ \vdots \\ x_N \end{bmatrix} \begin{bmatrix} x_1 & \dots & x_N \end{bmatrix} = \begin{bmatrix} x_1^2 & x_1 x_2 & \dots & x_1 x_N \\ x_2 x_1 & x_2^2 & \dots & x_2 x_N \\ \vdots & \vdots & \ddots & \vdots \\ x_N x_1 & x_N x_2 & \dots & x_N^2 \end{bmatrix} \quad (16.2)
\end{aligned}$$

Distância e Ângulo O coseno do ângulo, α , entre dois vetores é:

$$\cos(\alpha) = \frac{\mathbf{u}'\mathbf{v}}{\|\mathbf{u}\| \cdot \|\mathbf{v}\|}$$

Dois vetores são **ortogonais** se $\mathbf{u}'\mathbf{v} = 0$.

Projeções Ortogonal

$$\text{proj}_{\mathbf{u}}(\mathbf{y}) = \hat{\mathbf{y}} = \frac{\mathbf{y}'\mathbf{u}}{\mathbf{u}'\mathbf{u}}\mathbf{u}$$

é a **projeção ortogonal** de \mathbf{y} em \mathbf{u} .

$$\mathbf{z} = \mathbf{y} - \hat{\mathbf{y}} = \mathbf{y} - \frac{\mathbf{y}'\mathbf{u}}{\mathbf{u}'\mathbf{u}}\mathbf{u}$$

é a **componente de \mathbf{y} ortogonal a \mathbf{u} (Rejeição)**.

Por construção, temos:

$$\mathbf{z} + \hat{\mathbf{y}} = \mathbf{y}.$$

[FIGURA AQUI]

Outras Notações Projeções Ortogonal Dado que

$$\text{proj}_{\mathbf{u}}(\mathbf{y}) = \frac{\mathbf{y}'\mathbf{u}}{\mathbf{u}'\mathbf{u}}\mathbf{u}$$

é a **projeção ortogonal** de \mathbf{y} em \mathbf{u} . Usando $\mathbf{y}'\mathbf{u} = \mathbf{u}'\mathbf{y}$, temos

$$\text{proj}_{\mathbf{u}}(\mathbf{y}) = \frac{\mathbf{u}\mathbf{u}'}{\mathbf{u}'\mathbf{u}}\mathbf{y}$$

Tirando o \mathbf{y} da equação, obtemos o **operador de projeção (Matriz de projeção em \mathbf{u})**:

$$\frac{\mathbf{u}\mathbf{u}'}{\mathbf{u}'\mathbf{u}} = \mathbf{u}(\mathbf{u}'\mathbf{u})^{-1}\mathbf{u}' = (\mathbf{u}'\mathbf{u})^{-1}\mathbf{u}\mathbf{u}' = (\|\mathbf{u}\|^2)^{-1}\mathbf{u}\mathbf{u}'$$

Agora, podemos definir o **operador rejeição** como:

$$\mathbf{I}_N - \frac{\mathbf{u}\mathbf{u}'}{\mathbf{u}'\mathbf{u}}$$

Usando o caso especial onde \mathbf{u} é um vetor de uns ($\mathbf{u} = \mathbf{1}_N$), temos a **projeção** no eixo de 45 graus:

$$(\mathbf{1}'_N \mathbf{1}_N)^{-1} \mathbf{1}_N \mathbf{1}'_N = N^{-1} \begin{bmatrix} 1 & \dots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \dots & 1 \end{bmatrix}_{N \times N} = \begin{bmatrix} 1/N & \dots & 1/N \\ \vdots & \ddots & \vdots \\ 1/N & \dots & 1/N \end{bmatrix}_{N \times N}$$

A **rejeição** no eixo de 45 graus:

$$\mathbf{I}_N - \frac{\mathbf{1}_N \mathbf{1}'_N}{\mathbf{1}'_N \mathbf{1}_N} = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix} - \begin{bmatrix} 1/N & 1/N & \dots & 1/N \\ 1/N & 1/N & \dots & 1/N \\ \vdots & \vdots & \ddots & \vdots \\ 1/N & 1/N & \dots & 1/N \end{bmatrix} = \begin{bmatrix} (N-1)/N & 1/N & \dots & 1/N \\ 1/N & (N-1)/N & \dots & 1/N \\ \vdots & \vdots & \ddots & \vdots \\ 1/N & 1/N & \dots & (N-1)/N \end{bmatrix}$$

Centering Matrix (Greene, 2012, p. 978, A.28)

$$\mathbf{M}^0 = \mathbf{I}_N - \mathbf{1}_N (\mathbf{1}'_N \mathbf{1}_N)^{-1} \mathbf{1}'_N = \mathbf{I}_N - N^{-1} \mathbf{1}_N \mathbf{1}'_N$$

A Matriz \mathbf{M}^0 é **idempotente** e **simétrica**.

Idempotência: $AA = A$

Simetria: $A' = A$

$$\mathbf{M}^0 \mathbf{x} = (\mathbf{I}_N - N^{-1} \mathbf{1}_N \mathbf{1}'_N) \mathbf{x} = \mathbf{x} - N^{-1} \mathbf{1}_N (\mathbf{1}'_N \mathbf{x}) = \mathbf{x} - \mathbf{1}_N \bar{x}$$

onde podemos denotar

$$\bar{x} \mathbf{1}_N = \begin{bmatrix} \bar{x} \\ \vdots \\ \bar{x} \end{bmatrix}$$

$$\mathbf{M}^0 \mathbf{x} = \mathbf{x} - \bar{x} \mathbf{1}_N$$

$$\mathbf{M}^0 \mathbf{1} = (\mathbf{I}_N - N^{-1} \mathbf{1}_N \mathbf{1}'_N) \mathbf{1}_N = \mathbf{1}_N - N^{-1} \mathbf{1}_N (\mathbf{1}'_N \mathbf{1}_N) = \mathbf{1}_N - \mathbf{1}_N = \mathbf{0}_N$$

16.3 Operações com Matrizes

Multiplicação por escalar

Soma

Subtração

Multiplicação de Matriz

$$A_{2 \times 2} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \quad B_{2 \times 3} = \begin{bmatrix} b_{11} & b_{12} & b_{13} \\ b_{21} & b_{22} & b_{23} \end{bmatrix}$$

$$[AB]_{2 \times 3} = \begin{bmatrix} a_{11} \\ a_{21} \end{bmatrix} \begin{bmatrix} b_{11} & b_{12} & b_{13} \end{bmatrix} + \begin{bmatrix} a_{12} \\ a_{22} \end{bmatrix} \begin{bmatrix} b_{21} & b_{22} & b_{23} \end{bmatrix} \implies AB = \sum_{i=1}^2 a_i b_i$$

onde a_i é a i -ésima **coluna** da matriz A . b_i é a i -ésima **linha** da matriz B .

16.3.1 Projeções

$$\mathbf{P}_X = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$$

$$\mathbf{M}_X = (\mathbf{I} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}')$$

Usando o modelo

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$$

E definindo $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$, temos

$$\mathbf{P}_X\mathbf{y} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \mathbf{X}\hat{\boldsymbol{\beta}} = \hat{\mathbf{y}}$$

$$\mathbf{M}_X\mathbf{y} = \mathbf{I}\mathbf{y} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{y} - \hat{\mathbf{y}} = \hat{\mathbf{u}}$$

17 Conceitos Básicos de Convergência Estatística

Definition 17.1 (Convergência em Probabilidade). Wooldridge (2010, Def 3.3, p.36)

Uma sequência de variáveis aleatórias: $\{X_N\}_{N \geq 1}$ **converge em probabilidade** para uma variável aleatória X se, dado $\varepsilon > 0$,

$$P(|X_N - X| > \varepsilon) \rightarrow 0,$$

quando $N \rightarrow +\infty$. E denotamos

$$\text{plim } X_N = X, \quad \text{ou} \quad X_N \xrightarrow{p} X, \quad \text{ou} \quad X_N - X \xrightarrow{p} 0.$$

Definition 17.2 (Estimador Consistente). Wooldridge (2010, Def 3.8, p.40)

Seja $\{\theta_N : N = 1, 2, \dots\}$ uma sequência de estimadores do vetor $\theta \in \Theta$ com dimensão $P \times 1$, onde N indexa o tamanho da amostra. Se

$$\hat{\theta} \xrightarrow{p} \theta \tag{17.1}$$

Para qualquer valor de θ , então dizemos que θ_N é um estimador consistente de θ .

Theorem 17.1 (LGN – Lei dos Grandes Números). Achar referência

Seja $\{X_i\}_{i \geq 1}$ uma sequência de variáveis aleatórias *iid* com $E(X_i) = \mu$. Então,

$$N^{-1} \sum_{i=1}^N X_i \xrightarrow{p} \mu.$$

Theorem 17.2 (LGN – Caso Matricial). Achar referência. O Teorema (17.3), abaixo, é diferente.

Seja $\{x_i\}_{i=1}^N$, uma sequência *iid* de vetores aleatórios $K \times 1$ com $E(x_i x_i') = Q_{K \times K}$ finita. Então,

$$N^{-1} \sum_{i=1}^N x_i x_i' \xrightarrow{p} Q.$$

Se Q for positiva definida, Q terá inversa.

Theorem 17.3 (LGNF – WLLN). Wooldridge (2010, Teo 3.1, p.39)

Seja $\{w_i : i = 1, 2, \dots\}$, uma sequência *iid* de vetores aleatórios $G \times 1$ com $E(|w_{ig}|) < \infty$ para $g = 1, \dots, G$. Então, a sequência satisfaz a **Lei dos Grandes Números Fraca (WLLN)**:

$$N^{-1} \sum_{i=1}^N w_i \xrightarrow{p} \mu_w,$$

onde $\mu_w \equiv E(w_i)$.

Definition 17.3 (o_p).

Wooldridge (2010, Def 3.4, p.36)

Wooldridge (2010, Lemma 3.2, p.36)

$$X_n = o_p(1) \implies X_n \xrightarrow{p} 0$$

$$X_n = o_p(Y_n) \implies \frac{X_n}{Y_n} = o_p(1) \implies \frac{X_n}{Y_n} \xrightarrow{p} 0$$

$$X_n = W_n + o_p(1) \implies (X_n - W_n) = o_p(1) \implies (X_n - W_n) \xrightarrow{p} 0$$

Definition 17.4 (Limitação em Probabilidade: O_p). Wooldridge (2010, Def 3.3 (3), p.36)

Dizemos que X_n é **limitado em probabilidade** e denotado por $X_n = O_p(1)$, se existe M maior que zero, tal que para todo ε maior que zero, $P(|X_n| > 0) < \varepsilon$.

$$X_n = O_p(1) \implies \exists M > 0; \forall \varepsilon > 0, P(|X_n| > 0) < \varepsilon.$$

Definition 17.5. Wooldridge (2010, Def 3.4, p.36)

Dizemos que $X_n = O_p(Y_n)$ se existe M maior que zero, tal que para todo ε maior que zero, $P(|X_n/Y_n| > 0) < \varepsilon$.

$$X_n = O_p(Y_n) \implies \exists M > 0; \forall \varepsilon > 0, P(|X_n/Y_n| > 0) < \varepsilon.$$

Lemma 17.1. Wooldridge (2010, Lemma 3.2, p.36)

Se $X_n = O_p(1)$ e $Y_n = o_p(1)$, então

$$X_n Y_n = O_p(1) o_p(1) = o_p(1).$$

Lemma 17.2 (Equivalência Assintótica). Wooldridge (2010, Lemma 3.7, p.39)

Seja $\{x_n\}$ e $\{z_n\}$ sequências de vetores aleatórios $K \times 1$. Se $z_n \xrightarrow{d} z$ e $x_n - z_n \xrightarrow{p} \mathbf{0}_K$. Então,

$$x_n \xrightarrow{d} z.$$

Definition 17.6 (Convergência em Distribuição). Wooldridge (2010, Def 3.6, p.38)

Seja $\{X_n\}_{n \geq 1}$ uma sequência de variáveis aleatórias e X uma variável aleatória com F_n e F suas respectivas FDAs, então

$$X_n \xrightarrow{d} X, \text{ se } F_n(X) \rightarrow F(X)$$

para todo X onde F é contínuo.

Lemma 17.3 (Convergência em Distribuição e Limitação em Probabilidade). Wooldridge (2010, Lemma 3.5, p.39)

Se $X_n \xrightarrow{d} X$, X um variável aleatória qualquer; então $X_n = O_p(1)$.

Definition 17.7 (TCL – Teorema Central do Limite). Achar Referência

Seja $\{X_n\}_{n=1}^N$ iid com $E(X_n) = \mu$ e $\text{Var}(X_n) = \sigma^2 < +\infty$. Então, para $S_N = \sum_{n=1}^N X_n$:

$$\frac{S_N - N\mu}{\sqrt{N}\sigma} = \frac{N(\bar{X} - \mu)}{\sqrt{N}\sigma} = \frac{N(\bar{X} - \mu)}{\sqrt{N}\sigma} = \boxed{\frac{\sqrt{N}(\bar{X} - \mu)}{\sigma} \xrightarrow{d} Z \sim N(0, 1)}.$$

Theorem 17.4 (TCL – Lindeberg-Levy). Wooldridge (2010, Teo 3.2, p.40)

Seja $\{w_i : i = 1, 2, \dots\}$ uma sequência iid de vetores aleatórios $G \times 1$ com $E(w_{ig}^2) < \infty$ para $g = 1, \dots, G$ e $E(w_i) = \mathbf{0}$. Então, $\{w_i : i = 1, 2, \dots\}$ satisfaz o **Teorema Central do Limite (CLT)**; qual seja:

$$N^{-1/2} \sum_{i=1}^N w_i \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{B}),$$

onde, $\mathbf{B} = \text{Var}(w_i) = E(w_i w_i')$ é necessariamente positiva semidefinida. Para nossos propósitos, \mathbf{B} será sempre positiva definida.

Corollary 17.1. Wooldridge (2010, Cor 3.2, p.39)

Seja $\{\mathbf{z}_N\}$ uma sequência de vetores $K \times 1$ aleatórios tal que $\mathbf{z}_N \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{V})$, então:

1. Para qualquer matriz \mathbf{A} de dimensão $K \times M$ **não** estocástica, temos:

$$\mathbf{A}'\mathbf{z}_N \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{A}'\mathbf{V}\mathbf{A}).$$

$$2. \mathbf{z}_N'\mathbf{V}^{-1}\mathbf{z}_N \xrightarrow{d} \chi_K^2 \text{ (ou } \mathbf{z}_N'\mathbf{V}^{-1}\mathbf{z}_N \overset{a}{\sim} \chi_K^2).$$

Definition 17.8 (raiz de N assintoticamente normalmente distribuido). Wooldridge (2010, Def 3.9, p.40)

Seja $\{\hat{\boldsymbol{\theta}}_N : N = 1, 2, \dots\}$ uma sequência de estimadores do vetor $\boldsymbol{\theta} \in \boldsymbol{\Theta}$ com dimensão $P \times 1$. Suponha que

$$\sqrt{N}(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta}) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{V}) \quad (17.2)$$

onde \mathbf{V} é uma matriz $P \times P$ positiva semidefinida. Então dizemos que $\hat{\boldsymbol{\theta}}_N$ é \sqrt{N} -asintoticamente normalmente distribuido e \mathbf{V} é a **variância assintótica** de $\sqrt{N}(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta})$, denotada $\text{Avar}\sqrt{N}(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta}) = \mathbf{V}$

Remark. Apesar de $\mathbf{V}/N = \text{Var}(\hat{\boldsymbol{\theta}}_N)$ ser verdade apenas em casos especiais, e raramente $\hat{\boldsymbol{\theta}}_N$ ter uma distribuição exatamente normal, tratamos $\hat{\boldsymbol{\theta}}_N$ como se

$$\hat{\boldsymbol{\theta}}_N \sim \mathcal{N}(\boldsymbol{\theta}, \mathbf{V}/N). \quad (17.3)$$

sempre que a equação (17.2) for verdade. Por essa razão, \mathbf{V}/N é chamado de **variância assintótica** de $\hat{\boldsymbol{\theta}}_N$, e escrevemos:

$$\text{Avar}(\hat{\boldsymbol{\theta}}_N) = \mathbf{V}/N. \quad (17.4)$$

Abaixo, temos as definições necessárias para mostrar como verificar se um estimador é consistente por EQM. Quero saber se mantemos essa parte. Se sim, precisamos de referências.

Definition 17.9 (Desigualdade de Markov). Achar referência

Seja $\{X_n\}_{n \geq 1}$ uma sequência de variáveis aleatórias com $E|X_n|^K < +\infty$, $K > 0$. Então, dado $\varepsilon > 0$

$$P(|X_n| > \varepsilon) \leq \frac{E|X_n|^K}{\varepsilon^K}$$

Definition 17.10. Achar referência

$$0 \leq P(|\hat{\theta} - \theta| > \varepsilon) \leq \frac{E|X_n|^2}{\varepsilon^2}$$

Definition 17.11 (Erro Quadrático Médio). Achar referência

$$EQM(\hat{\theta}) = E \left[(\hat{\theta} - \theta)^2 \right] = \left[\text{Bias}(\hat{\theta})^2 + \text{Var}(\hat{\theta}) \right]$$

Remark. Achar referência?

Então, se $\text{Bias}(\hat{\theta}) \rightarrow 0$ e $\text{Var}(\hat{\theta}) \rightarrow 0$, temos que $EQM(\hat{\theta}) \rightarrow 0$. Pelo **Teorema do Sanduíche**, $P(|\hat{\theta} - \theta| > \varepsilon) \rightarrow 0$; logo, $\hat{\theta} \xrightarrow{p} \theta$.

References

GREENE, WILLIAM H. 2012. *Econometric Analysis*. 7 edn. Boston: Prentice Hall.

WOOLDRIDGE, JEFFREY M. 2010. *Econometric Analysis of Cross Section and Panel Data*. 2 edn. Boston, Massachusetts: MIT Press.