

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
PROGRAMA DE PÓS-GRADUAÇÃO EM ECONOMIA
Microeconometria – 2015/3

Microeconometrics: Lecture Notes

Autor: Paulo Ferreira Naibert
Professor: Hudson Torrent

Porto Alegre
30/06/2020
Revisão: July 7, 2020

1 Regressão MQO Clássico

Wooldridge (2010, C.4 – The Single-Equation Linear Model and OLS Estimation, p.49–76)

1.1 Modelo de equações lineares

O modelo populacional que estudamos é linear em seus parâmetros,

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_K x_K + u \quad (1.1)$$

onde:

y, x_1, \dots, x_K são escalares aleatórios e observáveis (i.e., conseguimos observá-los em uma amostra aleatória da população);

u é o *random disturbance* não observável, ou erro;

$\beta_0, \beta_1, \dots, \beta_K$ são parâmetros (constantes) que gostaríamos de estimar.

Notação Vetorial

Wooldridge (2010, Sec. 4.2 – Asymptotic Properties of OLS; p.51)

Por conveniência, escrevemos a equação populacional em forma de vetor:

$$y = \mathbf{x}\boldsymbol{\beta} + u \quad (1.2)$$

onde,

$\mathbf{x} \equiv (x_1, \dots, x_K)$ é um vetor $1 \times K$ de regressores;

$\boldsymbol{\beta} \equiv (\beta_1, \dots, \beta_K)'$ é um vetor $K \times 1$.

Uma vez que a maioria das equações contém um intercepto, assumiremos que $x_1 \equiv 1$, visto que essa hipótese deixa a interpretação mais fácil.

Amostra Aleatória

Assumimos que conseguimos obter uma amostra aleatória de tamanho N da população para estimarmos $\boldsymbol{\beta}$. Dessa forma, $\{(\mathbf{x}_i, y_i); i = 1, 2, \dots, N\}$ são tratados como variáveis aleatória independentes, identicamente distribuídas, onde \mathbf{x}_i é $1 \times K$ e y_i é escalar. Para cada observação i , temos:

$$y_i = \mathbf{x}_i \boldsymbol{\beta} + u_i. \quad (1.3)$$

onde \mathbf{x}_i é um vetor $1 \times K$ de regressores.

1.2 Hipóteses

OLS.1 $y_i = \mathbf{x}_i \boldsymbol{\beta} + u_i, \quad i = 1, \dots, N;$

OLS.2 \mathbf{X} é não estocástica;

OLS.3 $\{u_i\}_{i=1}^N$ é *iid* com e para cada $i = 1, \dots, N$:

$$E(u_i) = 0$$

$$\text{Var}(u_i) = E(u_i^2) = \sigma^2$$

OLS.2' \mathbf{X} é estocástica;

OLS.3'

$$E(u_i|\mathbf{X}) = 0,$$

$$\text{Var}(u_i|\mathbf{X}) = E\left\{[u_i - E(u_i|\mathbf{X})]^2|\mathbf{X}\right\} = E(u_i^2|\mathbf{X}) = \sigma^2.$$

Remark. $E(u_i|\mathbf{X}) = 0$ implica que u_i é **não correlacionado** com todos os regressores x_k para $k = 1, \dots, K$. **Exogeneidade estrita.**

1.3 Estimação

Usando **OLS.1:**

$$y_i = \mathbf{x}_i\boldsymbol{\beta} + u_i$$

$$\mathbf{x}_i'y_i = \mathbf{x}_i'\mathbf{x}_i\boldsymbol{\beta} + \mathbf{x}_i'u_i$$

$$E(\mathbf{x}_i'y_i) = E(\mathbf{x}_i'\mathbf{x}_i)\boldsymbol{\beta} + E(\mathbf{x}_i'u_i)$$

Usando $E(\mathbf{x}_i'u_i) = 0$ [Qual seria essa hipótese?]

$$E(\mathbf{x}_i'y_i) = E(\mathbf{x}_i'\mathbf{x}_i)\boldsymbol{\beta}$$

$$\boxed{\boldsymbol{\beta} = [E(\mathbf{x}_i'\mathbf{x}_i)]^{-1}E(\mathbf{x}_i'y_i)} \quad (1.4)$$

Agora, usando o **princípio da analogia** e utilizando **estimadores amostrais**:

$$\boxed{\hat{\boldsymbol{\beta}} = \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'\mathbf{x}_i\right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'y_i\right)} \quad (1.5)$$

Podemos desenvolver essa equação para:

$$\begin{aligned} \hat{\boldsymbol{\beta}} &= \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'\mathbf{x}_i\right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'(\mathbf{x}_i\boldsymbol{\beta} + \mathbf{u}_i)\right) \\ &= \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'\mathbf{x}_i\right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'\mathbf{x}_i\boldsymbol{\beta}\right) + \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'\mathbf{u}_i\right) \\ \boxed{\hat{\boldsymbol{\beta}} &= \boldsymbol{\beta} + \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'\mathbf{x}_i\right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i'\mathbf{u}_i\right)} \end{aligned} \quad (1.6)$$

1.3.1 Notação Matricial

Empilhando as N observações, obtemos a **Notação Matricial**:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u} \quad (1.7)$$

\mathbf{y} é um vetor $N \times 1$;

\mathbf{X} é uma matriz $N \times K$ de regressores, com N vetores, \mathbf{x}_i , de dimensão $1 \times K$ empilhados;

$\boldsymbol{\beta}$ é um vetor $K \times 1$;

\mathbf{u} é um vetor $N \times 1$;

$$\mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix}; \quad \mathbf{X} = \begin{bmatrix} \mathbf{x}_1 \\ \vdots \\ \mathbf{x}_N \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1K} \\ \vdots & \vdots & \ddots & \vdots \\ x_{N1} & x_{N2} & \dots & x_{NK} \end{bmatrix}; \quad \mathbf{u} = \begin{bmatrix} u_1 \\ \vdots \\ u_N \end{bmatrix}.$$

As somas de vetores viram simples multiplicações de matrizes e a equação (1.5), vira:

$$\begin{aligned} \hat{\boldsymbol{\beta}} &= (N^{-1} \mathbf{X}' \mathbf{X})^{-1} (N^{-1} \mathbf{X}' \mathbf{y}) \\ \boxed{\hat{\boldsymbol{\beta}} &= (\mathbf{X}' \mathbf{X})^{-1} (\mathbf{X}' \mathbf{y})} \end{aligned} \tag{1.8}$$

1.4 Valor Esperado

$$\begin{aligned} E(\hat{\boldsymbol{\beta}}) &= E[(\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{y}] \\ &= E[(\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' (\mathbf{X} \boldsymbol{\beta} + \mathbf{u})] \\ &= E[(\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{X} \boldsymbol{\beta} + (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{u}] \\ &= E(\boldsymbol{\beta}) + E[(\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{u}] \end{aligned}$$

$$\boxed{E(\hat{\boldsymbol{\beta}}) = \boldsymbol{\beta} + E[(\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{u}]}$$

1.4.1 Viés

$$\boxed{B(\hat{\boldsymbol{\beta}}) = E(\hat{\boldsymbol{\beta}}) - \boldsymbol{\beta}}$$

$$\boxed{B(\hat{\boldsymbol{\beta}}) = E[(\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{u}]}$$

Remark. Sob **OLS.2'** e **OLS.3'**:

$$\begin{aligned} E[(\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{u}] &= E\{E[(\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{u} | \mathbf{X}]\} \\ &= E\left\{(\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \underbrace{E(\mathbf{u} | \mathbf{X})}_{=0}\right\} = 0 \end{aligned}$$

ou seja, $B(\hat{\boldsymbol{\beta}}) = 0$, logo $\hat{\boldsymbol{\beta}}$ é **não-viciado**. O que também é equivalente a $E(\hat{\boldsymbol{\beta}}) = \boldsymbol{\beta}$.

1.5 Variância

Supondo **OLS.2'** e **OLS.3'**:

$$\begin{aligned} \text{Var}(\hat{\boldsymbol{\beta}} | \mathbf{X}) &= E\left\{\left[\hat{\boldsymbol{\beta}} - E(\hat{\boldsymbol{\beta}} | \mathbf{X})\right]^2 | \mathbf{X}\right\} \\ &= E\left\{\left[\hat{\boldsymbol{\beta}} - E(\hat{\boldsymbol{\beta}} | \mathbf{X})\right] \left[\hat{\boldsymbol{\beta}} - E(\hat{\boldsymbol{\beta}} | \mathbf{X})\right]' | \mathbf{X}\right\} \\ &= E\left\{[(\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{u}] [(\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{u}]' | \mathbf{X}\right\} \\ &= E[(\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{u} \mathbf{u}' \mathbf{X} (\mathbf{X}' \mathbf{X})^{-1} | \mathbf{X}] \end{aligned}$$

$$\boxed{\text{Var}(\hat{\boldsymbol{\beta}} | \mathbf{X}) = (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' E[\mathbf{u} \mathbf{u}' | \mathbf{X}] \mathbf{X} (\mathbf{X}' \mathbf{X})^{-1}}$$

1.5.1 Homocedasticidade

Supondo **homocedasticidade** e ausência de correlação serial: $E[\mathbf{u}\mathbf{u}'|\mathbf{X}] = \sigma^2 I_N$. Assim,

$$\text{Var}(\hat{\boldsymbol{\beta}}|\mathbf{X}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'I_N\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}$$

$$\boxed{\text{Var}(\hat{\boldsymbol{\beta}}|\mathbf{X}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}}.$$

2 Ausência de Exogeneidade Estrita

Nem sempre poderemos supor **exogeneidade estrita**. Por exemplo, no modelo com variável defasada mostrado abaixo:

$$\begin{aligned}y_t &= \beta_0 + \beta_1 y_{t-1} + \beta_2 x_{1t} + u_t \\y_{t-1} &= \beta_0 + \beta_1 y_{t-2} + \beta_2 x_{1t-1} + u_{t-1} \\y_t &= \beta_0(1 + \beta_1) + \beta_1^2 y_{t-2} + \beta_1 \beta_2 x_{1t-1} + \beta_2 x_{1t} + u_t + \beta_1 u_{t-1},\end{aligned}$$

o erro é correlacionado com o regressor y_{t-1} . Nesse caso, tentaremos obter apenas **consistência** e **variância assintótica** do estimador. Para tanto, utilizaremos a equação (1.6):

$$\hat{\beta} = \beta + \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i u_i \right).$$

Aqui começaria a seção 15.

2.1 Consistência

Vamos definir a matriz $K \times K$, $\mathbf{A} \equiv E(\mathbf{x}'_i \mathbf{x}_i)$. Supondo \mathbf{A} , finita e positiva definida, posto(\mathbf{A}) = K . Usando **LGN matricial** (Definição 15.7 na página 35), temos:

[lembrar que as dimensões dos vetores estão invertidas: $1 \times K$ e **não** $K \times 1$]

$$N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \xrightarrow{p} \mathbf{A} \implies \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \xrightarrow{p} \mathbf{A}^{-1}. \quad (2.1)$$

Além disso, vamos supor $E(\mathbf{x}'_i u_i) = 0$, o que corresponde a $Cov(\mathbf{x}_i, u_i) = 0$, ou seja, o erro u_i **não** é correlacionado com os regressores da própria equação. Isso é bem menos que exogeneidade estrita. Então,

$$N^{-1} \sum_{i=1}^N \mathbf{x}'_i u_i \xrightarrow{p} E(\mathbf{x}'_i u_i) = \mathbf{0}_K.$$

Logo,

$$\boxed{\hat{\beta} = \beta + \underbrace{\left(\sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \left(\sum_{i=1}^N \mathbf{x}'_i u_i \right)}_{\xrightarrow{p} 0}}$$

Então, $(\hat{\beta} - \beta) \xrightarrow{p} 0$ que é equivalente a $\hat{\beta} \xrightarrow{p} \beta$ e plim $\hat{\beta} = \beta$, ou seja, $\hat{\beta}$ é **consistente** para β .

2.2 Normalidade Assintótica

$$\begin{aligned}\hat{\beta} &= \beta + \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i u_i \right) \\ (\hat{\beta} - \beta) &= \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i u_i \right) \\ \sqrt{N}(\hat{\beta} - \beta) &= \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i \right)\end{aligned}$$

Supondo $E(x_{ik}^2 u_i^2) < +\infty$, $k = 1, \dots, K$, e definindo $\mathbf{B} = E[\mathbf{x}'_i u_i u_i \mathbf{x}_i] = E[u_i^2 \mathbf{x}'_i \mathbf{x}_i]$. Temos, pela Definição 15.16 (TCL), que

$$N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i \xrightarrow{d} N(\mathbf{0}, \mathbf{B}) \implies N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i = O_p(1) \quad (2.2)$$

Além disso, vamos utilizar a matriz **simétrica** e **não singular** \mathbf{A} da equação (2.1). Assim, temos

$$\begin{aligned}\sqrt{N}(\hat{\beta} - \beta) &= \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i \right) \\ &= \left[\left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} + \mathbf{A}^{-1} - \mathbf{A}^{-1} \right] \left(N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i \right) \\ &= \left[\left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} - \mathbf{A}^{-1} \right] \left(N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i \right) + \mathbf{A}^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i \right),\end{aligned}$$

Podemos inverter \mathbf{A} porque ela tem posto completo (não singular). Pelas propriedades de \mathbf{A} , temos:

$$N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \xrightarrow{p} \mathbf{A} \implies \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} - \mathbf{A}^{-1} = o_p(1).$$

Então,

$$\sqrt{N}(\hat{\beta} - \beta) = o_p(1)O_p(1) + \mathbf{A}^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i \right),$$

Usando (2.2) e a Definição 15.13.

$$\mathbf{A}^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{x}'_i u_i \right) \xrightarrow{d} N(\mathbf{0}, \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1}).$$

Lembrando que $o_p(1)O_p(1) = o_p(1)$, temos:

$$\sqrt{N}(\hat{\beta} - \beta) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1}) \implies \sqrt{N}(\hat{\beta} - \beta) \stackrel{a}{\sim} \mathcal{N}(\mathbf{0}, \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1})$$

2.3 Variância

$$\mathbf{V} = \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1}$$

$$\mathbf{V} = \mathbb{E}[(\mathbf{x}'_i \mathbf{x}_i)]^{-1} \mathbb{E}[(\mathbf{x}'_i u'_i u_i \mathbf{x}_i)] \mathbb{E}[(\mathbf{x}'_i \mathbf{x}_i)]^{-1}$$

$$\mathbf{V} = \mathbb{E}[(\mathbf{x}'_i \mathbf{x}_i)]^{-1} \mathbb{E}[u_i^2 \mathbf{x}'_i \mathbf{x}_i] \mathbb{E}[(\mathbf{x}'_i \mathbf{x}_i)]^{-1}.$$

2.3.1 Homocedasticidade

Sob **Homocedasticidade**, temos $\mathbf{B} = \mathbb{E}(u_i^2 \mathbf{x}'_i \mathbf{x}_i) = \sigma^2 \mathbb{E}(\mathbf{x}'_i \mathbf{x}_i)$, logo

$$\boxed{\mathbf{V} = \sigma^2 \mathbb{E}[(\mathbf{x}'_i \mathbf{x}_i)]^{-1}}.$$

2.3.2 Estimador Amostral

$$\begin{aligned} \hat{\mathbf{V}} &= \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N u_i^2 \mathbf{x}'_i \mathbf{x}_i \right) \left(N^{-1} \sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \\ &= N \left(\sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \left(\sum_{i=1}^N u_i^2 \mathbf{x}'_i \mathbf{x}_i \right) \left(\sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \end{aligned}$$

$$\boxed{\hat{\mathbf{V}} = N (\mathbf{X}' \mathbf{X})^{-1} \left(\sum_{i=1}^N u_i^2 \mathbf{x}'_i \mathbf{x}_i \right) (\mathbf{X}' \mathbf{X})^{-1}}.$$

2.3.3 Variância do estimador de OLS

$$\text{Var}(\sqrt{N} \hat{\boldsymbol{\beta}}) = \mathbf{V}$$

$$\text{Var}(\hat{\boldsymbol{\beta}}) = N^{-1} \mathbf{V}$$

$$\boxed{\text{Var}(\hat{\boldsymbol{\beta}}) = (\mathbf{X}' \mathbf{X})^{-1} \left(\sum_{i=1}^N u_i^2 \mathbf{x}'_i \mathbf{x}_i \right) (\mathbf{X}' \mathbf{X})^{-1}}.$$

A variância **Robusta** é:

$$\boxed{\widehat{\text{Var}}(\hat{\boldsymbol{\beta}}) = (\mathbf{X}' \mathbf{X})^{-1} \left(\sum_{i=1}^N \hat{u}_i^2 \mathbf{x}'_i \mathbf{x}_i \right) (\mathbf{X}' \mathbf{X})^{-1}}.$$

A variância sob **Homocedasticidade** é:

$$\boxed{\widehat{\text{Var}}(\hat{\boldsymbol{\beta}}) = \hat{\sigma}^2 (\mathbf{X}' \mathbf{X})^{-1}}.$$

3 System OLS (SOLS)

Wooldridge (2010, C.7 – Estimating Systems of Equations by OLS and GLS, p.143–179)

Wooldridge (2010, Sec.7.3 – System OLS Estimation of a Multivariate Linear System, p.147)

3.1 Preliminares

Wooldridge (2010, Sec.7.3.1)

Assumimos que temos as seguintes observações *cross section iid*: $\{(\mathbf{X}_i, \mathbf{y}_i) : i = 1, \dots, N\}$, onde:

\mathbf{X}_i é uma matriz $G \times K$ e contém as variáveis explicativas que aparecem em qualquer lugar do sistema.

\mathbf{y}_i é um vetor $G \times 1$, que contém as variáveis dependentes para todas as equações G (ou períodos de tempo, no caso de dados de painel).

O modelo linear multivariado para uma observação (draw) aleatória da população pode ser expresso como:

$$\mathbf{y}_i = \mathbf{X}_i \boldsymbol{\beta} + \mathbf{u}_i, \quad i = 1, \dots, N, \quad (3.1)$$

onde:

$\boldsymbol{\beta}$ é um vetor $K \times 1$ de parâmetros de interesse; e

\mathbf{u}_i é um vetor $G \times 1$ de não observáveis.

A equação (3.1) explica as G variáveis y_{i1}, \dots, y_{iG} em termos de \mathbf{X}_i e das não observáveis \mathbf{u}_i . Por causa da hipótese de amostra aleatória podemos escrever tudo em termos de uma observação genérica.

3.2 Propriedades Assintóticas do SOLS

Wooldridge (2010, Sec.7.3.1)

SOLS.1 $E(\mathbf{X}_i' \mathbf{u}_i) = 0$.

SOLS.2 $A \equiv E(\mathbf{X}_i' \mathbf{X}_i)$ é não singular (tem posto pleno, posto igual a K).

A hipótese **SOLS.1** é a mais fraca que podemos impor num arcabouço de regressão para conseguirmos um estimador de $\boldsymbol{\beta}$ consistente. Essa hipótese permite que alguns elementos de \mathbf{X}_i sejam correlacionados com elementos de \mathbf{u}_i . Uma hipótese mais forte seria:

$$E(\mathbf{u}_i | \mathbf{X}_i) = \mathbf{0} \quad (3.2)$$

Sob **SOLS.1**, temos:

$$\begin{aligned} E[\mathbf{X}_i' (\mathbf{y}_i - \mathbf{X}_i \boldsymbol{\beta})] &= \mathbf{0} \\ E(\mathbf{X}_i' \mathbf{X}_i) \boldsymbol{\beta} &= E(\mathbf{X}_i' \mathbf{y}_i) \end{aligned}$$

Para cada i , $\mathbf{X}_i \mathbf{y}_i$ é um vetor aleatório $K \times 1$ e $\mathbf{X}_i' \mathbf{X}_i$ é uma matriz $K \times K$ aleatória simétrica, positiva semidefinida. Então, $E(\mathbf{X}_i' \mathbf{X}_i)$ é sempre uma matriz $K \times K$ não aleatória simétrica, positiva semidefinida. Para conseguirmos estimar $\boldsymbol{\beta}$ precisamos assumir que ele é o único vetor $K \times 1$ que satisfaz $E(\mathbf{X}_i' \mathbf{X}_i) \boldsymbol{\beta} = E(\mathbf{X}_i' \mathbf{y}_i)$. Por isso assumimos **SOLS.2** e sob **SOLS.1** e **SOLS.2**, podemos escrever $\boldsymbol{\beta}$ como:

$$\boxed{\boldsymbol{\beta} = [E(\mathbf{X}_i' \mathbf{X}_i)]^{-1} E(\mathbf{X}_i' \mathbf{y}_i)} \quad (3.3)$$

o que mostra que **SOLS.1** e **SOLS.2** identifica o vetor β . **O princípio da analogia** sugere que estimemos β pelas analogias amostrais de (3.3). Assim, definimos o estimador SOLS de β como:

$$\hat{\beta}^{SOLS} = \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{y}_i \right). \quad (3.4)$$

Para computar $\hat{\beta}$ usando linguagem de computação é mais fácil utilizar a notação matricial

$$\hat{\beta}^{SOLS} = (\mathbf{X}'\mathbf{X})^{-1} (\mathbf{X}'\mathbf{y}) \quad (3.5)$$

onde

$\mathbf{X} \equiv (\mathbf{X}'_1, \dots, \mathbf{X}'_N)$ é uma matriz $NG \times K$ dos \mathbf{X}_i empilhados.

$\mathbf{y} \equiv (\mathbf{y}'_1, \dots, \mathbf{y}'_N)$ é um vetor $NG \times 1$ das observações \mathbf{y}_i empilhadas.

SOLS para SUR Estimação SOLS para um modelo SUR é equivalente a OLS equação a equação.

3.2.1 Consistência

Para provarmos a **consistência** do estimador, usamos a equação (3.4):

$$\begin{aligned} \hat{\beta}^{SOLS} &= \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{y}_i \right) \\ &= \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left[N^{-1} \sum_{i=1}^N \mathbf{X}_i' (\mathbf{X}_i \beta + \mathbf{u}_i) \right] \\ &= \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \beta \right) + \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right) \\ &= \beta + \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right) \end{aligned}$$

Por **SOLS.1**, $N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \xrightarrow{p} \mathbf{0}$; e por **SOLS.2** $\left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \xrightarrow{p} A^{-1}$.

Resumimos esse resultado pelo seguinte Teorema:

[Consistência do SOLS] Sob Hipóteses **SOLS.1** e **SOLS.2**, temos

$$\hat{\beta}^{SOLS} \xrightarrow{p} \beta.$$

3.2.2 Normalidade Assintótica

Para fazermos **Inferência**, precisamos achar a variância assintótica do estimador de OLS sob, essencialmente, as mesmas duas hipóteses. Tecnicamente, a seguinte derivação exige os elementos de $\mathbf{X}_i' \mathbf{u}_i \mathbf{u}_i' \mathbf{X}_i$ tenham *finite expected absolute value*. De (3.4) e (3.1), escrevemos:

$$\begin{aligned}\hat{\beta} &= \beta + \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right) \\ (\hat{\beta} - \beta) &= \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right) \\ \sqrt{N}(\hat{\beta} - \beta) &= \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right).\end{aligned}$$

Uma vez que $E(\mathbf{X}_i' \mathbf{u}_i) = 0$, sob a hipótese **SOLS.1**, o CLT implica que:

$$N^{-1/2} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \xrightarrow{d} N(\mathbf{0}, \mathbf{B}),$$

onde

$$\mathbf{B} \equiv E(\mathbf{X}_i' \mathbf{u}_i \mathbf{u}_i' \mathbf{X}_i) \equiv \text{Var}(\mathbf{X}_i' \mathbf{u}_i).$$

Em particular,

$$N^{-1/2} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i = O_p(1).$$

Porém,

$$\left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} = (\mathbf{X}' \mathbf{X} / N)^{-1} = A^{-1} + o_p(1).$$

Sendo Assim,

$$\begin{aligned}\sqrt{N}(\hat{\beta} - \beta) &= \left[A^{-1} + \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} - A^{-1} \right] \left(N^{-1/2} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right) \\ &= A^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right) + [(\mathbf{X}' \mathbf{X} / N)^{-1} - A^{-1}] \left(N^{-1/2} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right) \\ &= A^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right) + o_p(1) O_p(1) \\ &= A^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{X}_i' \mathbf{u}_i \right) + o_p(1)\end{aligned}$$

Portanto, com apenas *single-equation OLS and 2SLS*, obtemos a representação assintótica para $\sqrt{N}(\hat{\beta} - \beta)$ que é uma combinação linear não aleatória de somas parciais que satisfazem o CLT. Usando o **lema de equivalência assintótica**, temos:

$$\sqrt{N}(\hat{\beta} - \beta) \xrightarrow{d} N(\mathbf{0}, A^{-1} \mathbf{B} A^{-1})$$

Resumimos esse resultado com o seguinte Teorema:

[Normalidade Assintótica do SOLS] Sob Hipóteses **SOLS.1** e **SOLS.2**, temos que a seguinte equação vale:

$$\boxed{\sqrt{N}(\hat{\beta} - \beta) \xrightarrow{d} N(\mathbf{0}, A^{-1}\mathbf{B}A^{-1})}. \quad (3.6)$$

3.2.3 Variância Assintótica

A variância assintótica de $\hat{\beta}^{SOLS}$ é:

$$\text{Avar}(\hat{\beta}^{SOLS}) = A^{-1}\mathbf{B}A^{-1}/N. \quad (3.7)$$

Assim, $\text{Avar}(\hat{\beta}^{SOLS})$ tende a zero a uma taxa $1/N$, como esperado. Estimação consistente de A é:

$$\hat{A} \equiv \mathbf{X}'\mathbf{X}/N = N^{-1} \sum_{i=1}^N \mathbf{X}_i'\mathbf{X}_i$$

Um estimador consistente para B pode ser achado usando o princípio da analogia.

$$B = E(\mathbf{X}_i'\mathbf{u}_i\mathbf{u}_i'\mathbf{X}_i), \quad N^{-1} \sum_{i=1}^N \mathbf{X}_i'\mathbf{u}_i\mathbf{u}_i'\mathbf{X}_i \xrightarrow{p} B.$$

Uma vez que não podemos observar \mathbf{u}_i , usamos os resíduos da estimação de SOLS:

$$\hat{\mathbf{u}}_i \equiv \mathbf{y}_i - \mathbf{X}_i\hat{\beta} = \mathbf{u}_i - \mathbf{X}_i(\hat{\beta} - \beta).$$

Assim, definimos \hat{B} e usando LGN, podemos mostrar que:

$$\hat{B} \equiv N^{-1} \sum_{i=1}^N \mathbf{X}_i'\hat{\mathbf{u}}_i\hat{\mathbf{u}}_i'\mathbf{X}_i \xrightarrow{p} B.$$

onde supomos que certos momentos envolvendo \mathbf{X}_i e \mathbf{u}_i são finitos.

Portanto, $\text{Avar}[\sqrt{N}(\hat{\beta} - \beta)]$ é **consistentemente** estimado por $\hat{A}^{-1}\hat{B}\hat{A}^{-1}$, e $\text{Avar}(\hat{\beta})$ é estimado como:

$$\hat{V} \equiv \left(\sum_{i=1}^N \mathbf{X}_i'\mathbf{X}_i \right)^{-1} \left(\sum_{i=1}^N \mathbf{X}_i'\hat{\mathbf{u}}_i\hat{\mathbf{u}}_i'\mathbf{X}_i \right) \left(\sum_{i=1}^N \mathbf{X}_i'\mathbf{X}_i \right)^{-1}.$$

Sob as hipóteses **SOLS.1** e **SOLS.2**, nós fazemos inferência em β como $\hat{\beta}$ fosse normalmente distribuído com média β e variância \hat{V} .

4 SOLS para Dados de Painei

Wooldridge (2010, Sec.7.8 – The Linar Panel Data Model, Revisited. p.169)

No caso de dados de painel:

$$\sum_{i=1}^N \mathbf{X}'_i \mathbf{X}_i = \sum_{i=1}^N \sum_{t=1}^T \mathbf{x}'_{it} \mathbf{x}_{it}; \quad \sum_{i=1}^N \mathbf{X}'_i \mathbf{y}_i = \sum_{i=1}^N \sum_{t=1}^T \mathbf{x}'_{it} y_{it}.$$

Portanto, podemos escrever $\hat{\beta}$ como:

$$\hat{\beta}^{POLS} = \left(\sum_{i=1}^N \sum_{t=1}^T \mathbf{x}'_{it} \mathbf{x}_{it} \right)^{-1} \left(\sum_{i=1}^N \sum_{t=1}^T \mathbf{x}'_{it} y_{it} \right). \quad (4.1)$$

Este estimador é chamado **estimador de Mínimos Quadrados Agrupados (POLS)** porque ele corresponde a rodar uma regressão OLS nas observações agrupadas através de i e t . O estimador da equação (4.1) é o mesmo para unidades de *cross section* amostradas em diferentes pontos do tempo. O Teorema 3.2.1, abaixo, mostraa que o estimador POLS é consistente sob as condições de ortogonalidade na hipótese **XX** e uma hipótese de posto completo.

$$\begin{aligned} E(\mathbf{x}_{it}) \\ \mathbf{X}'_i \mathbf{u}_i = \sum_{t=1}^T \mathbf{x}'_{it} u_{it} \end{aligned}$$

5 System GLS (SGLS)

Wooldridge (2010, Sec.7.4 – Consistency and Asymptotic Normality of Generalized Least Squares, p.153)

Hipóteses

Para implementarmos o estimador de **GLS** precisamos das seguintes hipótese:

1. $E(\mathbf{X}_i \otimes \mathbf{u}_i) = 0$.

Para SGLS ser consistente, precisamos que \mathbf{u}_i não seja correlacionada com nenhum elemento de \mathbf{X}_i .

2. Ω é positiva definida (para ter inversa). $E(\mathbf{X}_i' \Omega^{-1} \mathbf{X}_i)$ é **não** singular (para ter inversa).

Onde, Ω é a seguinte matriz **simétrica**, positiva-definida:

$$\Omega = E(\mathbf{u}_i \mathbf{u}_i').$$

Estimação

Agora, transformamos o sistema de equações ao realizarmos a pré-multiplicação do sistema por $\Omega^{-1/2}$:

$$\begin{aligned}\Omega^{-1/2} \mathbf{y}_i &= \Omega^{-1/2} \mathbf{X}_i \boldsymbol{\beta} + \Omega^{-1/2} \mathbf{u}_i \\ \mathbf{y}_i^* &= \mathbf{X}_i^* \boldsymbol{\beta} + \mathbf{u}_i^*\end{aligned}$$

Estimando a equação acima por **SOLS**:

$$\begin{aligned}\beta^{SOLS} &= \left(\sum_{i=1} \mathbf{X}_i^{*'} \mathbf{X}_i^* \right)^{-1} \left(\sum_{i=1} \mathbf{X}_i^{*'} \mathbf{y}_i^* \right) \\ &= \left(\sum_{i=1} \mathbf{X}_i' \Omega^{-1/2} \Omega^{-1/2} \mathbf{X}_i \right)^{-1} \left(\sum_{i=1} \mathbf{X}_i' \Omega^{-1/2} \Omega^{-1/2} \mathbf{y}_i \right) \\ &= \left(\sum_{i=1} \mathbf{X}_i' \Omega^{-1} \mathbf{X}_i \right)^{-1} \left(\sum_{i=1} \mathbf{X}_i' \Omega^{-1} \mathbf{y}_i \right)\end{aligned}$$

6 GLS Factível

Wooldridge (2010, Sec.7.5 – Feasible GLS, p.153)

FSGLS: SGLS Factível

Para obtermos β^{SGLS} precisamos conhecer Ω , o que não ocorre na prática. Então, precisamos estimar Ω com um estimador consistente. Para tanto usamos um procedimento de dois passos:

1. Estimar $\mathbf{y}_i = \mathbf{X}_i\beta + \mathbf{u}_i$ via **SOLS** e guardar o resíduo estimado $\hat{\mathbf{u}}_i$.
2. Estimar Ω com o seguinte estimador $\hat{\Omega}$:

$$\hat{\Omega} = N^{-1} \sum_{i=1}^N \mathbf{u}_i \mathbf{u}_i'$$

Com a estimativa $\hat{\Omega}$ feita, podemos obter β^{FSGLS} pela fórmula do β^{SGLS} :

$$\beta^{FGLS} = \left[\sum_i \mathbf{X}_i' \hat{\Omega}^{-1} \mathbf{X}_i \right]^{-1} \left[\sum_i \mathbf{X}_i' \hat{\Omega}^{-1} \mathbf{y}_i \right]$$

Empilhando as N observações:

$$\beta^{FGLS} = \left[\mathbf{X} \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{X}' \right]^{-1} \left[\mathbf{X}' \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{y} \right]$$

Reescrevendo a equação acima:

$$\begin{aligned} \beta^{FGLS} &= \left[\mathbf{X} \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{X}' \right]^{-1} \left[\mathbf{X}' \left(I_N \otimes \hat{\Omega}^{-1} \right) (\mathbf{X}\beta + \mathbf{u}) \right] \\ &= \left[\mathbf{X} \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{X}' \right]^{-1} \left\{ \left[\mathbf{X}' \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{X} \right] \beta + \left[\mathbf{X}' \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{u} \right] \right\} \\ &= \beta + \left[\mathbf{X} \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{X}' \right]^{-1} \left[\mathbf{X}' \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{u} \right] \end{aligned}$$

Valor Esperado

$$E(\beta^{FGLS}) = \beta + \left[\mathbf{X} \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{X}' \right]^{-1} \left[\mathbf{X}' \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{u} \right]$$

Concluimos que, se $\hat{\Omega} \xrightarrow{p} \Omega$, então, $\beta^{FSGLS} \xrightarrow{p} \beta$,

Variância

$$\begin{aligned} \text{Var}(\beta^{FGLS}) &= \left[\mathbf{X} \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{X}' \right]^{-1} \left[\mathbf{X}' \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{u} \right] \left\{ \left[\mathbf{X} \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{X}' \right]^{-1} \left[\mathbf{X}' \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{u} \right] \right\}' \\ &= \left[\mathbf{X} \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{X}' \right]^{-1} \left[\mathbf{X}' \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{u} \mathbf{u}' \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{X} \right] \left[\mathbf{X} \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{X}' \right]^{-1} \end{aligned}$$

Tirando o valor Esperado e supondo que:

$$E(\mathbf{X}_i \Omega^{-1} \mathbf{u}_i \mathbf{u}_i' \mathbf{X}_i) = E(\mathbf{X}_i \Omega^{-1})$$

temos:

$$E \left[\mathbf{X}' \left(I_N \otimes \hat{\Omega}^{-1} \right) \mathbf{u} \mathbf{u}' \left(I_N \otimes \hat{\Omega}^{-1} \right)' \mathbf{X} \right] = E(\mathbf{X}' \Omega^{-1} \mathbf{X})$$

e temos:

$$\text{Var}(\beta^{FSGLS}) = [E(\mathbf{X}' \Omega^{-1} \mathbf{X})]^{-1}.$$

7 Modelo de Efeitos Não Observados

[Wooldridge](#) (2010, C.10 – Basic Linear Unobserved Effects Panel Data Models)

8 Endogeneity and GMM

Modelo

No seguinte modelo *cross-section*:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \varepsilon_i ; \quad i = 1, \dots, N. \quad (8.1)$$

A variável explicativa x_k é dita **endógena** se ela for correlacionada com erro. Se x_k for não correlacionada com o erro, então x_k é dita **exógena**.

Endogeneidade surge, normalmente, de três maneiras diferentes:

1. Variável Omitida;
2. Simultaneidade;
3. Erro de Medida.

No modelo (8.1) vamos supor:

- x_1 é exógena.
- x_2 é endógena.

Hipóteses

Assim, precisamos encontrar um instrumento z_i para x_2 , uma vez que queremos estimar β_0 , β_1 e β_2 de maneira consistente. Para z_i ser um bom instrumento precisamos que z tenha:

1. $Cov(z, \varepsilon) = 0 \implies z$ é exógena em (8.1).
2. $Cov(z, x_2) \neq 0 \implies$ correlação com x_2 após controlar para outras variáveis.

Estimação

Indo para o problema de dados de painel, temos:

$$\mathbf{y}_i = \mathbf{X}_i \boldsymbol{\beta} + \mathbf{u}_i ; \quad i = 1, \dots, N. \quad (8.2)$$

onde \mathbf{y}_i é um vetor $T \times 1$, \mathbf{X}_i é uma matriz $T \times K$, $\boldsymbol{\beta}$ é o vetor de coeficientes $K \times 1$, \mathbf{u}_i é o vetor de erros $T \times 1$.

Se é verdade que há endogeneidade em (8.2), então:

$$E(\mathbf{X}_i' \mathbf{u}_i) \neq 0$$

Definimos Z_i como uma matriz $T \times L$ com $L \geq K$ de variáveis exógenas (incluindo o instrumento). Queremos acabar com a endogeneidade, ou seja:

$$E(Z_i' \mathbf{u}_i) = 0$$

Supondo $L = K$ (apenas substituímos a variável endógena por um instrumento).

$$\begin{aligned} E[Z_i' (\mathbf{y}_i - \mathbf{X}_i \boldsymbol{\beta})] &= 0 \\ E(Z_i' \mathbf{y}_i) - E(Z_i' \mathbf{X}_i) \boldsymbol{\beta} &= 0 \\ E(Z_i' \mathbf{y}_i) &= E(Z_i' \mathbf{X}_i) \boldsymbol{\beta} \end{aligned}$$

$$\boxed{\boldsymbol{\beta} = [E(Z_i' \mathbf{X}_i)]^{-1} [E(Z_i' \mathbf{y}_i)]}$$

Se Usarmos estimadores amostrais:

$$\hat{\beta} = \left[N^{-1} \sum_{i=1}^N Z_i' \mathbf{X}_i \right]^{-1} \left[N^{-1} \sum_{i=1}^N Z_i' \mathbf{y}_i \right]$$

$$\boxed{\hat{\beta} = (Z' \mathbf{X})^{-1} (Z' \mathbf{y})}$$

Se $L > K$, vamos considerar:

$$\text{Min}_{\beta} E(Z_i \mathbf{u}_i)^2$$

onde:

$$\begin{aligned} E(Z_i \mathbf{u}_i)^2 &= E[(Z_i \mathbf{u}_i)'(Z_i \mathbf{u}_i)] = (Z' \mathbf{y} - Z' \mathbf{X} \beta)'(Z' \mathbf{y} - Z' \mathbf{X} \beta) \\ &= \mathbf{y}' Z Z' \mathbf{y} - \mathbf{y}' Z Z' \mathbf{X} \beta - \beta' \mathbf{X}' Z Z' \mathbf{y} + \beta' \mathbf{X}' Z Z' \mathbf{X} \beta \end{aligned}$$

Derivando em relação em β e igualando a zero:

$$\begin{aligned} -2\mathbf{y}' Z Z' \mathbf{X} + 2\beta' \mathbf{X}' Z Z' \mathbf{X} &= 0 \\ \beta' \mathbf{X}' Z Z' \mathbf{X} &= \mathbf{y}' Z Z' \mathbf{X} \\ \beta' &= (\mathbf{y}' Z Z' \mathbf{X})(\mathbf{X}' Z Z' \mathbf{X})^{-1} \\ \boxed{\beta &= (\mathbf{X}' Z Z' \mathbf{X})^{-1}(\mathbf{X}' Z Z' \mathbf{y})} \end{aligned}$$

Um estimador mais eficiente pode ser encontrado fazendo:

$$\text{Min}_{\beta} E[(Z_i' \mathbf{y} - Z_i' \mathbf{X} \beta)' W (Z_i' \mathbf{y} - Z_i' \mathbf{X} \beta)].$$

Escolhendo \widehat{W} , a priori, temos:

$$\text{Min}_{\beta} \left\{ \mathbf{y}' Z \widehat{W} Z' \mathbf{y} - \mathbf{y}' Z \widehat{W} Z' \mathbf{X} \beta - \beta' \mathbf{X}' Z \widehat{W} Z' \mathbf{y} + \beta' \mathbf{X}' Z \widehat{W} Z' \mathbf{X} \beta \right\}$$

Derivando em relação em β e igualando a zero:

$$\begin{aligned} -2\mathbf{y}' Z \widehat{W} Z' \mathbf{X} + 2\beta' \mathbf{X}' Z \widehat{W} Z' \mathbf{X} &= 0 \\ \beta' \mathbf{X}' Z \widehat{W} Z' \mathbf{X} &= \mathbf{y}' Z \widehat{W} Z' \mathbf{X} \\ \beta' &= (\mathbf{y}' Z \widehat{W} Z' \mathbf{X})(\mathbf{X}' Z \widehat{W} Z' \mathbf{X})^{-1} \\ \boxed{\beta^{GMM} &= (\mathbf{X}' Z \widehat{W}' Z' \mathbf{X})^{-1}(\mathbf{X}' Z \widehat{W}' Z' \mathbf{y})} \end{aligned}$$

Valor Esperado

$$\boxed{E(\beta^{GMM}) = \beta + E[(\mathbf{X}' Z \widehat{W}' Z' \mathbf{X})^{-1}(\mathbf{X}' Z \widehat{W}' Z' \mathbf{u})]}.$$

Variância

$$\begin{aligned}\text{Var}(\beta^{GMM}) &= \text{E} \left\{ \left[(X'Z\widehat{W}'Z'X)^{-1}(X'Z\widehat{W}'Z'\mathbf{u}) \right] \left[(X'Z\widehat{W}'Z'X)^{-1}(X'Z\widehat{W}'Z'\mathbf{u}) \right]' \right\} \\ &= \text{E} \left\{ (X'Z\widehat{W}'Z'X)^{-1}X'Z\widehat{W}'Z'\mathbf{u}\mathbf{u}'Z\widehat{W}Z'X(X'Z\widehat{W}'Z'X)^{-1} \right\}.\end{aligned}$$

Definindo $\Delta = \text{E}(Z'\mathbf{u}\mathbf{u}'Z)$ com $\Delta = W^{-1}$:

$$\begin{aligned}\text{Var}(\beta^{GMM}) &= \text{E} \left\{ (X'Z\widehat{W}'Z'X)^{-1}X'Z\widehat{W}'W^{-1}\widehat{W}Z'X(X'Z\widehat{W}'Z'X)^{-1} \right\} \\ &= \text{E} \left\{ (X'Z\widehat{W}'Z'X)^{-1}(X'Z\widehat{W}'Z'X)(X'Z\widehat{W}'Z'X)^{-1} \right\}.\end{aligned}$$

$$\boxed{\text{Var}(\beta^{GMM}) = \text{E} \left[(X'Z\widehat{W}'Z'X)^{-1} \right]}.$$

Se tivéssemos definido $W = (Z'Z)^{-1}$, teríamos β^{2SLS} .

9 Random Effects (RE, EA)

Modelo

O modelo linear de **efeitos não observados**:

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + c_i + u_{it}, \quad (9.1)$$

onde $t = 1, \dots, T$ e $i = 1, \dots, N$.

O modelo contém explicitamente um componente não observado que não varia no tempo c_i . Abordamos esse componente como parte do erro, não como parâmetro a ser estimado. Para a análise de **Efeitos Aleatórios, (EA) ou (RE)**, supomos que as regressões \mathbf{x}_{it} são **não correlacionados** com c_i , mas fazemos hipóteses mais restritas que o **POLS**; pois assim exploramos a presença de **correlação serial** do erro composto por GLS e garantimos a consistência do estimador de FGLS.

Podemos reescrever (9.1) como:

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + v_{it}, \quad (9.2)$$

onde $t = 1, \dots, T$, $i = 1, \dots, N$ e $\boxed{v_{it} = c_i + u_{it}}$ é o erro composto.

Agora, vamos empilhar os t 's e reescrever (9.2) como:

$$\mathbf{y}_i = X_i\boldsymbol{\beta} + \mathbf{v}_i, \quad (9.3)$$

onde $i = 1, \dots, N$ e $\boxed{\mathbf{v}_i = c_i\mathbf{1}_T + \mathbf{u}_i}$.

Hipóteses de $\hat{\boldsymbol{\beta}}^{RE}$

As Hipóteses que usamos para $\hat{\boldsymbol{\beta}}^{RE}$ são:

1. Usamos o modelo correto e c_i não é endógeno.

- a) $E(u_{it} | x_{i1}, \dots, x_{iT}, c_i) = 0$, $i = 1, \dots, N$.
- b) $E(c_{it} | x_{i1}, \dots, x_{iT}) = E(c_i) = 0$, $i = 1, \dots, N$.

2. Posto completo de $E(X_i'\Omega^{-1}X_i)$.

Definindo a matriz $T \times T$, $\boxed{\Omega \equiv E(\mathbf{v}_i\mathbf{v}_i')}$, queremos que $E(X_i\Omega^{-1}X_i)$ tenha posto completo (posto = K).

A matriz Ω é simétrica $\Omega' = \Omega$ e positiva definida $\det(\Omega) > 0$. Assim podemos achar $\Omega^{1/2}$ e $\Omega^{-1/2}$ com $\Omega = \Omega^{1/2}\Omega^{1/2}$ e $\Omega^{-1} = \Omega^{-1/2}\Omega^{-1/2}$.

Estimação

Premultiplicando (9.3) por $\Omega^{-1/2}$ dos dois lados, temos:

$$\begin{aligned} \Omega^{-1/2}\mathbf{y}_i &= \Omega^{-1/2}X_i\boldsymbol{\beta} + \Omega^{-1/2}\mathbf{v}_i \\ \mathbf{y}_i^* &= X_i^*\boldsymbol{\beta} + \mathbf{v}_i^*, \end{aligned} \quad (9.4)$$

Estimando o modelo acima por POLS:

$$\begin{aligned}
\beta^{POLS} &= \left(\sum_{i=1}^N X_i^{*'} X_i^* \right)^{-1} \left(\sum_{i=1}^N X_i^{*'} \mathbf{y}_i^* \right) \\
&= \left(\sum_{i=1}^N X_i' \Omega^{-1} X_i \right)^{-1} \left(\sum_{i=1}^N X_i' \Omega^{-1} \mathbf{y}_i \right) \\
&= (X'(I_N \otimes \Omega^{-1})X)^{-1} (X'(I_N \otimes \Omega^{-1})\mathbf{y}).
\end{aligned} \tag{9.5}$$

O problema, agora, é estimar Ω . Supondo:

- $E(u_{it}u_{it}) = \sigma_u^2$;
- $E(u_{it}u_{is}) = 0$.

Como $\Omega = E(\mathbf{v}_i \mathbf{v}_i') = E[(c_i \mathbf{1}_T + \mathbf{u}_i)(c_i \mathbf{1}_T + \mathbf{u}_i)']$, temos que:

$$E(v_{it}v_{it}) = E(c_i^2 + 2c_i u_{it} + u_{it}^2) = \sigma_c^2 + \sigma_u^2$$

$$E(v_{it}v_{is}) = E[(c_i + u_{it})(c_i + u_{is})] = E(c_i^2 + c_i u_{is} + u_{it}c_i + u_{it}u_{is}) = \sigma_c^2.$$

Assim,

$$\Omega = E(\mathbf{v}_i \mathbf{v}_i') = \sigma_u^2 I_T + \sigma_c^2 \mathbf{1}_T \mathbf{1}_T'$$

onde $\sigma_u^2 I_T$ é uma matriz diagonal, e $\sigma_c^2 \mathbf{1}_T \mathbf{1}_T'$ é uma matriz com todos os elementos iguais a σ_c^2 .

Agora, rodando POLS em (9.3) e guardando os resíduos, temos:

$$\hat{v}_{it}^{POLS} = \hat{y}_{it}^{POLS} - \mathbf{x}_{it} \hat{\boldsymbol{\beta}}^{POLS}$$

e conseguimos estimar σ_v^2 e σ_c^2 por estimadores amostrais:

- como $\sigma_v^2 = E(v_{it}^2)$:

$$\hat{\sigma}_v^2 = (NT - K)^{-1} \sum_{i=1}^N \sum_{t=1}^T \hat{v}_{it}^2$$

- como $\sigma_c^2 = E(v_{it}v_{is})$:

$$\hat{\sigma}_c^2 = \left[N \frac{T(T-1)}{2} - K \right]^{-1} \sum_{i=1}^N \sum_{t=1}^{T-1} \sum_{s=t+1}^T \hat{v}_{it} \hat{v}_{is}$$

- N indivíduos;
- T elementos da diagonal principal de Ω
- $\frac{T(T-1)}{2}$ elementos da matriz triangular superior dos elementos fora da diagonal.
- K regressores.

Agora que temos $\hat{\sigma}_v^2$ e $\hat{\sigma}_c^2$ podemos achar $\hat{\sigma}_u^2$ pela equação $\boxed{\hat{\sigma}_u^2 = \hat{\sigma}_v^2 - \hat{\sigma}_c^2}$. Dessa forma, achamos os T^2 elementos de $\hat{\Omega}$, e podemos escrever:

$$\hat{\Omega} = \hat{\sigma}_u^2 I_T + \hat{\sigma}_c^2 \mathbf{1}_T \mathbf{1}_T'$$

Com $\hat{\Omega}$ estimado, reescrevemos (9.5) como:

$$\beta^{RE} = [X'(I_N \otimes \hat{\Omega}^{-1})X]^{-1} [X'(I_N \otimes \hat{\Omega}^{-1})\mathbf{y}]. \tag{9.6}$$

Valor Esperado

$$\boxed{E(\boldsymbol{\beta}^{RE}) = \boldsymbol{\beta} + \left[X'(I_N \otimes \hat{\Omega}^{-1})X \right]^{-1} \left[X'(I_N \otimes \hat{\Omega}^{-1})\mathbf{v} \right]}.$$

Variância

$$\text{Var}(\boldsymbol{\beta}^{RE}) = E \left\{ \left[X'(I_N \otimes \hat{\Omega}^{-1})X \right]^{-1} \left[X'(I_N \otimes \hat{\Omega}^{-1})\mathbf{v}\mathbf{v}'(I_N \otimes \hat{\Omega}^{-1})'X \right] \left[X'(I_N \otimes \hat{\Omega}^{-1})X \right] \right\},$$

como $E(\mathbf{v}_i\mathbf{v}_i') = \Omega$,

$$\boxed{\text{Var}(\boldsymbol{\beta}^{RE}) = E \left[X'(I_N \otimes \hat{\Omega}^{-1})X \right]}.$$

10 Fixed Effects (EF, FE)

Modelo

O modelo linear de **efeitos não observados**:

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + c_i + u_{it}, \quad (10.1)$$

onde $t = 1, \dots, T$ e $i = 1, \dots, N$.

O modelo contém explicitamente um componente não observado que não varia no tempo c_i . Abordamos esse componente como parte do erro, não como parâmetro a não observado. No caso da análise de **Efeitos Fixos (EF, FE)**, permitimos que esse componente c_i seja correlacionado com \mathbf{x}_{it} . Assim, se decidíssemos estimar o modelo (10.1) por POLS, ignorando c_i , teríamos problemas de inconsistência devido a **endogeneidade**.

As T equações do modelo (10.1) podem ser reescritas como:

$$\mathbf{y}_i = X_i\boldsymbol{\beta} + c_i\mathbf{1}_T + \mathbf{u}_i, \quad (10.2)$$

com $\mathbf{v}_i = c_i\mathbf{1}_T + \mathbf{u}_i$ sendo os erros compostos.

Matriz M^0

Definimos a matriz M^0 como:

$$M^0 = I_T - T^{-1}\mathbf{1}_T\mathbf{1}_T' = I_T - \mathbf{1}_T(\mathbf{1}_T'\mathbf{1}_T)^{-1}\mathbf{1}_T'.$$

A matriz M^0 é idempotente e simétrica.

$$M^0\mathbf{x} = \mathbf{x} - \bar{\mathbf{x}}\mathbf{1}_T = \ddot{\mathbf{x}}.$$

Podemos transformar o modelo (10.3) ao premultiplicarmos todo o modelo por M^0 .

$$M^0\mathbf{y}_i = M^0X_i\boldsymbol{\beta} + M^0(c_i\mathbf{1}_T) + M^0\mathbf{u}_i, \quad i = 1, \dots, N.$$

$$M^0(c_i\mathbf{1}_T) = (I_T - T^{-1}\mathbf{1}_T\mathbf{1}_T')c_i\mathbf{1}_T = c_i\mathbf{1}_T - T^{-1}c_i\mathbf{1}_T\mathbf{1}_T'\mathbf{1}_T = c_i\mathbf{1}_T - c_i\mathbf{1}_T \implies \boxed{M^0(c_i\mathbf{1}_T) = 0}$$

$$\ddot{\mathbf{y}}_i = \ddot{X}_i\boldsymbol{\beta} + \ddot{\mathbf{u}}_i, \quad i = 1, \dots, N. \quad (10.3)$$

Estimação POLS

Aplicando POLS no modelo (10.3)

$$\boxed{\boldsymbol{\beta}^{FE} = \left[\sum_{i=1}^N \ddot{X}_i'\ddot{X}_i \right]^{-1} \left[\sum_{i=1}^N \ddot{X}_i'\ddot{\mathbf{y}}_i \right]} \quad (10.4)$$

Hipóteses

As Hipóteses que usamos para $\hat{\boldsymbol{\beta}}^{FE}$ são:

FE.1: Exogeneidade Estrita: $E(u_{it} | \mathbf{x}_{i1}, \dots, \mathbf{x}_{iT}, c_i) = 0$, para $t = 1, \dots, T$ e $i = 1, \dots, N$.

FE.2: Posto completo de $E(X_i'\Omega^{-1}X_i)$ (para inverter a matriz). $\text{posto}[E(X_i'\Omega^{-1}X_i)] = K$.

FE.3: Homoscedasticidade: $E(\mathbf{u}_i\mathbf{u}_i' | X_i, c_i) = \sigma_u^2 I_T$.

Valor Esperado

Usando **FE.1** e **FE.2**, apenas.

$$E(\beta^{FE}) = \beta + E \left[\left(\sum_{i=1}^N \ddot{X}'_i \ddot{X}_i \right)^{-1} \left(\sum_{i=1}^N \ddot{X}'_i \ddot{u}_i \right) \right]$$

$$E(\beta^{FE}) = \beta + E \left[(\ddot{X}' \ddot{X})^{-1} (\ddot{X}' \ddot{u}) \right]$$

Sabendo que $\ddot{X} = (I_N \otimes M^0)X$ e $\ddot{u} = (I_N \otimes M^0)u$, definimos:

$$E(\beta^{FE}) = \beta + E \left\{ [X'(I_N \otimes M^0)(I_N \otimes M^0)X]^{-1} [X'(I_N \otimes M^0)(I_N \otimes M^0)u] \right\}$$

$$E(\beta^{FE}) = \beta + E \left\{ [X'(I_N \otimes M^0)X]^{-1} [X'(I_N \otimes M^0)u] \right\}$$

Variância

Usamos a variância do estimador para inferência. Usando **FE.1** e **FE.2**, apenas:

$$\text{Var}(\beta^{FE}) = E \left[(\ddot{X}' \ddot{X})^{-1} (\ddot{X}' \ddot{u}) (\ddot{u}' \ddot{X}) (\ddot{X}' \ddot{X})^{-1} \right]$$

Pão:

$$\begin{aligned} E \left[(\ddot{X}' \ddot{X})^{-1} \right] &= E \left\{ [X'(I_N \otimes M^0)(I_N \otimes M^0)X]^{-1} \right\} \\ &= E \left\{ [X'(I_N \otimes M^0)X]^{-1} \right\} \end{aligned}$$

Recheio:

$$\begin{aligned} E \left[(\ddot{X}' \ddot{u}) (\ddot{u}' \ddot{X}) \right] &= E \left[X'(I_N \otimes M^0)(I_N \otimes M^0)u u'(I_N \otimes M^0)(I_N \otimes M^0)X \right] \\ &= E \left[X'(I_N \otimes M^0)u u'(I_N \otimes M^0)X \right] \end{aligned}$$

$$\text{Var}(\beta^{FE}) = \text{Pão Recheio Pão}$$

$$\text{Var}(\beta^{FE}) = E \left\{ [X'(I_N \otimes M^0)X]^{-1} \right\} E \left[X'(I_N \otimes M^0)u u'(I_N \otimes M^0)X \right] E \left\{ [X'(I_N \otimes M^0)X]^{-1} \right\}$$

Variância sob Homocedasticidade

Usando **FE.3**, temos

Recheio':

$$E \left[X'(I_N \otimes M^0) \right] \sigma_u^2 I_{NT} E \left[(I_N \otimes M^0)X \right] = \sigma_u^2 E \left[X'(I_N \otimes M^0)X \right]$$

$(I_N \otimes M^0)$ é uma matrix de dimensão $NT \times NT$, visto que I_N é $N \times N$ e M^0 é $T \times T$.

$$\text{Var}(\beta^{FE}) = \text{Pão Recheio' Pão}$$

$$\begin{aligned} &= E \left\{ [X'(I_N \otimes M^0)X]^{-1} \right\} \sigma_u^2 E \left[X'(I_N \otimes M^0)X \right] E \left\{ [X'(I_N \otimes M^0)X]^{-1} \right\} \\ &= E \left\{ [X'(I_N \otimes M^0)X]^{-1} \right\} \sigma_u^2 I_{NT} \end{aligned}$$

$$\text{Var}(\beta^{FE}) = \sigma_u^2 \cdot E \left[X'(I_N \otimes M^0)X \right]$$

11 First Difference (FD, PD)

Modelo

O modelo linear de **efeitos não observados**:

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + c_i + u_{it}, \quad (11.1)$$

para $t = 1, \dots, T$ e $i = 1, \dots, N$.

O modelo contém explicitamente um componente não observado, c_i , que não varia no tempo. Tratamos o componente não observado como parte do erro, não como parâmetro a ser estimado. Aqui permitimos que c_i seja correlacionado com \mathbf{x}_{it} . Deste modo, **não** podemos ignorar a sua presença e estimar (11.1) por POLS, visto que isso resultaria num estimador inconsistente devido a **endogeneidade**.

Assim, transformamos o modelo para eliminar c_i e conseguirmos fazer uma estimação consistente de $\boldsymbol{\beta}$. A transformação a ser feita é a primeira diferença. Para tanto, seguimos os seguintes passos:

- Reescrevemos (11.1) defasado:

$$y_{it-1} = \mathbf{x}_{it-1}\boldsymbol{\beta} + c_i + u_{it-1} \quad (11.2)$$

- Tiramos a diferença entre (11.2) e (11.1):

$$\begin{aligned} y_{it} - y_{it-1} &= (\mathbf{x}_{it} - \mathbf{x}_{it-1})\boldsymbol{\beta} + c_i - c_i + u_{it} - u_{it-1} \\ \Delta y_{it} &= \Delta \mathbf{x}_{it}\boldsymbol{\beta} + \Delta u_{it}. \end{aligned} \quad (11.3)$$

para $t = 2, \dots, T$ e $i = 1, \dots, N$.

Reescrevendo (11.3) no formato matricial empilhando T :

$$\Delta \mathbf{y}_i = \Delta \mathbf{X}_i \boldsymbol{\beta} + \mathbf{e}_i \quad (11.4)$$

com $\boxed{e_{it} = \Delta u_{it}}$.

- $\Delta \mathbf{y}_i$ vetor $(T-1) \times 1$
- $\Delta \mathbf{X}_i$ matriz $(T-1) \times K$
- $\boldsymbol{\beta}$ vetor $K \times 1$
- \mathbf{e}_i vetor $(T-1) \times 1$

Estimação POLS

O estimador $\hat{\boldsymbol{\beta}}^{FD}$ é o POLS da regressão no modelo (11.4), assim:

$$\boxed{\boldsymbol{\beta}^{FD} = \left[\sum_{i=1}^N \Delta \mathbf{X}_i' \Delta \mathbf{X}_i \right]^{-1} \left[\sum_{i=1}^N \Delta \mathbf{X}_i' \Delta \mathbf{y}_i \right]} \quad (11.5)$$

Hipóteses

As Hipóteses que usamos para $\hat{\boldsymbol{\beta}}^{FD}$ são:

FD.1: Exogeneidade Estrita: $E(u_{it} | \mathbf{x}_{i1}, \dots, \mathbf{x}_{iT}, c_i) = 0$, para $t = 1, \dots, T$ e $i = 1, \dots, N$.

FD.2: Posto completo de $E(\Delta \mathbf{X}_i' \Delta \mathbf{X}_i)$ (para inverter a matriz). *posto* $[E(\Delta \mathbf{X}_i' \Delta \mathbf{X}_i)] = K$.

FD.3: Homoscedasticidade: $E(\mathbf{e}_i \mathbf{e}_i' | \mathbf{X}_i, c_i) = \sigma_e^2 I_{T-1}$.

Valor Esperado

Usando apenas **FD.1** e **FD.2**:

$$E(\beta^{FD}) = \beta + E \left[\left(\sum_{i=1}^N \Delta X_i' \Delta X_i \right)^{-1} \left(\sum_{i=1}^N \Delta X_i' e_i \right) \right]$$

$$\boxed{E(\beta^{FD}) = \beta + E \left[(\Delta X' \Delta X)^{-1} (\Delta X' e) \right]}$$

Variância

Usando apenas **FD.1** e **FD.2**:

$$\boxed{\text{Var}(\beta^{FD}) = E \left[(\Delta X' \Delta X)^{-1} (\Delta X' e e' \Delta X) (\Delta X' \Delta X)^{-1} \right]}$$

Variância sob Homocedasticidade

Usando **FD.3**, temos

$$\text{Var}(\beta^{FD}) = \sigma_e^2 E \left[(\Delta X' \Delta X)^{-1} (\Delta X' \Delta X) (\Delta X' \Delta X)^{-1} \right]$$

$$\boxed{\text{Var}(\beta^{FD}) = \sigma_e^2 E \left[(\Delta X' \Delta X)^{-1} \right]}$$

com

$$\sigma_e^2 = [N(T-1) - K]^{-1} \left[\sum_{i=1}^N \sum_{t=1}^T \hat{e}_{it}^2 \right],$$

que é a média de todos \hat{e}_{it}^2 contando K regressores.

12 Exogeneidade Estrita e FDIV

Modelo

No seguinte modelo

$$y_{it} = \mathbf{x}_{it}\boldsymbol{\beta} + u_{it},$$

para $t = 1, \dots, T$ e $i = 1, \dots, N$.

- y_{it} escalar;
- \mathbf{x}_{it} vetor $1 \times K$;
- $\boldsymbol{\beta}$ vetor $K \times 1$;
- u_{it} escalar.

$\{x_{it}\}$ é estritamente **exógeno** se valer:

$$E(u_{it} | \mathbf{x}_{i1}, \dots, \mathbf{x}_{iT}) = 0, \quad t = 1, \dots, T$$

ou seja:

$$E(y_{it} | \mathbf{x}_{i1}, \dots, \mathbf{x}_{iT}) = \mathbf{x}_{it}\boldsymbol{\beta}, \quad t = 1, \dots, T$$

o que é equivalente a hipótese de que utilizamos o modelo linear correto.

Para o seguinte modelo:

$$y_{it} = \mathbf{z}_{it}\boldsymbol{\gamma} + \rho y_{it-1} + c_i + u_{it}, \quad t = 2, \dots, T$$

é **impossível** termos exogeneidade estrita. Isso porque, nesse modelo, de efeitos não observados temos:

$$E(y_{it} | \mathbf{z}_{i1}, \dots, \mathbf{z}_{iT}, y_{it-1}, c_i) \neq 0.$$

Isso ocorre porque, y_{it} é afetado por y_{it-1} que contribui para y_{it} com, pelo menos, ρc_i .

$$\left. \begin{aligned} y_{it} &= \mathbf{z}_{it}\boldsymbol{\gamma} + \rho y_{it-1} + c_i + u_{it} \\ y_{it-1} &= \mathbf{z}_{it-1}\boldsymbol{\gamma} + \rho y_{it-2} + c_i + u_{it-1} \end{aligned} \right\} \implies y_{it} = \mathbf{z}_{it}\boldsymbol{\gamma} + \rho(\mathbf{z}_{it-1}\boldsymbol{\gamma} + \rho y_{it-2} + c_i + u_{it-1}) + c_i + u_{it}.$$

Para eliminarmos este efeito, podemos tirar a primeira diferença do modelo:

$$y_{it} - y_{it-1} = (\mathbf{z}_{it} - \mathbf{z}_{it-1})\boldsymbol{\gamma} + \rho(y_{it-1} - y_{it-2}) + (c_i - c_i) + (u_{it} - u_{it-1})$$

$\Delta y_{it} = \Delta \mathbf{z}_{it}\boldsymbol{\gamma} + \rho \Delta y_{it-1} + \Delta u_{it}, \quad t = 3, \dots, T$

(12.1)

Estimação

Não podemos estimar o modelo (12.1) por POLS, uma vez que $Cov(\Delta y_{it-1}, \Delta u_{it}) \neq 0$. Como saída, podemos estimar por P2SLS, usando instrumentos para Δy_{it-1} (alguns instrumentos para Δy_{it-1} são $y_{it-2}, y_{it-3}, \dots, y_{i1}$).

P2SLS

$$y_{it} = \mathbf{x}_{it}'\boldsymbol{\beta} + u_{it}$$

- $i = 1, \dots, N$
- $t = 1, \dots, T$
- y_{it} escalar;
- \mathbf{x}_{it} vetor $K \times 1$;
- $\boldsymbol{\beta}$ vetor $K \times 1$;
- u_{it} escalar.

$$\boxed{\boldsymbol{\beta}^{P2SLS} = (X'P_ZX)^{-1}(X'P_Z\mathbf{y})}$$

com

$$\boxed{P_Z = Z'(Z'Z)^{-1}Z}$$

onde P_Z é a matriz de projeção em Z .

FDIV

$$y_{it} = \mathbf{x}_{it}'\boldsymbol{\beta} + c_i + u_{it}, \quad i = 1, \dots, N, \quad t = 1, \dots, T$$

$$\Delta y_{it} = \Delta \mathbf{x}_{it}'\boldsymbol{\beta} + \Delta u_{it}, \quad i = 1, \dots, N, \quad t = 2, \dots, T$$

Vamos supor $\Delta \mathbf{x}_{it}'$ tem variável endógena (y_{it} , no caso). \mathbf{w}_{it} é um vetor $1 \times L_t$ de instrumentos, onde $L_t \geq K$. Se os instrumentos forem diferentes:

$$W_i = \text{diag}(\mathbf{w}_{i2}', \mathbf{w}_{i3}', \dots, \mathbf{w}_{iT}')$$

onde W_i é uma matriz $(T-1) \times L$

$$L = L_2 + L_3 + \dots + L_T$$

Hipóteses

FDIV.1: $E(\mathbf{w}_{it}\Delta u_{it})$ para $i = 1, \dots, N, t = 2, \dots, T$.

FDIV.2: $Posto[E(W_i'W_i)] = L$

FDIV.3: $Posto[E(W_i'\Delta X_i)] = K$

Estimação FDIV

$$\boxed{\boldsymbol{\beta}^{FDIV} = (\Delta X'P_W\Delta X)^{-1}(\Delta X'P_W\Delta \mathbf{y})}$$

$$\boxed{P_W = W(W'W)^{-1}W'}$$

Valor Esperado

$$E(\boldsymbol{\beta}^{FDIV}) = \boldsymbol{\beta} + (\Delta X'P_W\Delta X)^{-1}(\Delta X'P_W\mathbf{e})$$

Variância

$$\begin{aligned}
\text{Var}(\boldsymbol{\beta}^{FDIV}) &= \text{E} \left\{ [\text{E}(\boldsymbol{\beta}^{FDIV}) - \boldsymbol{\beta}] [\text{E}(\boldsymbol{\beta}^{FDIV}) - \boldsymbol{\beta}]' \right\} \\
&= \text{E} \left\{ [\Delta X' P_W \Delta X]^{-1} [\Delta X' P_W \mathbf{e}] [\Delta X' P_W \mathbf{e}]' [\Delta X' P_W \Delta X]^{-1} \right\} \\
&= \text{E} \left[(\Delta X' P_W \Delta X)^{-1} (\Delta X' P_W \mathbf{e} \mathbf{e}' P_W \Delta X) (\Delta X' P_W \Delta X)^{-1} \right]
\end{aligned}$$

$$e_i = \Delta u_{it}.$$

13 Latent Variables, Probit and Logit

Modelo

Suponha y^* não observável (**latente**) seguindo o seguinte modelo:

$$y_i^* = \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i. \quad (13.1)$$

Defina y como:

$$y_i = \begin{cases} 1, & y_i^* \geq 0 \\ 0, & y_i^* < 0 \end{cases}$$

temos que:

$$P(y_i = 1 | \mathbf{x}) = p(\mathbf{x})$$

$$P(y_i = 0 | \mathbf{x}) = 1 - p(\mathbf{x}).$$

Além disso, pela definição de y_i , equação (13.1), temos:

$$\begin{aligned} P(y_i = 1 | \mathbf{x}) &= P(y_i^* \geq 0 | \mathbf{x}) \\ &= P(\mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i \geq 0 | \mathbf{x}) \\ &= P(\varepsilon_i \geq -\mathbf{x}_i' \boldsymbol{\beta} | \mathbf{x}). \end{aligned}$$

Agora, supondo que ε_i tem FDA, G , tal que $G' = g$ é simétrica ao redor de zero:

$$\begin{aligned} P(y_i = 1 | \mathbf{x}) &= 1 - P(\varepsilon_i < -\mathbf{x}_i' \boldsymbol{\beta} | \mathbf{x}) \\ &= 1 - G(-\mathbf{x}_i' \boldsymbol{\beta} | \mathbf{x}) \\ &= G(\mathbf{x}_i' \boldsymbol{\beta}). \end{aligned}$$

Se $G(\cdot)$ for uma distribuição:

Normal Padrão: $\hat{\boldsymbol{\beta}}$ é o estimador **probit**.

Logística: $\hat{\boldsymbol{\beta}}$ é o estimador **logit**.

Supondo $\mathbf{y}_i | \mathbf{x} \sim \text{Bernoulli}(p(\mathbf{x}))$, sua fmp é dada por:

$$f(y_i | \mathbf{x}_i; \boldsymbol{\beta}) = [G(\mathbf{x}_i' \boldsymbol{\beta})]^{y_i} [1 - G(\mathbf{x}_i' \boldsymbol{\beta})]^{1-y_i}, \quad y = 0, 1.$$

Para estimarmos $\hat{\boldsymbol{\beta}}$ por máxima verossimilhança, temos de encontrar $\boldsymbol{\beta} \in B$, onde B é o espaço paramétrico, tal que $\boldsymbol{\beta}$ maximize o valor da distribuição conjunta de \mathbf{y} , ou seja:

$$\text{Max}_{\boldsymbol{\beta} \in B} \prod_{i=1}^N f(y_i | \mathbf{x}_i; \boldsymbol{\beta}).$$

Tirando o logaritmo e dividindo tudo por N (podemos fazer isso pois são transformações monotônicas e não alteram o lugar onde $\boldsymbol{\beta}$ ótimo irá parar):

$$\text{Max}_{\boldsymbol{\beta} \in B} \left\{ N^{-1} \sum_{i=1}^N \ln [f(y_i | \mathbf{x}_i; \boldsymbol{\beta})] \right\}.$$

Podemos definir $\ell_i(\boldsymbol{\beta}) = \ln[f(y_i | \mathbf{x}_i; \boldsymbol{\beta})]$ como sendo a verossimilhança condicional da observação i :

$$\max_{\beta \in B} \left\{ N^{-1} \sum_{i=1}^N \ell_i(\beta) \right\}.$$

Dessa forma, podemos ver que o problema acima é a analogia amostral de:

$$\max_{\beta \in B} E[\ell_i(\beta)].$$

Definindo o *vector score* da observação i :

$$s_i(\beta) = [\nabla_{\beta} \ell_i(\beta)]' = \left[\frac{\partial \ell_i(\beta)}{\partial \beta_1}, \dots, \frac{\partial \ell_i(\beta)}{\partial \beta_K} \right]$$

Definindo a **Matriz Hessiana** da observação i :

$$H_i(\beta) = \nabla_{\beta} s_i(\beta) = \nabla_{\beta}^2 \ell_i(\beta)$$

Tendo essas definições, o **Teorema do Valor Médio** (TVM) nos diz que no intervalo $[a, b]$, existe um número, c , tal que:

$$f'(c) = \frac{f(b) - f(a)}{b - a}.$$

FAZER DESENHO

Trocando $f(\cdot)$ por $s_i(\cdot)$, a por β_0 , b por $\hat{\beta}$ e c por $\bar{\beta}$, temos:

$$H_i(\bar{\beta}) = \frac{s_i(\hat{\beta}) - s_i(\beta_0)}{\hat{\beta} - \beta_0},$$

tirando médias dos dois lados:

$$N^{-1} \sum_{i=1}^N H_i(\bar{\beta}) = \frac{1}{\hat{\beta} - \beta_0} N^{-1} \sum_{i=1}^N [s_i(\hat{\beta}) - s_i(\beta_0)]$$

Supondo que $\hat{\beta}$ maximiza $\ell(\beta | \mathbf{y}, \mathbf{x})$, temos que: $N^{-1} \sum_{i=1}^N s_i(\hat{\beta}) = 0$. E podemos reescrever a equação anterior como:

$$\begin{aligned} \hat{\beta} - \beta_0 &= (-1) \left[N^{-1} \sum_{i=1}^N H_i(\bar{\beta}) \right]^{-1} N^{-1} \sum_{i=1}^N s_i(\beta_0) \\ \sqrt{N}(\hat{\beta} - \beta_0) &= \left[-N^{-1} \sum_{i=1}^N H_i(\bar{\beta}) \right]^{-1} \sqrt{N} \cdot N^{-1} \sum_{i=1}^N s_i(\beta_0) \\ \sqrt{N}(\hat{\beta} - \beta_0) &= \left[-N^{-1} \sum_{i=1}^N H_i(\bar{\beta}) \right]^{-1} N^{-1/2} \sum_{i=1}^N s_i(\beta_0). \end{aligned}$$

Onde

$$\left[-N^{-1} \sum_{i=1}^N H_i(\bar{\beta}) \right]^{-1} \xrightarrow{p} A_0^{-1}, \quad N^{-1/2} \sum_{i=1}^N s_i(\beta_0) \xrightarrow{d} N(0, B_0).$$

Assim, temos que:

$$\sqrt{N}(\hat{\beta} - \beta_0) \rightarrow N(0, A_0^{-1} B_0 A_0^{-1}).$$

A forma mais simples de achar $\text{Var}(\hat{\beta})$ é:

$$\text{Var}(\hat{\beta}) = -E[H_i(\hat{\beta})]^{-1}.$$

14 ATT, ATE, Propensity Score

Modelo

- $y_1 \rightarrow$ variável de interesse com tratamento
- $y_0 \rightarrow$ variável de interesse sem tratamento

$$w = \begin{cases} 1 & \text{se tratam} \\ 0 & \text{se não tratam} \end{cases}$$

Idealmente, para isolarmos completamente o efeito de $w = 1$, gostaríamos de poder calcular:

$$N^{-1} \sum_{i=1}^N (y_{i1} - y_{i0}).$$

Ou seja, o efeito que o tratamento causa sobre um indivíduo com todo o resto permanecendo constante. Em outras palavras, queríamos que houvesse dois mundos paralelos observáveis onde seria possível observar o que acontece com y_i com e sem tratamento. Infelizmente, para cada indivíduo i , observamos apenas y_{i1} ou y_{i0} , nunca ambos.

Antes de continuarmos, faremos as seguintes definições:

ATE: $E(y_1 - y_0)$

ATT: $E(y_1 - y_0 | w = 1)$ (ATE no tratado).

ATE e ATT condicional a variáveis \mathbf{x}

$$ATE(\mathbf{x}) = E(y_1 - y_0 | \mathbf{x})$$

$$ATT(\mathbf{x}) = E(y_1 - y_0 | \mathbf{x}, w = 1)$$

OBS:

$$E(y_1 - y_0) = E[E(y_1 - y_0 | w)]$$

$$E(y_1 - y_0 | w) = E(y_1 - y_0 | w = 0) \cdot P(w = 0) + E(y_1 - y_0 | w = 1) \cdot P(w = 1).$$

Métodos Assumindo Ignorabilidade do Tratamento

ATE.1: Ignorabilidade.

w e (y_1, y_0) são independentes condicionais a \mathbf{x} .

ATE.1': Ignorabilidade da Média.

$$\text{a) } E(y_0 | w, \mathbf{x}) = E(y_0 | \mathbf{x})$$

$$\text{b) } E(y_1 | w, \mathbf{x}) = E(y_1 | \mathbf{x})$$

Vamos definir

$$E(y_0 | \mathbf{x}) = \mu_0(\mathbf{x})$$

$$E(y_1 | \mathbf{x}) = \mu_1(\mathbf{x}).$$

Sob **ATE.1** e **ATE.1'**:

$$ATE(\mathbf{x}) = E(y_1 - y_0 | \mathbf{x}) = \mu_1(\mathbf{x}) - \mu_0(\mathbf{x})$$

$$ATT(\mathbf{x}) = E(y_1 - y_0 | \mathbf{x}, w = 1) = \mu_1(\mathbf{x}) - \mu_0(\mathbf{x})$$

ATE.2: Overlap

Para todo \mathbf{x} , $P(w = 1 | \mathbf{x}) \in (0, 1)$, $p(\mathbf{x}) = p(w = 1 | \mathbf{x})$.

$p(\mathbf{x})$ é o *Propensity Score*, ele representa a probabilidade de y_i ser tratado dado o valor das covariáveis \mathbf{x} . Essa hipótese é importante visto que podemos expressar o *ATE* em função de $p(\mathbf{x})$.

Para o *ATT* vamos supor:

ATT.1': $E(y_0 | \mathbf{x}, w) = E(y_0 | \mathbf{x})$

ATT.2: Overlap: Para todo \mathbf{x} , $P(w = 1 | \mathbf{x}) < 1$.

Propensity Score

Como foi dito anteriormente, apenas observamos ou y_1 ou y_0 para a mesma pessoa, mas não ambos. Mais precisamente, junto com w , o resultado observado é:

$$y = wy_1 + (1 - w)y_0$$

como w é binário, $w^2 = w$, assim, temos:

$$\begin{aligned} wy &= w^2y_1 + (w - w^2)y_0 \implies \boxed{wy = wy_1} \\ (1 - w)y &= (w - w^2)y_1 + (w^2 - 2w + 1)y_0 \implies \boxed{(1 - w)y = (1 - w)y_0}. \end{aligned}$$

Fazemos isso para tentar isolar $\mu_0(\mathbf{x})$ e $\mu_1(\mathbf{x})$:

$$\mu_1(\mathbf{x})$$

$$\begin{aligned} E(wy | \mathbf{x}) &= E[E(wy_1 | \mathbf{x}, w) | \mathbf{x}] \\ &= E[w\mu_1(\mathbf{x}) | \mathbf{x}] \\ &= \mu_1(\mathbf{x})E(w | \mathbf{x}). \end{aligned}$$

Como w é binária: $E(w | \mathbf{x}) = P(w = 1 | \mathbf{x}) = p(\mathbf{x})$. Assim:

$$E(wy | \mathbf{x}) = \mu_1(\mathbf{x})p(\mathbf{x})$$

$$\boxed{\mu_1(\mathbf{x}) = \frac{E(wy | \mathbf{x})}{p(\mathbf{x})}}$$

$$\mu_0(\mathbf{x})$$

$$\begin{aligned} E[(1 - w)y | \mathbf{x}] &= E[E((1 - w)y_0 | \mathbf{x}, w) | \mathbf{x}] \\ &= E[(1 - w)\mu_0(\mathbf{x}) | \mathbf{x}] \\ &= \mu_0(\mathbf{x})E(w | \mathbf{x}) \end{aligned}$$

$$E[(1 - w)y | \mathbf{x}] = \mu_0(\mathbf{x})[1 - p(\mathbf{x})] \implies$$

$$\boxed{\mu_0(\mathbf{x}) = \frac{E[(1 - w)y | \mathbf{x}]}{1 - p(\mathbf{x})}}$$

ATE:

$$\mu_1(\mathbf{x}) - \mu_0(\mathbf{x}) = E \left[\frac{[w - p(\mathbf{x})]y}{p(\mathbf{x})[1 - p(\mathbf{x})]} | \mathbf{x} \right]$$

$$\boxed{\widehat{ATE} = N^{-1} \sum_{i=1}^N \frac{[w_i - p(\mathbf{x}_i)]y_i}{p(\mathbf{x}_i)[1 - p(\mathbf{x}_i)]}}$$

ATT:

$$E(y_1|\mathbf{x}, w = 1) - E(y_0|\mathbf{x}) = \frac{1}{\hat{P}(w = 1)} E \left[\frac{[w - \hat{p}(\mathbf{x})]y}{[1 - \hat{p}(\mathbf{x})]} | \mathbf{x} \right]$$

$$\hat{P}(w = 1) = N^{-1} \sum_{i=1}^N w_i$$

$$\widehat{ATT} = \frac{N}{\sum_{i=1}^N w_i} N^{-1} \sum_{i=1}^N \frac{[w_i - \hat{p}(\mathbf{x}_i)]y_i}{[1 - \hat{p}(\mathbf{x}_i)]}$$

$$\boxed{\widehat{ATT} = \frac{1}{\sum_{i=1}^N w_i} \sum_{i=1}^N \frac{[w_i - \hat{p}(\mathbf{x}_i)]y_i}{[1 - \hat{p}(\mathbf{x}_i)]}}$$

Appêndice

Sums of Values

(Greene, 2012, p. 977, A.2.7)

$$\mathbf{1}'_N \mathbf{1}_N = N \quad ; \quad \mathbf{1}_N \mathbf{1}'_N = \begin{bmatrix} 1 & \dots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \dots & 1 \end{bmatrix}_{N \times N}$$

Defining \mathbf{x} with dimension $1 \times N$:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_N \end{bmatrix}$$

$$\mathbf{x}' \mathbf{1}_N = \mathbf{1}'_N \mathbf{x} = (\mathbf{x}' \mathbf{1}_N)' = \sum_{i=1}^N x_i$$

$$\mathbf{1}_N \mathbf{x}' = \begin{bmatrix} x_1 & \dots & x_N \\ \vdots & \ddots & \vdots \\ x_1 & \dots & x_N \end{bmatrix}_{N \times N} \quad ; \quad \mathbf{x} \mathbf{1}'_N = \begin{bmatrix} x_1 & \dots & x_1 \\ \vdots & \ddots & \vdots \\ x_N & \dots & x_N \end{bmatrix}_{N \times N}$$

$$E(\mathbf{x}) = \bar{\mathbf{x}} = N^{-1} \sum_{i=1}^N x_i = N^{-1} \mathbf{x}' \mathbf{1}_N$$

Important Idempotent Matrices

(Greene, 2012, p. 978, A.28)

Centering Matrix

$$M^0 = I_N - \mathbf{1}_N (\mathbf{1}'_N \mathbf{1}_N)^{-1} \mathbf{1}'_N = I_N - N^{-1} \mathbf{1}_N \mathbf{1}'_N$$

A Matriz M^0 é **idempotente** e **simétrica**.

Idempotência: $AA = A$

Simetria: $A' = A$

$$M^0 \mathbf{x} = (I_N - N^{-1} \mathbf{1}_N \mathbf{1}'_N) \mathbf{x} = \mathbf{x} - N^{-1} \mathbf{1}_N (\mathbf{1}'_N \mathbf{x}) = \mathbf{1}_N \bar{\mathbf{x}} = \begin{bmatrix} \bar{\mathbf{x}} \\ \vdots \\ \bar{\mathbf{x}} \end{bmatrix}$$

$$M^0 \mathbf{1} = (I_N - N^{-1} \mathbf{1}_N \mathbf{1}'_N) \mathbf{1}_N = \mathbf{1}_N - N^{-1} \mathbf{1}_N (\mathbf{1}'_N \mathbf{1}_N) = \mathbf{0}_N$$

15 Conceitos Básicos de Convergência Estatística

Definition 15.1 (Estimador Consistente). Um estimador $\hat{\theta}$ é **consistente** para um parâmetro θ se

$$\hat{\theta} \xrightarrow{p} \theta.$$

Definition 15.2 (Convergência em Probabilidade). Uma sequência de variáveis aleatórias: $\{X_n\}_{n \geq 1}$ **converge em probabilidade** para uma variável aleatória X se, dado $\varepsilon > 0$,

$$P(|X_n - X| > \varepsilon) \rightarrow 0,$$

quando $n \rightarrow +\infty$. E denotamos

$$X_n \xrightarrow{p} X.$$

Definition 15.3 (Desigualdade de Markov). Seja $\{X_n\}_{n \geq 1}$ uma sequência de variáveis aleatórias com $E|X_n|^K < +\infty$, $K > 0$. Então, dado $\varepsilon > 0$

$$P(|X_n| > \varepsilon) \leq \frac{E|X_n|^K}{\varepsilon^K}$$

Definition 15.4.

$$0 \leq P(|\hat{\theta} - \theta| > \varepsilon) \leq \frac{E|X_n|^2}{\varepsilon^2}$$

Definition 15.5 (Erro Quadrático Médio).

$$EQM(\hat{\theta}) = E \left[\left(\hat{\theta} - \theta \right)^2 \right] = \left[Bias(\hat{\theta})^2 + Var(\hat{\theta}) \right]$$

Então, se $Bias(\hat{\theta}) \rightarrow 0$ e $Var(\hat{\theta}) \rightarrow 0$, temos que $EQM(\hat{\theta}) \rightarrow 0$. Pelo **Teorema do Sanduíche**, $P(|\hat{\theta} - \theta| > \varepsilon) \rightarrow 0$; logo, $\hat{\theta} \xrightarrow{p} \theta$.

Definition 15.6 (LGN – Lei dos Grandes Números). Seja $\{X_i\}_{i \geq 1}$ uma sequência de variáveis aleatórias *iid* com $E(X_i) = \mu$. Então,

$$N^{-1} \sum_{i=1}^N X_i \xrightarrow{p} \mu.$$

Definition 15.7 (LGN – Caso Matricial). Seja $\{\mathbf{x}_i\}_{i=1}^N$, uma sequência *iid* de vetores aleatórios $K \times 1$ com $E(\mathbf{x}_i \mathbf{x}_i') = Q_{K \times K}$ finita. Então,

$$N^{-1} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i' \xrightarrow{p} Q.$$

Se Q for positiva definida, Q terá inversa.

Multiplicação de Matriz

$$A_{2 \times 2} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \quad B_{2 \times 3} = \begin{bmatrix} b_{11} & b_{12} & b_{13} \\ b_{21} & b_{22} & b_{23} \end{bmatrix}$$

$$[AB]_{2 \times 3} = \begin{bmatrix} a_{11} \\ a_{21} \end{bmatrix} \begin{bmatrix} b_{11} & b_{12} & b_{13} \end{bmatrix} + \begin{bmatrix} a_{12} \\ a_{22} \end{bmatrix} \begin{bmatrix} b_{21} & b_{22} & b_{23} \end{bmatrix} \implies AB = \sum_{i=1}^2 a_i b_i$$

onde a_i é a i -ésima **coluna** da matriz A . b_i é a i -ésima **linha** da matriz B .

Definition 15.8.

$$P(|X_n - X| > \varepsilon) \rightarrow 0$$

$$X_n - X \xrightarrow{p} 0$$

$$X_n \xrightarrow{p} X$$

Definition 15.9 (o_p).

$$X_n = o_p(1) \implies X_n \xrightarrow{p} 0$$

$$X_n = o_p(Y_n) \implies \frac{X_n}{Y_n} = o_p(1) \implies \frac{X_n}{Y_n} \xrightarrow{p} 0$$

$$X_n = W_n + o_p(1) \implies (X_n - W_n) = o_p(1) \implies (X_n - W_n) \xrightarrow{p} 0$$

Definition 15.10 (Limitação em Probabilidade: O_p). Dizemos que X_n é **limitado em probabilidade** e denotado por $X_n = O_p(1)$, se existe M maior que zero, tal que para todo ε maior que zero, $P(|X_n| > 0) < \varepsilon$.

$$X_n = O_p(1) \implies \exists M > 0; \forall \varepsilon > 0, P(|X_n| > 0) < \varepsilon.$$

Definition 15.11. Dizemos que $X_n = O_p(Y_n)$ se existe M maior que zero, tal que para todo ε maior que zero, $P(|X_n/Y_n| > 0) < \varepsilon$.

$$X_n = O_p(Y_n) \implies \exists M > 0; \forall \varepsilon > 0, P(|X_n/Y_n| > 0) < \varepsilon.$$

Definition 15.12. Se $X_n = O_p(1)$ e $Y_n = o_p(1)$, então

$$X_n Y_n = O_p(1) o_p(1) = o_p(1).$$

Definition 15.13 (Equivalência Assintótica). Seja $\{\mathbf{x}_n\}$ e $\{\mathbf{z}_n\}$ sequências de vetores aleatórios $K \times 1$. Se $\mathbf{z}_n \xrightarrow{d} \mathbf{z}$ e $\mathbf{x}_n - \mathbf{z}_n \xrightarrow{p} \mathbf{0}_K$. Então,

$$\mathbf{x}_n \xrightarrow{d} \mathbf{z}.$$

Definition 15.14 (Convergência em Distribuição). Seja $\{X_n\}_{n \geq 1}$ uma sequência de variáveis aleatórias e X uma variável aleatória com F_n e F suas respectivas FDAs, então

$$X_n \xrightarrow{d} X, \text{ se } F_n(X) \rightarrow F(X)$$

para todo X onde F é contínuo.

Definition 15.15 (Convergência em Distribuição e Limitação em Probabilidade). Se $X_n \xrightarrow{d} X$, X um variável aleatória qualquer; então $X_n = O_p(1)$.

Definition 15.16 (TCL – Teorema Central do Limite). Seja $\{X_n\}_{n=1}^N$ *iid* com $E(X_n) = \mu$ e $\text{Var}(X_n) = \sigma^2 < +\infty$. Então, para $S_N = \sum_{n=1}^N X_n$:

$$\frac{S_N - N\mu}{\sqrt{N}\sigma} = \frac{N(\bar{X} - \mu)}{\sqrt{N}\sigma} = \frac{N(\bar{X} - \mu)}{\sqrt{N}\sigma} = \boxed{\frac{\sqrt{N}(\bar{X} - \mu)}{\sigma} \xrightarrow{d} Z \sim N(0, 1)}.$$

Definition 15.17 (TCL – Caso Vetorial). Seja $\{\mathbf{w}_i\}_{i=1}^n$ uma sequência *iid* de vetores aleatórios $K \times 1$ com $E(w_{ik}^2) < +\infty$, $k = 1, \dots, K$ e $E(\mathbf{w}_i) = \mathbf{0}_K$. Então,

$$N^{-1/2} \sum_{i=1}^N \mathbf{w}_i \xrightarrow{d} N(\mathbf{0}, B),$$

onde, $B = \text{Var}(\mathbf{w}_i) = E(\mathbf{w}_i \mathbf{w}_i')$.

Definition 15.18. Seja $\{\mathbf{z}_n\}$ uma sequência de vetores $K \times 1$ aleatórios com

$$\mathbf{z}_n \xrightarrow{d} N(\mathbf{0}, V).$$

Então, para qualquer matriz A de dimensão $K \times M$ **não** estocástica,

$$A' \mathbf{z}_n \xrightarrow{d} N(\mathbf{0}, A'VA).$$

TODO

1. Acabar Aula 2
2. Revisar Aula 1 com C.4
3. Revisar Conceitos Estatísticos com C.3
4. Fazer POLS com Sec 7.8

References

GREENE, WILLIAM H. 2012. *Econometric Analysis*. 7 edn. Boston: Prentice Hall.

WOOLDRIDGE, JEFFREY M. 2010. *Econometric Analysis of Cross Section and Panel Data*. 2 edn. Boston, Massachusetts: MIT Press.